Ekonomická fakulta
Faculty of Economics
Jihočeská univerzita v Českých Budějovicích
University of South Bohemia in České Budějovice

Jihočeská univerzita v Českých Budějovicích

Ekonomická fakulta

Katedra aplikované matematiky a informatiky

Diplomová práce

Optimalizace vytápění budov pomocí strojového učení

Vypracoval: Bc. Matěj Vachuta

Vedoucí práce: Prokýšek Miloš, PhDr. Ph.D.

České Budějovice 2026

JIHOČESKÁ UNIVERZITA V ČESKÝCH BUDĚJOVICÍCH

Ekonomická fakulta

Akademický rok: 2023/2024

ZADÁNÍ DIPLOMOVÉ PRÁCE

(projektu, uměleckého díla, uměleckého výkonu)

Jméno a příjmení:	**Bc. Matěj VACHUTA**
Osobní číslo:	**E23459**
Studijní program:	**N0613A140025 Aplikovaná informatika**
Specializace:	**Softwarové inženýrství**
Téma práce:	**Optimalizace vytápění budov pomocí strojového učení**
Zadávající katedra:	**Katedra aplikované matematiky a informatiky**

Zásady pro vypracování

Student v diplomové práci zpracuje rešerši existujících přístupů a použitých nástrojů pro optimalizaci vytápění chytrých budov.
Na konkrétním příkladu budovy navrhne a implementuje vlastní řešení pro optimalizaci vytápění. Zvolené řešení podrobí diskuzi a testování.
Vítanou nadstavbou práce je ověření řešení na reálné budově.

Rozsah pracovní zprávy:	**40 – 50 stran**
Rozsah grafických prací:	**dle potřeby**
Forma zpracování diplomové práce:	**tištěná**

Seznam doporučené literatury:

Merabet, G. H., Essaaidi, M., Haddou, M. B., Qolomany, B., Qadir, J., Anan, M., ... & Benhaddou, D. (2021). Intelligent building control systems for thermal comfort and energy-efficiency: A systematic review of artificial intelligence-assisted techniques. Renewable and Sustainable Energy Reviews, 144, 110969.

Vedoucí diplomové práce: **PhDr. Miloš Prokýšek, Ph.D.**
Katedra informatiky

Datum zadání diplomové práce: **27. února 2024**
Termín odevzdání diplomové práce: **15. dubna 2025**

JIHOČESKÁ UNIVERZITA
V ČESKÝCH BUDĚJOVICÍCH
EKONOMICKÁ FAKULTA
Studentská 13 (26)
370 05 České Budějovice

doc. RNDr. Zuzana Dvořáková Líšková, Ph.D.
děkanka

doc. RNDr. Jana Klicnarová, Ph.D.
vedoucí katedry

V Českých Budějovicích dne 27. února 2024

Prohlašuji, že svou diplomovou práci jsem vypracoval samostatně pouze s použitím pramenů a literatury uvedených v seznamu citované literatury. Prohlašuji, že v souladu s § 47b zákona č. 111/1998 Sb. v platném znění souhlasím se zveřejněním své diplomové práce, a to - v nezkrácené podobě/v úpravě vzniklé vypuštěním vyznačených částí archivovaných Ekonomickou fakultou - elektronickou cestou ve veřejně přístupné části databáze STAG provozované Jihočeskou univerzitou v Českých Budějovicích na jejích internetových stránkách, a to se zachováním mého autorského práva k odevzdanému textu této kvalifikační práce. Souhlasím dále s tím, aby toutéž elektronickou cestou byly v souladu s uvedeným ustanovením zákona č. 111/1998 Sb. zveřejněny posudky školitele a oponentů práce i záznam o průběhu a výsledku obhajoby kvalifikační práce. Rovněž souhlasím s porovnáním textu mé kvalifikační práce s databází kvalifikačních prací Theses.cz provozovanou Národním registrem vysokoškolských kvalifikačních prací a systémem na odhalování plagiátů.

České Budějovice dne 7.4. 2026 .....

Matěj Vachuta

Abstrakt

Tato diplomová práce se zabývá optimalizací řízení vytápění budov pomocí metod strojového učení. Tradiční systémy řízení často nedokážou efektivně reagovat na tepelnou setrvačnost budov a proměnlivé vnější vlivy. Prediktivní řízení (MPC) tyto nedostatky řeší, avšak naráží na obtížnou identifikaci a údržbu přesných fyzikálních modelů. Práce proto navrhuje a v simulačním prostředí ověřuje hybridní přístup, který kombinuje nominální modelově prediktivní regulátor s vrstvou reziduální korekce zajišťovanou rekurentní neuronovou sítí (LSTM).

Experimentální srovnání se třemi referenčními strategiemi (On/Off, PID a čistý MPC) na třech typech místností a šesti klimatických scénářích ukázalo, že navržený hybridní regulátor statisticky významně snižuje dobu porušení tepelného komfortu. Největší přínos byl zaznamenán v prostorech s proměnlivou obsazeností a vysokou nepřesností nominálního modelu (např. zasedací místnosti), kde podíl času mimo komfort klesl o desítky procent při srovnatelné spotřebě energie. Naopak v tepelně stabilních zónách s dobře identifikovaným modelem byl rozdíl minimální. Výsledky prokazují, že spojení fyzikálně podloženého MPC s datově řízenou reziduální korekcí představuje efektivní řešení, které kompenzuje nepřesnosti modelu bez narušení stability optimalizačního procesu.

Klíčová slova:

optimalizace vytápění, modelově prediktivní řízení, MPC, strojové učení, rekurentní neuronová síť

Abstract

This master's thesis deals with the optimization of building heating control using machine learning methods. Traditional control systems often fail to efficiently respond to the thermal inertia of buildings and variable external influences. Model Predictive Control (MPC) addresses these shortcomings but faces challenges in identifying and maintaining accurate physical models. Therefore, this thesis proposes and evaluates a hybrid approach in a simulation environment, combining a nominal model predictive controller with a residual correction layer provided by a recurrent neural network (LSTM).

An experimental comparison with three reference strategies (On/Off, PID, and pure MPC) across three room types and six climate scenarios showed that the proposed hybrid controller statistically significantly reduces the time of thermal comfort violation. The greatest benefit was observed in spaces with variable occupancy and high nominal model inaccuracy (e.g., meeting rooms), where the time outside the comfort zone decreased by tens of percent while maintaining comparable energy consumption. Conversely, in thermally stable zones with a well-identified model, the difference was minimal. The results demonstrate that combining physics-based MPC with data-driven residual correction represents an effective solution that compensates for model inaccuracies without compromising the stability of the optimization process.

Keywords:

building heating control, model predictive control, MPC, machine learning, recurrent neural network

Poděkování

Rád bych poděkoval panu PhDr. Miloši Prokýškovi, Ph.D., za jeho odborné vedení, cenné připomínky a vstřícný přístup, který mi během vypracování této diplomové práce věnoval. Velký dík patří také mé rodině a přátelům za jejich podporu a povzbuzení. Zvláště pak děkuji své mamince za trpělivost, pevné nervy a zázemí, které mi po celou dobu studia poskytovala.

Obsah

1 Úvod **1**

2 Vytápění a chytré budovy **3**

2.1 Energetická náročnost budov a význam vytápění 3

2.1.1 Podíl budov na celkové spotřebě energie 3

2.1.2 Podíl vytápění v rezidenčních a kancelářských budovách . . . 5

2.1.3 Kritéria pro porovnání technologií vytápění 6

2.1.4 Motivace pro optimalizaci vytápění 6

2.2 Chytré budovy a řídicí systémy 7

2.2.1 Definice a koncept chytrých budov 7

2.2.2 Základní funkce chytrých budov 8

2.2.3 Building Management Systems (BMS) a jejich architektura . . 8

2.2.4 Senzory, aktuátory a Internet věcí (IoT) 8

2.2.5 Prediktivní řízení a pokročilé algoritmy 9

2.2.6 Integrace s elektrickou sítí (B2G) 9

2.2.7 Výzvy a budoucí směry 9

2.3 Systémy vytápění 9

2.4 Otopné soustavy a předávání tepla 11

2.4.1 Nízkoteplotní plošné vytápění 11

3 Modelování tepelné dynamiky místnosti **12**

3.1 Základní principy tepelné dynamiky zóny 12

3.2 Přístupy k modelování budov 13

3.2.1 Klasifikace modelovacích přístupů 13

3.2.2 RC sítě a jejich matematická formulace 13

3.2.3 Grey-box modely pro model predictive control 14

3.2.4 Neuronové sítě a data-driven přístupy v MPC 14

3.2.5 Efektivní data-driven MPC pro demand response 14

3.2.6 Důsledky pro návrh prediktoru 14

3.3 Model jedné místnosti 15

3.3.1 TiTe model jako základní grey-box přístup 15

3.3.2 Stavový prostorový popis a diskrétní formulace 15

3.3.3 Identifikace parametrů a Bayesovský přístup 15

3.3.4 Volba komplexity a integrace s MPC 15

3.4 Neuronové sítě pro modelování tepelné dynamiky 16

3.4.1 Datové požadavky a konstrukce vstupů 16

3.4.2 NARX a obecné autoregresní sítě 16

3.4.3 LSTM a GRU pro dlouhodobé závislosti 16

3.4.4 Bayesovské NN a kvantifikace nejistoty 16
3.4.5 Physics-informed a modulární NN 17
3.4.6 Konvexní architektury pro NN-MPC 17
3.4.7 Transfer learning a provozní adaptace 17
3.5 Datová a integrační vrstva: od BMS k modelu 17
3.5.1 Kde vznikají data 17
3.5.2 Protokoly a bodový model 18
3.5.3 Interoperabilita a sémantika dat 18
3.5.4 Důsledky pro trénink a validaci 18
3.6 Neuronové sítě jako prediktory tepelné dynamiky 18
3.6.1 Reprezentace vstupů a tvorba regresorů pro časové řady . . . 18
3.6.2 Jednokroková vs. vícekroková predikce 19
3.6.3 Architektury pro sekvenční modelování 19
3.6.4 Tréninkové cíle, regularizace a validace v režimu časových řad 20
3.6.5 Životní cyklus prediktoru: drift, rekalibrace a online adaptace 20
3.7 Datová integrace, BMS a sémantika měření 21
3.7.1 BMS jako primární zdroj provozních dat 21
3.7.2 Interoperabilita: komunikační standardy vs. význam dat . . . 21
3.7.3 Sémantická vrstva: Project Haystack a Brick 22
3.7.4 Důsledky pro modelování a řízení 22

4 Řídicí metody pro vytápění 23
4.1 Klasické metody řízení vytápění 23
4.1.1 On/Off a hysterezní řízení 23
4.1.2 PID regulátory 23
4.1.3 Ladění PID parametrů 24
4.1.4 Data-driven adaptivní ladění 24
4.1.5 Klíčové poznatky k využití PDCBO 24
4.1.6 Limity klasických metod 25
4.2 Základní princip modelově prediktivního řízení (MPC) 25
4.2.1 Princip fungování MPC 25
4.2.2 Klíčové výhody MPC 26
4.2.3 Varianty MPC 26
4.2.4 Výpočetní aspekty 27
4.2.5 Formální optimalizační úloha MPC pro vytápění 27
4.2.6 Měkká omezení a robustní komfort 28
4.2.7 Komfortní kritéria: teplotní pásmo vs. PMV/PPD 28
4.2.8 Odhad stavu a poruch: proč je důležitý pozorovatel 29
4.2.9 Robustní a stochastické MPC v HVAC 29

4.3 MPC ve vytápění a HVAC . . . 29
4.3.1 Typické aplikace a úspory . . . 29
4.3.2 Multi-zónové a distribuované MPC . . . 30
4.3.3 Bariéry adopce v praxi . . . 30
4.4 Data-driven MPC s neuronovými sítěmi . . . 31
4.4.1 Architektonické přístupy k NN-MPC . . . 31
4.4.2 Kvantifikace nejistoty . . . 32
4.4.3 Praktické implementace a důsledky pro návrh . . . 32
4.4.4 Implementační aspekty a hardware . . . 32
4.4.5 Klíčové poznatky . . . 33

5 Východiska a omezení pro návrh řešení 34

6 Metodika a návrh simulačního experimentu 36
6.1 Cíle praktické části a specifikace požadavků . . . 36
6.1.1 Definice KPI . . . 36
6.2 Architektura aplikace a správa experimentů . . . 40
6.3 Konfigurace a simulační model prostředí . . . 41
6.3.1 Typové místnosti . . . 41
6.3.2 Model tepelné dynamiky . . . 41
6.4 Strukturální odchylka modelu a skrytá obsazenost . . . 42
6.4.1 Záměrná chyba nominálního modelu . . . 42
6.4.2 Skrytá obsazenost . . . 43
6.5 Návrh a implementace řídicích strategií . . . 43
6.5.1 Sjednocené rozhraní . . . 43
6.5.2 Řízení s pásmem necitlivosti (`onoff`) . . . 44
6.5.3 PID regulátor . . . 44
6.5.4 Konvenční MPC . . . 44
6.6 Hybridní MPC s reziduální korekcí (LSTM) . . . 45
6.6.1 Motivace . . . 45
6.6.2 Architektura reziduální sítě . . . 45
6.6.3 Trénink . . . 45
6.6.4 Inference . . . 46
6.7 Metodika generování testovacích scénářů . . . 47
6.7.1 Klimatické profily . . . 47
6.7.2 Reprodukovatelnost . . . 48
6.8 Experimentální infrastruktura a ověřovací pravidla . . . 48
6.8.1 Základní běh . . . 48
6.8.2 Komplexní benchmark . . . 48
6.8.3 Ochranné mechanismy a audit . . . 49

6.9 Metodika statistického vyhodnocení 49

7 Experimentální vyhodnocení a výsledky 51

7.1 Souhrnné výsledky experimentu 51

7.1.1 Celkové pořadí regulátorů 51

7.1.2 Normalizace napříč místnostmi 52

7.1.3 Spotřeba energie 53

7.2 Analýza chování regulátorů v referenčních scénářích 54

7.2.1 Deskriptivní průměr v hodinách 54

7.2.2 Normalizované scénářové srovnání 55

7.2.3 Interpretace scénářů na úrovni místností 56

7.2.4 Reprezentativní časové trajektorie 57

7.2.5 Doplňková ablace velikosti odchylky modelu 60

7.3 Robustnost optimalizace a výpočetní náročnost 60

7.3.1 Stabilita solveru 60

7.3.2 Výpočetní náročnost 60

7.4 Výsledky statistického posouzení 61

7.4.1 Statistická významnost na úrovni běhů 61

7.4.2 Výsledky na úrovni scénářů 62

7.4.3 Pohled na úrovni místností 62

8 Diskuze a zhodnocení limitů 63

8.1 Interpretace výsledků experimentu 63

8.2 Praktická doporučení pro nasazení 64

8.3 Reprodukovatelnost a robustnost řešení 64

8.4 Ohrožení validity a omezení 64

8.5 Možnosti budoucího rozšíření 65

9 Závěr 67

Seznam zkratek 69

Summary 72

Seznam použitých zdrojů 74

Seznam obrázků 83

Seznam tabulek 84

Příloha A – Obsah přiloženého datového nosiče 85

1 Úvod

Tato diplomová práce se zaměřuje na možnosti optimalizace řízení vytápění s využitím metod strojového učení. Budovy patří mezi významné spotřebitele energie a vytápění tvoří podstatnou část jejich provozních nákladů. V kontextu chytrých budov se proto stále častěji uvažuje o využití pokročilé senzoriky, IoT a datově řízených metod, které by umožnily efektivněji řídit dodávku tepla a současně zachovat požadovaný tepelný komfort uživatelů.

V praxi je řízení vytápění často realizováno pevně nastavenými programy, jednoduchými pravidly nebo klasickými regulátory, které pracují s omezeným množstvím vstupů, typicky s venkovní teplotou a časovým rozvrhem. Takové přístupy však zpravidla nedokážou dostatečně zohlednit časovou dynamiku, setrvačnost budovy ani vlivy, které se v čase výrazně mění, jako je obsazenost, vnitřní tepelné zisky, sluneční záření nebo vítr. Důsledkem může být zbytečná spotřeba energie, nebo zhoršení komfortu. Podstatou problému je tedy řízení systému s výraznou časovou dynamikou a nejistotou, kde je žádoucí nejen reagovat na aktuální stav, ale také pracovat s odhadem budoucího vývoje a plánovat řídicí zásahy s určitým předstihem.

Řízení vnitřního prostředí budov se obvykle shrnuje pod pojem HVAC, který zahrnuje vytápění, větrání a chlazení. Pod oblast HVAC spadá široká škála úloh od regulace teploty a kvality vzduchu až po řízení chlazení a větrání. Tato práce se však záměrně vymezuje pouze na regulaci vytápění a soustředí se na návrh systému, který řídí zdroj vytápění pro zvolený prostor, tedy pro jednu zónu (jednu místnost). Cílem není navrhnout univerzální řešení pro všechny části HVAC ani kompletní řízení celé budovy, ale popsat a ověřit postup pro řízení dodávky tepla v definovaném prostoru na základě dostupných provozních dat.

Práce vychází z výzkumného očekávání, že metody strojového učení mohou v úloze řízení vytápění nabídnout přesnější zachycení dynamiky systému a proměnných vlivů prostředí a tím vytvářet předpoklad pro úspornější provoz při zachování požadovaného komfortu. Na tato očekávání navazují výzkumné otázky, které práce řeší: jaké přístupy a nástroje se dnes používají pro optimalizaci vytápění a jak se liší tradiční metody od řešení využívajících umělou inteligenci, jaká data jsou pro optimalizaci vytápění v praxi dostupná a v jaké kvalitě, a jak navrhnout a vyhodnotit konkrétní postup řízení vytápění pro zvolenou místnost tak, aby bylo možné jeho chování transparentně a objektivně porovnat s referenčními strategiemi z hlediska

energie a komfortu.

Hlavním cílem této diplomové práce je navrhnout a ověřit postup pro řízení dodávky tepla v definovaném prostoru na základě dostupných provozních dat. Tohoto cíle má být dosaženo vytvořením systému, který využívá modely strojového učení a umožňuje objektivní porovnání s referenčními strategiemi z hlediska spotřeby energie a zajištění tepelného komfortu. Hlavní cíl práce je následně rozpracován do systému dílčích cílů:

- Zhodnocení teoretických východisek a rešerše aktuálních přístupů k modelování tepelné dynamiky budov a řídicích metod, od tradičních regulátorů až po datově řízené modelově prediktivní řízení.
- Příprava simulačního prostředí ve formě zjednodušeného fyzikálního modelu.
- Návrh, implementace a validace vlastního řešení řízení vytápění.
- Porovnání jednotlivých řídicích algoritmů na základě definovaných KPI výkonosti v simulované prostředí.

2 Vytápění a chytré budovy

2.1 Energetická náročnost budov a význam vytápění

2.1.1 Podíl budov na celkové spotřebě energie

Budovy představují jeden z nejvýznamnějších sektorů z hlediska spotřeby energie i emisí skleníkových plynů. V evropském kontextu jsou často uváděny hodnoty kolem 40% spotřeby energie a přibližně 36% emisí skleníkových plynů, což z budov činí klíčovou oblast pro naplňování klimaticko-energetických cílů. (European Commission, 2020a). Z tohoto důvodu je zvyšování energetické účinnosti budov dlouhodobě zakotveno v evropské legislativě a politice energetické efektivity. (např. EPBD) (European Commission, 2020b).

Situace v Evropské unii

Pro interpretaci významu sektoru budov je důležité rozlišovat, zda se podíl vztahuje ke konečné spotřebě energie (energie dodaná koncovému uživateli) nebo k primární energii (energie včetně ztrát při výrobě a transformaci). Z pohledu konečné spotřeby energie sektorové členění ukazuje, že budovy patří v Evropě mezi dominantní koncové sektory. V roce 2010 připadalo na budovy 41% celkové konečné spotřeby energie, zatímco doprava představovala 32% a průmysl 25% (Enerdata, 2012).

Vedle tohoto „koncového“ pohledu je v literatuře často diskutována také perspektiva primární energie, která lépe vystihuje systémové dopady spotřeby (zejména u elektřiny a tepla). V tomto vyjádření je evropský fond budov odhadován na přibližně 720 Mtoe[1]/rok. Tento odhad je současně interpretován jako zhruba 40% celkové poptávky EU po primární energii (EURAC Research, 2021). Jinými slovy, ačkoliv se konkrétní procenta liší podle definice ukazatele a referenčního roku, sektor budov dlouhodobě představuje přibližně „dvě pětiny“ energetického systému EU.

Aktuálnější agregované analýzy (ODYSSEE-MURE) uvádějí, že na úrovni EU budovy tvoří přibližně 43% konečné spotřeby. Současně je ve stejném zdroji uvedeno, že jejich spotřeba byla od roku 2014 stabilní, zatímco HDP v období 2014–2019 rostlo přibližně o 1,5% ročně. Tato kombinace naznačuje postupné „oddělování“ (decoupling) ekonomického růstu od energetické spotřeby v sektoru budov, i když bez výrazného poklesu absolutní spotřeby (ODYSSEE-MURE, 2021).

[1] Mtoe (*Million tonnes of oil equivalent*) – milion tun ropného ekvivalentu, jednotka energie užívaná v makroekonomice a energetice. 1 Mtoe = 11,63 TWh.

Energetický význam sektoru budov je dále podmíněn strukturou fondu. Pro evropské prostředí je typická dominance rezidenčního segmentu: rezidenční budovy tvoří přibližně 76% podlahové plochy budov na úrovni EU. Ve většině zemí zároveň rezidenční sektor představuje více než 60% spotřeby energie v rámci sektoru budov (Enerdata, 2012). Z hlediska politik a opatření je podstatný také stav existujícího fondu: přibližně 85% budov bylo postaveno před rokem 2000 a přibližně 75% z nich má slabou energetickou účinnost. Míra renovací se dlouhodobě pohybuje okolo 1% ročně (European Commission, 2020b). To implikuje, že významné úspory a snižování emisí budou do značné míry záviset na renovacích stávajících budov, nikoli pouze na standardech novostaveb.

Dominance vytápění a ohřevu vody

V sektoru domácností je energetická náročnost budov z velké části determinována dodávkou tepla, konkrétně vytápěním prostoru a přípravou teplé užitkové vody. V roce 2023 představovalo vytápění prostoru a ohřev vody 77,6% konečné spotřeby energie domácností v EU. Pro dekarbonizaci je proto klíčové nejen snižování potřeby tepla (zateplení, řízení, renovace), ale i změna zdrojů a paliv. Podle Eurostatu obnovitelné zdroje pokrývají 33,0% energetických potřeb pro vytápění prostoru a 16,2% pro ohřev vody (EU, 2023) (Eurostat, 2025).

Pro doplnění kontextu lze uvést také globální perspektivu: celková konečná spotřeba energie v budovách je uváděna kolem 123 EJ, přičemž přibližně polovina (cca 63 EJ) připadá na vytápění prostoru a ohřev vody. Současně se globální dodávka tepla v budovách stále ve velké míře opírá o fosilní paliva: v roce 2020 tvořila fosilní paliva přibližně 62% dodávky energie pro budovy, následovaná biomasou (26%) a moderními obnovitelnými zdroji (12%) (Energy Transitions Commission, 2020). V evropském prostředí se dekarbonizace vytápění a chlazení typicky diskutuje také ve vazbě na vysoký podíl fosilních paliv a na roli zemního plynu. Sekundární analýzy k tomu uvádějí významnou roli plynu v evropském teplárenství (FutureBridge, n.d.).

Situace v České republice

V ČR je sektor budov (rezidenční a službový) rovněž významným spotřebitelem energie. Podle profilu ODYSSEE-MURE je jeho spotřeba dlouhodobě relativně stabilní: v období 2000–2022 kolísala kolem 10 Mtoe, přičemž se v čase měnila struktura spotřeby mezi rezidenční a nerezidenční částí sektoru (ODYSSEE-MURE, 2025). Důležitý empirický obraz struktury dodávek energie do domácností poskytuje šetření ENERGO (ČSÚ): v roce 2021 domácnosti přijímaly největší část energie z

obnovitelných zdrojů (mírně přes 30%) a následoval zemní plyn (přibližně 26%) (Czech Statistical Office, 2021).

2.1.2 Podíl vytápění v rezidenčních a kancelářských budovách

Energetická náročnost budov je ve významné míře ovlivněna spotřebou energie na vytápění prostoru a (v závislosti na typu budovy a systému) také na přípravu teplé užitkové vody. Tuto dominanci potvrzují jak agregovaná evropská data (viz výše), tak i modelové a simulační studie na úrovni jednotlivých typů budov. V simulační studii tří typických rezidenčních budov v jižní Evropě tvořila složka „vytápění prostoru + TUV“ většinu nakoupené energie napříč odlišnými klimatickými podmínkami i provozními režimy vytápění (Wang et al., 2022).

Rezidenční budovy

V segmentu rezidenčních budov, které tvoří v celkové podlahové ploše budov dominantní podíl (například 84% v Řecku, 81% v Portugalsku a 83% ve Španělsku), je energetická bilance citlivá na režim vytápění a na to, zda je spotřeba posuzována v režimu přerušovaného či nepřetržitého vytápění. Simulační rozklad nakoupené energie u referenčních (před-renovačních) stavů prokázal následující podíly „vytápění prostoru + TUV“ na celkové nakoupené energii při přerušovaném vytápění: Řecko (bytový dům) 71%, Portugalsko (sociální bydlení) 89% a Španělsko (řadový dům) 86%.

Při přechodu na nepřetržité vytápění (continuous heating) se podíl „vytápění prostoru + TUV“ dále zvýšil na 86% (Řecko), 94% (Portugalsko) a 88% (Španělsko), což ukazuje, že provozní režim může významně měnit jak absolutní spotřebu, tak i relativní strukturu koncové spotřeby energie (Wang et al., 2022). Tato zjištění jsou stejná i s poznatky z UK, kde jsou systémy vytápění identifikovány jako dominantní složka rezidenční energetické poptávky s podílem přibližně 80% (“Enhanced EnHub: dynamic simulation of housing stock energy systems”, 2020). Významný vliv na spotřebu má současně uživatelské chování (Wang et al., 2022).

Nerezidenční a kancelářské budovy

U nerezidenčních budov je vedle samotného podílu vytápění důležité také tempo renovací a potenciál úspor, protože i tento segment musí přispět k naplnění klimatických cílů. Zdroje uvádí, že renovací pro splnění klimatických cílů dosáhlo přibližně 12% rezidenčního fondu a zhruba 9% nerezidenčního fondu (Wang et al., 2022).

Z pohledu návrhu a simulací se v obou sektorech často uvažují nízkoteplotní otopné soustavy (např. podlahové vytápění), protože umožňují snížit teplotu topné vody oproti radiátorům a tím zvýšit účinnost tepelných čerpadel. Tento vztah je explicitně diskutován v kontextu modelování podlahových otopných systémů (Göbel et al., 2021). Pro analýzu dopadů technologií a provozních režimů na úrovni větších celků se používají také dynamické simulační nástroje ("Enhanced EnHub: dynamic simulation of housing stock energy systems", 2020).

2.1.3 Kritéria pro porovnání technologií vytápění

Pro účely této kapitoly budu technologie vytápění porovnávat podle těchto pěti praktických kritérií:

1. **investiční náklady** (CAPEX),
2. **provozní náklady** a citlivost na ceny energie (OPEX),
3. **environmentální dopady** (primární energie/CO_2),
4. **vhodnost pro nízkoteplotní otopné soustavy**,
5. **regulační vlastnosti** (rychlost odezvy, omezení výkonu, setrvačnost).

Tato kritéria jsou důležitá nejen pro volbu technologie, ale také pro návrh prediktivního řízení, protože ovlivňují dynamiku soustavy, dostupné akční zásahy i dosažitelnou flexibilitu provozu.

2.1.4 Motivace pro optimalizaci vytápění

Optimalizace vytápění v budovách představuje komplexní úlohu, ve které je nutné vyvažovat ekonomické náklady, environmentální dopady a tepelný komfort. Moderní řídicí přístupy, zejména model predictive control (MPC), umožňují řídit vytápění na základě predikce poptávky a současně explicitně zohlednit komfortní omezení. V prostředí nearly-zero energy buildings (nZEB) bylo prokázáno, že MPC může při dodržení omezení dle ASHRAE Standard 55 a při řízení setpointů v rozmezí 20–22 °C dosahovat až 17% denních úspor nákladů na vytápění oproti konvenčnímu řízení při srovnatelném komfortu (Qi et al., 2025).

Ekonomické důvody

Ceny energie a volba energetického nosiče významně ovlivňují provozní náklady budov, přičemž vytápění patří k dominantním položkám. Případová studie existujícího bytového domu v Prištině (Kosovo) ukazuje výrazné rozdíly ve specifických

nákladech paliv. Ve stejné studii klesly roční náklady na vytápění po implementaci energeticky úsporných opatření z 20 548 € na 10 013 € (Bresa et al., 2023).

Dalším ekonomickým motivem je možnost flexibilního řízení poptávky (demand response, DR). V analýze německého systému dálkového vytápění autoři uvádějí, že aplikace DR snížila náklady na vytápění pro vlastníky budov o 2,8–4,9% (Ju et al., 2022). U složitějších energetických systémů mohou optimalizační strategie dosahovat ještě vyšších efektů (Zhang et al., 2023).

Environmentální důvody

Dekarbonizace budov je úzce svázána s tím, jakým způsobem je zajišťováno teplo. V uvedené případové studii vedla kombinace energeticky úsporných opatření a volby HVAC řešení k výrazné redukci emisí (Bresa et al., 2023). Z pohledu technologií je významným nástrojem elektrifikace tepla prostřednictvím tepelných čerpadel (CAP2i, 2024).

Komplexní přístup k optimalizaci

Optimalizace vytápění typicky přináší i další benefity (nižší náklady, nižší opotřebení komponent, prodloužení životnosti zařízení). Tyto přínosy jsou v praxi často spojovány s lepšími senzory, řízením a průběžnou optimalizací HVAC systémů. Zároveň existuje vazba na plnění norem a regulatorních rámců (Dassault Systèmes, n.d.).

Tepelný komfort uživatelů

Současně platí, že cílem optimalizace není pouze minimalizace energie, ale udržení tepelného komfortu uživatelů. V nZEB scénáři s MPC bylo explicitně zvoleno komfortní omezení a řízení teplotních setpointů 20–22 °C, přičemž bylo dosaženo srovnatelné úrovně komfortu při současných úsporách nákladů (Qi et al., 2025).

2.2 Chytré budovy a řídicí systémy

Moderní budovy procházejí transformací z pasivních struktur na inteligentní systémy schopné dynamicky reagovat na vnější i vnitřní podmínky.

2.2.1 Definice a koncept chytrých budov

Chytrá budova představuje významný pokrok oproti tradičním energeticky úsporným budovám. Podle definic používaných v odborných přehledech a evropském kontextu jde o budovu s vysokou energetickou účinností, schopnou řídit zdroje, měření

a flexibilitu ve vztahu k síti prostřednictvím pokročilých řídicích systémů.

Z pohledu data-driven přístupu je zásadní, aby budova dokázala bezpečně a konzistentně pracovat s daty a aby se řešila otázka interoperability, integrity a ochrany soukromí (IEA EBC Annex 81, 2023).

2.2.2 Základní funkce chytrých budov

Funkčnost chytrých budov lze rozdělit do čtyř propojených oblastí, které popisují jejich jádro (IEA EBC Annex 81, 2023):

1. **Climate Response (Reakce na klima)**
   schopnost budovy reagovat na aktuální i očekávané klimatické podmínky a minimalizovat energetickou poptávku při zachování požadovaných vnitřních podmínek.

2. **Grid Response (Reakce na síť)**
   schopnost budovy reagovat na signály ze sítě s cílem maximalizovat energetickou nebo ekonomickou efektivitu.

3. **User Response (Reakce na uživatele)**
   umožnění průběžné interakce uživatelů se systémem řízení a promítnutí preferencí do optimalizace provozu.

4. **Monitoring and Supervision (Monitoring a supervize)**
   real-time monitoring technických systémů a chování uživatelů.

2.2.3 Building Management Systems (BMS) a jejich architektura

Building Management System (BMS) představuje komplexní systém pro centralizaci a řízení různých funkcí budovy. V odborné literatuře se setkáváme s různými termíny – BAS, BACS, BMS nebo BEMS – které se často překrývají a všechny označují systémy pro automatizaci a řízení budov (Taboada-Orozco et al., 2024).

2.2.4 Senzory, aktuátory a Internet věcí (IoT)

Senzory a aktuátory tvoří fyzickou vrstvu chytrých budov, která zajišťuje sběr dat a provádění řídicích akcí. Budovy jsou bohaté na informace a vybaveny různými zařízeními, která neustále sbírají a produkují data.

Hlavní výzvou v této oblasti je heterogenita dat a zařízení (Taboada-Orozco et al., 2024; Al Dakheel et al., 2020).

2.2.5 Prediktivní řízení a pokročilé algoritmy

Moderní chytré budovy využívají pokročilé algoritmy pro optimalizaci svého provozu. Systematický přehled identifikoval hlavní kategorie metod používaných v BMS. Zvláštní pozornost si zaslouží Model Predictive Control (MPC) (Taboada-Orozco et al., 2024).

2.2.6 Integrace s elektrickou sítí (B2G)

Jednou z oblastí, kde budou mít data-driven aplikace významný dopad, je zlepšení interakce mezi budovami a energetickými sítěmi prostřednictvím zvýšené dostupnosti dat a zvýšené kapacity pro sdílení těchto dat.

V jádru interakce building-to-grid (B2G) je koncept flexibility. Existují dva hlavní přístupy k demand response: přímé řízení a nepřímé řízení.

Příkladem pokročilého data-driven B2G frameworku je Smart Energy Operating System (SEOS) v Dánsku (IEA EBC Annex 81, 2023).

2.2.7 Výzvy a budoucí směry

Širší adopce data-driven chytrých budov naráží na kombinaci technologických a regulatorních překážek (IEA EBC Annex 81, 2023; Taboada-Orozco et al., 2024). Z pohledu B2G se současně zdůrazňují požadavky na ochranu soukromí, bezpečnost a důvěryhodnost dat (IEA EBC Annex 81, 2023).

2.3 Systémy vytápění

Evropský rezidenční sektor využívá široké spektrum technologií vytápění. Z pohledu energetické transformace a plánování dekarbonizace se často používají simulační přístupy, které modelují konkurenci a difuzi jednotlivých technologií vytápění v čase.

Jednotlivé technologie:

- Kotle na zemní plyn
- Kotle na biomasu
- Tepelná čerpadla
- Elektrické vytápění a přímotopy
- Centrální zásobování teplem (CZT)

Pro správné zasazení do kontextu je klíčové přiblížit model FTT:Heat (Future Technology Transformations: Heat). Jedná se o pokročilý simulační model technologické difuze, který je primárně určen k analýze a predikci vývoje trhu s vytápěcími systémy v domácnostech. Model podrobně zkoumá rozhodovací procesy investorů a domácností při výběru zdroje tepla, přičemž nahlíží na technologie nejen optikou čistých nákladů, ale zohledňuje také omezenou racionalitu spotřebitelů, behaviorální aspekty, technologické učení a dopady klimatických či dotačních politik (Knobloch et al., 2017). Díky tomuto komplexnímu přístupu dokáže FTT:Heat simulovat dynamiku tržních podílů jednotlivých technologií v čase a vytvářet realistické scénáře dekarbonizace sektoru budov.

Plynové kotle patří mezi běžně používané technologie vytápění domácností a v modelech technologické difuze vystupují jako jedna z konkurujících variant (Knobloch et al., 2017). V hodnoceních environmentální a ekonomické výkonnosti vytápěcích systémů se dopady technologií typicky vyjadřují přes primární energii a ekvivalentní emise CO_2, což umožňuje porovnání plynových kotlů s alternativami (Georges et al., 2012).

Biomasové technologie jsou v portfoliu FTT:Heat uvažovány jako jedna z alternativ k fosilním palivům a jejich uplatnění je v modelu výsledkem konkurence technologií při zohlednění nákladů a politik (Knobloch et al., 2017). Zároveň platí, že u domů s velmi nízkou potřebou tepla se může ekonomická rovnováha posouvat: investičně náročnější systémy (včetně biomasy, solární termiky či tepelných čerpadel) mohou mít z pohledu uživatele delší dobu návratnosti, i když mohou vykazovat příznivější environmentální profil při hodnocení přes primární energii a CO_2 (Georges et al., 2012).

Tepelná čerpadla jsou ve FTT:Heat explicitně zahrnuta jako klíčová nízkouhlíková alternativa a v dekarbonizačních scénářích mohou postupně nahrazovat část konvenčních zdrojů vytápění (Knobloch et al., 2017). V technicko-ekonomických analýzách pro pasivní a nízkoenergetické domy se opakovaně ukazuje, že rozhodování o vhodném zdroji tepla je citlivé na investiční náklady a na to, jak malá je celková roční dodávka tepla (tj. jak rychle se úspory v provozu projeví) (Georges et al., 2012). U tepelného čerpadla je z hlediska řízení i účinnosti zásadní teplotní rozdíl mezi zdrojem a „sink“ stranou, proto má význam volba nízkoteplotní otopné soustavy (např. podlahové vytápění), která snižuje potřebnou teplotu otopné vody a může zvyšovat účinnost tepelného čerpadla (Göbel et al., 2021).

Elektrické vytápění je ve FTT:Heat zahrnuto jako samostatná konkurenční technologie (včetně přímého odporového vytápění). V kontextu nízkoenergetických obálek budov je důležitý kompromis mezi investicí a provozem: jednoduché elektrické systémy mohou mít nižší pořizovací náklady, ale vyšší spotřebu elektřiny, přičemž při nízké potřebě tepla se návratnost investic do vysoce účinných systémů (např. tepelného čerpadla) může prodlužovat (Georges et al., 2012).

CZT (district heating) se ve FTT:Heat objevuje jako jedna z technologií pokrývajících poptávku po teple tam, kde je k dispozici odpovídající infrastruktura (Knobloch et al., 2017). V techno-ekonomických a environmentálních analýzách se CZT často porovnává s tepelnými čerpadly. Výsledky závisí mimo jiné na předpokladech o dodávkách energie (např. elektřina pro tepelná čerpadla a palivový mix pro CZT) a posuzují se v dimenzích primární energie, klimatických dopadů a nákladů životního cyklu (Dodoo, 2019).

2.4 Otopné soustavy a předávání tepla

2.4.1 Nízkoteplotní plošné vytápění

Podlahové vytápění představuje typický nízkoteplotní distribuční systém s vyšší tepelnou setrvačností danou konstrukcí podlahy. Studie z Modelica Conference 2021 popisuje detailní model teplovodního podlahového systému zahrnující rozdělovač, více topných okruhů a tepelné vrstvy podlahy, přičemž explicitně modeluje přenos tepla z potrubí přes podlahové vrstvy do místnosti. Parametrická analýza ukazuje, že konstrukční parametry (zejména rozteč trubek) přímo ovlivňují požadovanou teplotu přívodní vody: zvětšení rozteče z 100 mm na 400 mm zvýšilo teplotu přívodu z 36,6 °C na 47,5 °C (tj. o 10,9 K). Z pohledu chytrého řízení i návrhu prediktivních algoritmů je proto důležité, aby model distribuční soustavy zachycoval relevantní konstrukční parametry a dynamiku akumulace v podlaze, protože tyto vlastnosti ovlivňují odezvu systému a dosažitelnou účinnost zdroje (zejména u tepelných čerpadel) (Göbel et al., 2021).

3 Modelování tepelné dynamiky místnosti

Budovy se v současnosti podílejí významnou měrou na celosvětové spotřebě energie. S rostoucími požadavky na energetickou efektivitu a vnitřní komfort se však ukazuje, že tradiční přístupy k návrhu a provozu budov narážejí na své limity. Pro dosažení skutečných úspor již nestačí pouze kvalitní izolace. Klíčem se stává inteligentní řízení. Abychom však mohli budovu efektivně řídit nebo optimalizovat, musíme být schopni předvídat její chování.

Právě zde hraje nezastupitelnou roli matematické modelování. Model slouží jako "virtuální dvojče" reálného systému, které nám umožňuje analyzovat dynamické děje – například jak rychle místnost vychladne po vypnutí topení nebo jak se projeví náhlý sluneční svit – aniž bychom museli provádět nákladné experimenty na reálném objektu. Kvalitní model tepelné dynamiky je tak základním stavebním kamenem pro návrh pokročilých regulátorů i pro ověřování nových konceptů vytápění a chlazení.

3.1 Základní principy tepelné dynamiky zóny

Z pohledu teploty jedné zóny (místnosti) jsou rozhodující tři skupiny jevů: (i) přenos tepla přes obálku budovy (vedení + přestup), (ii) výměna vzduchu (infiltrace/větrání) a (iii) vnitřní a solární tepelné zisky (Vala, 2004).

Pro účely řízení se typicky používá **lumped** (koncentrovaný) popis: místo teplotního pole v prostoru uvažujeme jednu reprezentativní teplotu zóny $T_z(t)$. Dominantní dynamiku lze vyjádřit energetickou bilancí:

$$C_z \frac{dT_z}{dt} = \sum_{j \in \mathcal{N}} \frac{T_j - T_z}{R_{zj}} + \eta\, P_{\text{heat}}(t) + q_{\text{int}}(t) + q_{\text{sol}}(t) - q_{\text{vent}}(t), \tag{1}$$

kde C_z je ekvivalentní tepelná kapacita zóny (vzduch + "připojená" část konstrukcí), členy R_{zj} reprezentují tepelné odpory vůči okolí (venek, sousední zóny, obálka), P_{heat} je řídicí zásah (výkon topení) s účinností η a $q_{\text{int}}, q_{\text{sol}}, q_{\text{vent}}$ jsou poruchy (vnitřní zisky, slunce, větrání) (Doddi et al., 2018).

V praxi je klíčové, že tato dynamika má výraznou **setrvačnost** (časové konstanty v řádu hodin) a současně je ovlivněna poruchami, které se v čase mění (obsazenost, počasí). To je přesně důvod, proč reaktivní regulátory často nedokážou využít akumulaci v konstrukcích a proč dává smysl prediktivní řízení (MPC) (Drgoňa et al., 2020; Killian & Kozek, 2016).

Z hlediska modelování pro MPC jsou rozhodující dvě věci: (i) **správná časová dynamika** (časové konstanty a zpoždění) a (ii) **separace řízení a poruch** (aby optimalizátor věděl, co může ovlivnit a co ne). Detailní CFD a PDE modely jsou pro tento účel typicky zbytečně složité, místo toho se používají RC modely nebo datově řízené sekvenční modely (Doddi et al., 2018; Hannula et al., 2025).

3.2 Přístupy k modelování budov

3.2.1 Klasifikace modelovacích přístupů

Modelování tepelného chování budov lze rozdělit do tří základních kategorií: **white-box** modely, **grey-box** modely a **black-box** modely (Doddi et al., 2018).

White-box modely

White-box modely vycházejí z detailní fyzikální reprezentace systému a zahrnují rozsáhlé informace o konstrukci budovy, materiálech i HVAC. Typickým příkladem jsou simulační nástroje jako EnergyPlus. Pro řízení v reálném čase jsou však často nevhodné kvůli vysokým nárokům na parametrizaci a výpočet.

Black-box modely

Black-box modely se učí čistě z dat (např. lineární regrese, stromové modely, neuronové sítě). Dokážou být velmi přesné, ale trpí horší interpretovatelností a rizikem selhání mimo rozsah trénovacích dat.

Grey-box modely

Grey-box modely kombinují fyzikální strukturu s identifikací parametrů z dat. Typicky jde o RC (resistor-capacitor) sítě, které zachycují dominantní dynamiku s nízkou výpočetní náročností (Doddi et al., 2018; Frahm et al., 2022).

3.2.2 RC sítě a jejich matematická formulace

RC síť představuje budovu jako graf $G = (V, E)$, kde uzly jsou teplotní uzly (zóny nebo konstrukční uzly) a hrany reprezentují tepelné odpory mezi nimi. Pro zónu j platí bilance:

$$C_j \frac{dT_j}{dt} = \sum_{i \in N_j} \frac{T_i - T_j}{R_{ji}} + q_j, \tag{2}$$

kde q_j shrnuje poruchy a případně i řízení (Doddi et al., 2018).

V maticové formě:

$$[C]\frac{dT}{dt} = [R]T + q, \tag{3}$$

přičemž diskretizace dává standardní LTI tvar vhodný pro MPC:

$$T(k+1) = AT(k) + Bu(k) + Ed(k). \tag{4}$$

Tato forma je klíčová, protože umožňuje formulovat MPC jako konvexní optimalizaci (typicky QP) při zachování omezení (Rawlings et al., 2018).

3.2.3 Grey-box modely pro model predictive control

Grey-box modely představují praktický kompromis pro MPC: fyzikální interpretace parametrů zůstává zachována, ale model je dostatečně jednoduchý pro online optimalizaci (Frahm et al., 2022). U vícezónových budov umožňují modelovat vazby mezi zónami a přizpůsobit úroveň detailu podle účelu řízení (komfort vs. úspory vs. flexibilita) (Christofides et al., 2013).

3.2.4 Neuronové sítě a data-driven přístupy v MPC

Integrace neuronových sítí do rámce MPC je motivována dvěma praktickými důvody: (i) některé poruchy jsou obtížně měřitelné (obsazenost, interní zisky) a (ii) reálné budovy vykazují nelinearity a změny režimu, které jednoduché lineární modely nezachytí (Drgoňa et al., 2020; Eini & Abdelwahed, 2019).

V *learning-based MPC* mohou neuronové sítě sloužit jako (a) prediktor dynamiky, (b) prediktor poruch (obsazenost), nebo (c) korektor fyzikálního modelu (Eini & Abdelwahed, 2019; Jiang & Dong, 2024). Specificky pro obsazenost Eini & Abdelwahed (2019) použili NARX síť jako prediktor časové řady, kterou následně použili v MPC (Eini & Abdelwahed, 2019).

3.2.5 Efektivní data-driven MPC pro demand response

Paré et al. (2024) navrhují Input Convex Recurrent Neural Network (ICRNN), která zachovává konvexitu (vůči vstupům) a tím výrazně zlepšuje řešitelnost MPC v reálném čase (Paré et al., 2024). Tento směr je klíčový pro praktické nasazení NN-MPC, protože klasické NN často vedou na nekonvexní optimalizaci.

3.2.6 Důsledky pro návrh prediktoru

Volba modelu ovlivňuje nejen přesnost, ale hlavně řešitelnost a udržitelnost v provozu. Z hlediska výpočetní náročnosti jsou white-box modely nevhodné pro online

řízení, zatímco RC modely a konvexní architektury neuronových sítí jsou výpočetně řešitelné (tractable) (Doddi et al., 2018; Paré et al., 2024). Dalším klíčovým faktorem je schopnost generalizace, neboť čisté black-box modely mohou výrazně degradovat mimo trénovací režim. Z tohoto důvodu se jako robustnější jeví physics-informed či hybridní přístupy (Jiang & Dong, 2024). V neposlední řadě hraje roli nejistota samotné predikce. Pro robustní nebo stochastické MPC jsou proto vysoce relevantní probabilistické neuronové sítě, jako jsou například bayesovské LSTM (Hannula et al., 2025; Mesbah, 2016).

3.3 Model jedné místnosti

3.3.1 TiTe model jako základní grey-box přístup

Pro softwarovou implementaci tepelného modelu místnosti se jako vhodný kompromis jeví TiTe (Thermal inertia - Thermal environment) (Pathak et al., 2019). Tento model redukuje teplotní dynamiku na ekvivalentní RC síť (typicky 2R2C), která zachytí rozdíl mezi rychlou dynamikou vzduchu a pomalou dynamikou konstrukcí (Doddi et al., 2018).

Model lze interpretovat jako dvě kapacity (vzduch C_i a obálka C_e) a dva odpory (R_{ie}, R_{ea}), což umožňuje popsat klíčové zpoždění a setrvačnost důležité pro MPC.

3.3.2 Stavový prostorový popis a diskrétní formulace

Pro implementaci v MPC se spojitá dynamika převádí do diskrétního stavového prostoru (Goyal & Barooah, 2010). V každém kroku (např. 15 min) se aktualizuje stav a vytvoří predikce pro horizont MPC.

3.3.3 Identifikace parametrů a Bayesovský přístup

Pathak et al. (2019) ukazují Bayesovský přístup pro identifikaci parametrů RC modelu, který poskytuje nejen bodové odhady parametrů, ale i informaci o nejistotě (Pathak et al., 2019). Pro průběžnou adaptaci lze využít i online identifikaci (např. RLS) (Eini & Abdelwahed, 2019).

3.3.4 Volba komplexity a integrace s MPC

Pro jednozónové úlohy je 2R2C často praktické optimum: zachytí setrvačnost obálky, ale zůstává identifikovatelné a výpočetně nenáročné pro MPC (Bagheri et al., 2018; Pathak et al., 2019). U složitějších budov je pak vhodné přejít na vícestranné RC sítě nebo distribuované MPC (Christofides et al., 2013).

3.4 Neuronové sítě pro modelování tepelné dynamiky

Neuronové sítě se v kontextu tepelné dynamiky budov používají ve třech základních rolích: jako **prediktor dynamiky** (sekvenční model teploty nebo spotřeby), jako **prediktor poruch** (obsazenost, interní a solární zisky) a pro **hybridní korekci** fyzikálního (grey-box) modelu. Tato typologie je praktická zejména pro návrh MPC, protože jasně odlišuje, co je "model planty" a co jsou exogenní vstupy (Drgoňa et al., 2020; Eini & Abdelwahed, 2019).

3.4.1 Datové požadavky a konstrukce vstupů

Pro modely neuronových sítí (NN) je kritické, aby vstupy nesly komplexní informaci o celém systému. V první řadě musí zahrnovat **aktuální stav**, tedy poslední hodnoty teplot, případně odhad skrytého stavu. Dále je nezbytné zakomponovat proměnné **řízení**, jako je výkon topení, setpoint nebo povely ventilů a aktuální data o **počasí**, ke kterým podle dostupnosti patří venkovní teplota, globální radiace či rychlost větru. V neposlední řadě hraje důležitou roli **kalendářní struktura** (hodina dne, den v týdnu a svátky), jež funguje jako proxy proměnná pro obsazenost budovy. Bez těchto klíčových vstupů si neuronové sítě často "vymýšlí" neexistující dynamiku a režimy, které ve skutečnosti vznikají pouze v důsledku modelu nepředaných poruch (Drgoňa et al., 2020).

3.4.2 NARX a obecné autoregresní sítě

Pro časové řady je typické autoregresní modelování, kde predikce závisí na historii vstupů a výstupů. NARX síť má tvar:

$$y(t) = f(x(t-1), \ldots, x(t-d_x), y(t-1), \ldots, y(t-d_y)), \tag{5}$$

a je vhodná např. pro predikci obsazenosti nebo vnitřních zisků, které mají silnou časovou strukturu (Eini & Abdelwahed, 2019).

3.4.3 LSTM a GRU pro dlouhodobé závislosti

LSTM sítě jsou standardní volbou pro modelování dynamiky s dlouhou pamětí (tepelná setrvačnost) (Hannula et al., 2025). V praxi se často používá **encoder–decoder** (seq2seq) architektura, kdy encoder zpracuje minulost a decoder generuje predikci na horizont MPC, to je vhodné i pro online adaptaci (Sha et al., 2025).

3.4.4 Bayesovské NN a kvantifikace nejistoty

Pro řízení je důležité nejen "co model predikuje", ale i **jak moc si je jistý**. Hannula et al. (2025) ukazují bayesovský LSTM, který poskytuje prediktivní distribuci a

intervaly spolehlivosti (Hannula et al., 2025). Tato nejistota je přímo použitelná ve stochastickém MPC (např. *chance constraints*) (Mesbah, 2016).

3.4.5 Physics-informed a modulární NN

Čisté black-box modely mohou selhávat při změně režimu (retrofit, jiné užívání). Proto se prosazují hybridní a physics-informed přístupy. Jiang et al. (2024) navrhují modularizovanou NN, kde jednotlivé moduly odpovídají členům tepelné bilance (HVAC, infiltrace, interní zisky) a lze je znovupoužívat či přeladit po změně budovy (Jiang & Dong, 2024). Tento přístup zvyšuje interpretovatelnost a robustnost.

3.4.6 Konvexní architektury pro NN-MPC

Pokud je NN vložená přímo do MPC, vzniká typicky nekonvexní optimalizace. To komplikuje spolehlivé řešení v reálném čase. Směr konvexních sítí (ICNN/ICRNN) tento problém řeší tím, že vynutí konvexitu vůči vstupům a MPC pak lze řešit robustněji (Amos & Kolter, 2017; Paré et al., 2024).

3.4.7 Transfer learning a provozní adaptace

Nasazení v nové budově typicky trpí nedostatkem dat. Transfer learning umožňuje přenést předtrénovaný model a jen ho doladit. Tanahashi et al. (2024) ukazují přenos LSTM mezi scénáři s rozdílnou obsazeností (Tanahashi et al., 2024). Pro dlouhodobý provoz je pak relevantní online-learning, který udržuje přesnost při driftu (Sha et al., 2025).

3.5 Datová a integrační vrstva: od BMS k modelu

Modelování a řízení v reálné budově není jen volba rovnic nebo architektury sítě. Kritickou část tvoří **datová pipeline**: jak se z měření v BMS dostanou konzistentní časové řady vhodné pro identifikaci, trénink a online inferenci.

3.5.1 Kde vznikají data

Typická architektura automatizace budov je hierarchická: (i) **field vrstva** (senzory/aktuátory), (ii) **automatizační vrstva** (DDC/PLC regulátory, lokální PID), (iii) **supervizní vrstva** (BMS server, trendy, alarmy, vizualizace) a (iv) **enterprise/cloud vrstva** (analytika, optimalizace, reporting). Tato struktura je konzistentní s praxí BACS/BMS a je důležitá pro to, kam "posadit" MPC (Brooks et al., 2018; International Organization for Standardization, 2024a).

3.5.2 Protokoly a bodový model

BMS typicky komunikuje přes standardní protokoly (nejčastěji BACnet), které definují objektový model bodů, jejich vlastností a služby pro čtení/zápis (ASHRAE, 2020). Pro MPC je to důležité zejména proto, že tento model určuje, jaké veličiny jsou v systému vůbec dostupné (zda jde o přímá měření nebo odhady), jak se konkrétně provádí **zápis** povelů (včetně řízení setpointů, override funkcí a priorit) a jaké jsou fyzické i komunikační limity vzorkování a latence.

3.5.3 Interoperabilita a sémantika dat

Největší praktická bariéra při škálování na více budov nespočívá v samotném algoritmu, ale v heterogenním názvosloví a chybějících metadatech (tedy v nejistotě, co přesně znamená daný datový bod, jaké má jednotky, kontext zóny či vazby). Z tohoto důvodu se v praxi využívají standardizované sémantické vrstvy. Jednou z nich je Project Haystack, což je tagovací systém pro označení bodů a jejich kontextu (např. “zone”, “temp”, “sensor”) (Project Haystack, 2021b). Komplexnějším přístupem je pak Brick Schema, představující ontologii a metadatové schéma pro budovy, které umožňuje formálně popsat zařízení, zóny, datové body a jejich vzájemné vztahy (Balaji et al., 2018). Celá tato problematika metadat a ontologií v systémech budov je navíc systematicky shrnuta v přehledu iniciativy Annex 81 (Fierro & Pauwels, 2022a).

3.5.4 Důsledky pro trénink a validaci

Bez sémantiky a konzistentních jednotek vznikají typické chyby v podobě záměny teplot (supply vs. return), chybného škálování (°C vs. K), posunů časových zón a neznámých priorit override v systémech BMS. Tyto nedostatky přímo degradují jak identifikaci RC modelu, tak samotný trénink neuronových sítí. Pro zamezení těmto problémům je proto žádoucí standardizovat jednotky a timestampy, vytvořit explicitní mapování pointů na jejich fyzikální význam a současně logovat také povely, override a režimy BMS pro zachování potřebné kauzality v datech. Uvedené kroky tvoří nezbytný praktický předpoklad k tomu, aby nasazení MPC či NN-MPC přinášelo v reálném provozu replikovatelné výsledky (Drgoňa et al., 2020).

3.6 Neuronové sítě jako prediktory tepelné dynamiky

3.6.1 Reprezentace vstupů a tvorba regresorů pro časové řady

V praktických aplikacích je výkon neuronového prediktoru typicky limitován méně volbou „exotické“ architektury a více tím, *jak jsou sestaveny vstupy* a jak dobře od-

rážejí fyziku a provoz budovy. Pro jednojzónové (místnostní) modely se nejčastěji používá kombinace stavových veličin (minimálně T_{in}. Případně teplota obálky nebo teplota přívodu, pokud je dostupná), akčních veličin popisujících stav či konfiguraci topení (výkon, otevření ventilu, setpoint, režim), exogenních poruch (venkovní teplota, sluneční zisky a radiace, obsazenost a interní zisky) a kalendářního kontextu (den v týdnu, čas v dni, svátky), který slouží jako proxy pro provozní režimy. V MPC scénáři je navíc výhodné rozlišovat mezi měřenými vstupy (např. minulý výkon topení) a predikovanými vstupy (např. předpověď T_{out}), protože chyby předpovědí se v horizontu kumulují a ovlivňují robustnost řízení (Drgoňa et al., 2020).

Prakticky se vstupní vektor často sestavuje jako okno zpožděných hodnot (lag window). Například pro predikci $T_{\text{in}}(k+1)$ se použijí hodnoty $\{T_{\text{in}}(k), \ldots, T_{\text{in}}(k-L)\}$ a analogicky zpožděné hodnoty poruch a vstupů. Tento princip je kompatibilní s NARX formulací (explicitní autoregrese se zpožděním) i s rekurentními sítěmi (Eini & Abdelwahed, 2019).

3.6.2 Jednokroková vs. vícekroková predikce

Pro MPC se typicky požaduje vícekroková predikce na horizontu, pro kterou se v literatuře i praxi používají tři základní strategie. První z nich je recursive (iterativní) predikce, kdy je model trénován na jeden krok dopředu a v rámci MPC se opakovaně „rozbaluje“ (rollout), což má však za následek postupnou akumulaci chyby v predikčním horizontu. Alternativou je direct (multi-output) predikce, při níž model přímo generuje celý vektor predikce $\hat{T}_{\text{in}}(k+1{:}k+N)$. Výhodou tohoto přístupu je menší drift, avšak za cenu vyšších nároků na data a celkovou kapacitu modelu. Třetí možností je architektura seq2seq (encoder–decoder), kde encoder zpracuje historii stavů a decoder následně vygeneruje trajektorii na požadovaném horizontu. Tento postup je častý u sítí typu LSTM či GRU a velmi dobře se kombinuje s online adaptací v reálném provozu (Sha et al., 2025). V kontextu samotného řízení je kritické, že chyba predikce v pozdějších krocích horizontu může vést k agresivním, nebo naopak příliš konzervativním zásahům akčních členů. Z tohoto důvodu se v moderních přístupech stále častěji pracuje s kvantifikací nejistoty ve formě intervalů či rozdělení pravděpodobnosti predikce, případně se rovnou nasazují robustní varianty MPC (Hannula et al., 2025; Mesbah, 2016).

3.6.3 Architektury pro sekvenční modelování

Kromě klasických MLP/ANN a NARX jsou pro časové řady dominantní sekvenční architektury. Mezi ně patří především rekurentní sítě (LSTM/GRU), které přirozeně modelují zpoždění a tepelnou setrvačnost. V budovách se opakovaně používají jako

prediktory teploty a spotřeby a velmi dobře fungují v kombinaci s MPC (Hannula et al., 2025; Kumar et al., 2021).

Další variantou jsou Temporal Convolutional Networks (TCN) představující konvoluční přístup k sekvencím, jenž bývá výpočetně stabilní a snadno paralelizovatelný, díky čemuž v sekvenčních úlohách často přímo konkuruje RNN (Bai et al., 2018). Moderní alternativou jsou pak transformery, tedy pozornostní (attention) modely, které se prosadily zejména u dlouhých závislostí a multi-variačních sekvencí. Tyto modely mohou být vysoce relevantní pro multi-zónové budovy nebo pro komplexní kombinaci více datových zdrojů, jako jsou data z BMS, předpovědi počasí a ceny energií (Vaswani et al., 2017).

Samotná volba architektury v kontextu řízení budov obvykle není pouze otázkou maximální přesnosti na benchmarku, ale spíše hledáním kompromisu mezi latencí predikce, stabilitou v extrapolaci, nároky na data a celkovou řešitelností optimalizace v rámci MPC. Z tohoto úhlu pohledu mají značnou výhodu také konvexní nebo strukturálně omezené architektury neuronových sítí, protože zásadním způsobem zlepšují tractabilitu optimalizační úlohy (Amos & Kolter, 2017; Paré et al., 2024).

3.6.4 Tréninkové cíle, regularizace a validace v režimu časových řad

Pro data z provozu budov je typické, že vykazují silnou sezónnost, drift způsobený změnami v užívání a často obsahují chybějící úseky. Kromě standardní normalizace a čištění dat je proto naprosto klíčové správné časové dělení na trénovací, validační a testovací množiny. Toto rozdělení musí probíhat striktně sekvenčně bez nežádoucího míchání času, aby nedošlo k takzvanému data leakage, tedy úniku informací z budoucnosti do trénovací fáze.

Vzhledem k často omezené diverzitě provozních stavů budovy je nezbytnou součástí tréninku také vhodná regularizace, zahrnující techniky jako dropout, weight decay nebo early stopping. Stejný důraz musí být kladen na následnou validaci modelu na extrémních situacích, mezi které patří například mrazové dny či rychlé změny obsazenosti. Právě v těchto okrajových podmínkách totiž standardní modely nejčastěji selhávají.

Z tohoto hlediska představují značnou výhodu pravděpodobnostní modely. Jejich hlavním benefitem je schopnost vracet společně s predikcí také kvantifikaci její nejistoty, kterou lze v rámci prediktivního řízení přímo promítnout do konzervativnějších a bezpečnějších akčních zásahů (Hannula et al., 2025; Mesbah, 2016).

3.6.5 Životní cyklus prediktoru: drift, rekalibrace a online adaptace

Model tepelné dynamiky budovy nelze vnímat jako statický systém, který je po úvodním natrénování trvale neměnný. V reálném provozu totiž neustále dochází k

proměnám klíčových okrajových podmínek. Mění se zejména režimy větrání a infiltrace, míra obsazenosti prostor a s tím související interní tepelné zisky, ale také samotná nastavení systému BMS a lokálních regulátorů. V delším časovém horizontu mohou do hry vstoupit i změny fyzikálních vlastností obálky budovy, například v důsledku jejích částečných renovací nebo degradace materiálů.

Z těchto důvodů je pro praktické nasazení naprosto nezbytná průběžná detekce driftu v datech a předem definovaný plán rekalibrace. Jednou z nejefektivnějších cest, jak dlouhodobě udržet vysokou kvalitu predikce bez nutnosti kompletního a výpočetně náročného re-tréninku od nuly, je nasazení přístupů založených na online učení. Tato metoda umožňuje průběžnou adaptaci modelu na nově příchozí data a postupné zapomínání neaktuálních vzorců chování (Sha et al., 2025).

Celý tento proces životního cyklu prediktoru navíc úzce souvisí se samotnou datovou vrstvou BMS. Je to právě dlouhodobá kvalita, konzistence a správná sémantika měřených dat, co v konečném důsledku určuje, zda je praktická údržba, rekalibrace a průběžná adaptace takového modelu v reálném provozu vůbec realistická a ekonomicky udržitelná (Drgoňa et al., 2020).

3.7 Datová integrace, BMS a sémantika měření

3.7.1 BMS jako primární zdroj provozních dat

Většina provozních dat pro modelování budovy pochází z Building Management System (BMS) / Building Automation and Control System (BACS). Z pohledu životního cyklu projektu (specifikace, implementace, předání) je relevantní standardizační rámec BACS, který popisuje procesy a artefakty pro návrh a realizaci automatizace budov (International Organization for Standardization, 2024b). Pro data-driven modelování to znamená, že kvalita výsledného datasetu není jen otázkou senzorů, ale i toho, jak je BMS projektově navržen (co se měří, kde, jak často a s jakou identifikací).

3.7.2 Interoperabilita: komunikační standardy vs. význam dat

Komunikační standardy (typicky BACnet) řeší **přenos a přístup k bodům**, ale samy o sobě negarantují, že software „pochopí“, co konkrétní bod znamená v kontextu budovy. BACnet je standardizován jak v prostředí ASHRAE (ANSI/ASHRAE 135), tak v ISO řadě pro automatizaci budov, přičemž cílem je interoperabilní komunikace v systémech automatizace a řízení budov (ASHRAE, 2024; International Organization for Standardization, 2022). Pro ML/MPC je však klíčové i to, aby

měření měla konzistentní význam napříč zónami a budovami (např. rozdíl mezi *zone temperature*, *return air temperature* a *supply air temperature*).

3.7.3 Sémantická vrstva: Project Haystack a Brick

Z praktického hlediska je největší bariérou škálování analytiky a pokročilého řízení často **neexistence sémantiky** (metadata) nad body BMS. Projekt Haystack formalizuje metodiku „taggingu“: místo snahy vložit význam do názvu bodu se používá sada standardizovaných tagů, které popisují význam a vztahy entit a bodů (Project Haystack, 2021a). Tím se snižuje manuální práce při mapování dat do analytiky, protože aplikace mohou vyhledávat body podle tagů a vztahů, ne podle ad-hoc názvů.

Alternativní (a často kombinovaný) přístup je Brick – ontologie/metadatové schéma pro přenositelné aplikace v chytrých budovách. Brick explicitně modeluje zařízení, body a jejich vztahy, což je výhodné pro složitější dotazy a pro automatizaci integrace (Balaji et al., 2018). Přehledové materiály pro data-driven chytré budovy zdůrazňují, že právě sémantické vrstvy (Haystack, Brick aj.) jsou klíčem k interoperabilitě analytiky, fault detection i pokročilého řízení napříč budovami (Fierro & Pauwels, 2022b).

3.7.4 Důsledky pro modelování a řízení

Pro tuto práci z toho plynou dva praktické závěry:

1. Pokud má být prediktor (NN nebo grey-box) dlouhodobě udržitelný, musí mít data stabilní identitu a význam – tj. BMS body musí být konzistentně pojmenované nebo (lépe) semanticky anotované (Fierro & Pauwels, 2022b; Project Haystack, 2021a).

2. Architektura řešení (model + MPC) musí počítat s tím, že BMS je heterogenní prostředí: některé veličiny budou chybět, některé budou šumové a některé budou „nepřímo“ odvozené (např. interní zisky) – což motivuje hybridní modely a robustní/stochastické varianty MPC (Drgoňa et al., 2020; Mesbah, 2016).

4 Řídicí metody pro vytápění

4.1 Klasické metody řízení vytápění

Klasické metody řízení vytápění zahrnují jednoduché regulátory, které jsou díky své jednoduchosti a robustnosti stále v praxi nejrozšířenější. Ačkoliv pokročilé metody jako MPC nebo reinforcement learning prokázaly teoretický potenciál pro významné úspory energie, naprostá většina současných systémů stále využívá On/Off řízení, hysterezní termostaty nebo PID regulátory (Drgoňa et al., 2020).

4.1.1 On/Off a hysterezní řízení

Nejjednodušší forma řízení je binární spínač (On/Off), který topení zapíná při poklesu teploty pod nastavenou hodnotu a vypíná při jejím překročení. Hysterezní regulátor přidává pásmo necitlivosti (hysterezi) pro eliminaci rychlého cyklování (short cycling) (Åström & Murray, 2008). Například při nastavení 21°C s hysterezí ±0,5°C se topení vypne při 21,5°C a zapne až při 20,5°C (deadband řádu desetin °C je běžně používán i v experimentálních baseline nastaveních termostatů) (Ramaraj et al., 2025).

Výhodou těchto metod je extrémní jednoduchost a spolehlivost. Nevýhodou je absence schopnosti anticipovat změny. Regulátor pouze reaguje na aktuální stav. To vede k oscilacím teploty a neefektivnímu využití tepelné setrvačnosti budovy (Killian & Kozek, 2016).

4.1.2 PID regulátory

Proporcionálně-integrálně-derivační (PID) regulátory představují výrazně sofistikovanější přístup. Řídící akce je tvořena třemi složkami: proporcionální člen reaguje na velikost aktuální chyby, integrální člen odstraňuje ustálené odchylky akumulací minulých chyb a derivační člen předvídá budoucí vývoj na základě rychlosti změny chyby.

Pro PI regulátor platí:

$$u(t) = K_p e(t) + K_i \int_0^t e(\tau)\, d\tau \tag{6}$$

kde $e(t) = T_{\text{setpoint}}(t) - T(t)$ je odchylka teploty, K_p proporcionální zesílení a K_i integrální zesílení (Åström & Hägglund, 1995).

4.1.3 Ladění PID parametrů

Klíčovým problémem PID regulace je správné nastavení parametrů K_p, K_i a K_d. Mezi klasické metody ladění patří Ziegler-Nichols metoda z roku 1942, která využívá buď měření kritické frekvence (*closed-loop oscillation*), nebo analýzu odezvy na skok (*process reaction curve*). Ačkoliv je tento postup relativně jednoduchý, v praxi často vede k nadměrnému překmitu (Ziegler & Nichols, 1942). Dalším tradičním přístupem je Cohen-Coon metoda, jež je primárně zaměřena na potlačení poruch a ukazuje se jako vhodná zejména pro procesy s výrazným dopravním zpožděním (Cohen & Coon, 1953).

Tyto heuristické metody však často poskytují suboptimální výsledky, a to zejména v případě komplexních nelineárních systémů, jakými jsou právě budovy. Z tohoto důvodu jsou v současnosti intenzivně zkoumány pokročilé metaheuristické přístupy, jako jsou genetické algoritmy nebo *particle swarm optimization*. Tyto techniky se využívají pro automatické ladění parametrů tak, aby systematicky minimalizovaly zvolenou účelovou funkci, jakou je například *ITAE* (*Integral Time Absolute Error*) nebo *ISE* (*Integral Square Error*) (Joseph et al., 2022).

4.1.4 Data-driven adaptivní ladění

Xu et al. (2024) demonstrují přechodový most mezi klasickým PI a moderním data-driven přístupem. V simulaci jedné místnosti použili Bayesovskou optimalizaci k online ladění parametrů Kp, Ki, denní žádané teploty (Tset) a času předtápění (Xu et al., 2024).

Optimalizační proces lze zapsat jako hledání argumentu:

$$\theta^* = \arg\min_{\theta \in \Theta} \mathbb{E}[J(\theta)] \tag{7}$$

kde vektor parametrů $\theta = [K_p, K_i, T_{\text{set}}, t_{\text{pre}}]$ je laděn tak, aby minimalizoval očekávanou hodnotu ztrátové funkce J (zahrnující spotřebu a komfort) na základě pravděpodobnostního modelu (Gaussovských procesů) (Shahriari et al., 2016).

4.1.5 Klíčové poznatky k využití PDCBO

Z hlediska klíčových poznatků se u algoritmu PDCBO ukazuje především jeho vysoká adaptivita na aktuální počasí. V chladných dnech (při teplotách $\leq 10°$C) tento přístup automaticky volí malé K_p a velké K_i, což zajišťuje rychlé zahřátí systému proti ochlazování okolím, a současně iniciuje dřívější předtápění. Naopak v teplejších dnech preferuje opačné nastavení, tedy velké K_p a malé K_i, čímž efektivně předchází nežádoucímu překmitu teploty. Díky této dynamické úpravě parametrů dosahuje sys-

tém úspor až 4,7 % energie ve srovnání s tradičním statickým nastavením, přičemž spolehlivě udržuje tepelný diskomfort pod stanovenou prahovou hodnotou. Dalším významným přínosem je flexibilní sledování proměnných omezení. Pokud dojde ke změně preferencí obyvatel a jejich toleranci k diskomfortu, algoritmus se těmto novým podmínkám dokáže automaticky přizpůsobit během několika málo dní. Celkově tak tento přístup jasně demonstruje, že i koncepčně jednoduchý PI regulátor může fungovat vysoce inteligentně a efektivně, pokud se jeho parametry průběžně a adaptivně ladí pomocí metod strojového učení (Xu et al., 2024).

4.1.6 Limity klasických metod

I s pokročilým laděním zůstává zásadním omezením PI/PID řízení absence predikce. Regulátor neví, že za dvě hodiny začne svítit slunce nebo že obyvatelé odejdou z domu. Proto nemůže využít tepelnou setrvačnost budovy k předtopení nebo úspoře energie v reakci na předpověď ceny elektřiny či počasí (Drgoňa et al., 2020).

4.2 Základní princip modelově prediktivního řízení (MPC)

Model Predictive Control (MPC) představuje paradigmatickou změnu oproti reaktivním klasickým regulátorům. Místo reakce na aktuální chybu MPC optimalizuje sekvenci budoucích akcí na základě predikce vývoje systému (Rawlings et al., 2018).

4.2.1 Princip fungování MPC

V každém časovém kroku MPC provede následující kroky (Rawlings et al., 2018):

1. **Získání aktuálního stavu systému:** Na základě měření (např. vnitřní teplota) a případně odhadu stavu (pozorovatel/filtr) se určí aktuální stav x_k.

2. **Predikce poruch a vstupů:** Do výpočtu se zahrnou predikce exogenních veličin d_k (např. venkovní teplota, solární zisky, obsazenost) a případně dynamické ceny energie či signály *demand response*.

3. **Formulace optimalizační úlohy na horizontu:** Pro zvolený predikční horizont N se sestaví účelová funkce, která typicky penalizuje odchylku výstupu (komfort) a velikost/změny akční veličiny (energie, opotřebení) se váhami Q a R. Současně se definují omezení na stavy a vstupy (např. komfortní pásmo, limity výkonu, rychlost změny).

4. **Řešení optimalizační úlohy:** Vyřeší se optimalizační problém (typicky kvadratické programování pro lineární MPC, případně nelineární programování pro nelineární MPC) a získá se optimální sekvence vstupů $u^\star_{k|k}, u^\star_{k+1|k}, \ldots, u^\star_{k+N-1|k}$.

5. **Aplikace prvního vstupu (receding horizon):** Do systému se aplikuje pouze první krok $u_k = u^\star_{k|k}$, zbytek sekvence se nepoužije přímo, ale slouží pro plánování.

6. **Posun horizontu a opakování:** Po uplynutí vzorkovací periody se získají nová měření, horizont se posune o jeden krok a celý proces se opakuje, čímž MPC průběžně reaguje na odchylky modelu i na změny poruch.

4.2.2 Klíčové výhody MPC

Mezi hlavní výhody přístupu modelového prediktivního řízení (MPC) patří podle dostupné literatury (Drgoňa et al., 2020) především schopnost anticipace. Ta umožňuje do procesu optimalizace explicitně zahrnout předpověď počasí, budoucí obsazenost prostor nebo dynamické ceny energie (Oldewurtel et al., 2013). Dalším zásadním přínosem je skutečnost, že toto řízení explicitně respektuje veškeré fyzikální a provozní limity dané soustavy. V neposlední řadě MPC vyniká v řešení multi-objektivních úloh, protože dokáže transparentně vyvažovat protichůdné cíle, jakými jsou typicky požadovaný tepelný komfort uživatelů a celková spotřeba energie. Tohoto kompromisu je algoritmicky dosahováno prostřednictvím vhodného nastavení vah Q a R v samotné účelové funkci (Rawlings et al., 2018).

4.2.3 Varianty MPC

V závislosti na konkrétních cílech a komplexnosti budovy se v praxi využívají různé varianty prediktivního řízení (Drgoňa et al., 2020). Základní dělení vychází z linearity použitého modelu. Lineární MPC (LMPC) využívá lineární model, což typicky vede na konvexní optimalizační úlohy, jako je kvadratické programování. Tento přístup je výpočetně velmi efektivní a hodí se zejména tam, kde lze systém dobře aproximovat v jeho pracovním bodě. Naproti tomu nelineární MPC (NMPC) pracuje s nelineárním modelem, což sice umožňuje přesnější popis chování, například nelinearit HVAC zařízení, avšak za cenu nutnosti řešit složitější nelineární optimalizační úlohu a s tím spojených výrazně vyšších výpočetních nároků (Rawlings et al., 2018).

Z hlediska definice cílů a práce s nejistotami se uplatňují další specializované přístupy. Economic MPC (EMPC) neminimalizuje odchylku od referenční trajektorie, ale přímo optimalizuje zvolenou ekonomickou veličinu, jako je cena energie nebo celkové provozní náklady. Často se proto nasazuje v podmínkách dynamických tarifů a v programech *demand response* (Ellis et al., 2014; Paré et al., 2024). Při výskytu výrazných nejistot v modelu či vnějších poruchách se využívá robustní MPC. To explicitně zohledňuje tyto odchylky, typicky intervalově nebo pomocí scénářů, a snaží se zaručit splnění všech omezení i za nepříznivých podmínek, což však obvykle

vede ke konzervativnějšímu řízení (Bemporad & Morari, 1999). Jeho alternativou je stochastické MPC, které modeluje nejistoty pravděpodobnostně. Optimalizuje tak očekávaný výkon při zachování omezení s předem definovanou pravděpodobností (chance constraints), díky čemuž může dosahovat méně konzervativních výsledků než čistě robustní přístup.

Specifické varianty pak řeší samotnou výpočetní náročnost online optimalizace. Explicitní MPC přesouvá řešení optimalizační úlohy do offline fáze, jejímž výsledkem je explicitní zákon řízení, typicky po částech afinní. To umožňuje extrémně rychlou online implementaci, avšak tento přístup je silně limitován takzvanou kletbou dimenzionality, kdy složitost roste s dimenzí stavu a počtem omezení (Rawlings et al., 2018). Pro rozsáhlé systémy je naopak vhodné distribuované MPC (DMPC), které celý problém dekomponuje na více dílčích podsystémů, například na jednotlivé zóny budovy. Tyto podsystémy se následně řeší koordinovaně, čímž se efektivně snižuje celková výpočetní náročnost a otevírá se cesta ke škálování algoritmu na velké a komplexní budovy (Christofides et al., 2013).

4.2.4 Výpočetní aspekty

Každý krok řízení vyžaduje řešení optimalizačního problému, přičemž náročnost závisí na typu modelu a účelové funkce (Rawlings et al., 2018). (Paré et al., 2024) řeší tento problém pomocí *Input Convex RNN (ICRNN)*. Konvexní NN architektury obecně (ICNN) formalizují konvexitu optimalizačního problému i při použití hlubokých neuronových sítí (Amos & Kolter, 2017). Díky tomu bylo dosaženo řešení v čase < 5 minut pro komplexní komerční budovy, což je dostatečné pro standardní vzorkovací periody v HVAC systémech (Paré et al., 2024).

4.2.5 Formální optimalizační úloha MPC pro vytápění

Pro budovy lze MPC formulovat jako optimalizaci na diskrétním horizontu N nad prediktorem tepelné dynamiky. Ve standardním (tracking) tvaru se uvažuje model

$$x_{k+1} = f(x_k, u_k, d_k), \qquad y_k = g(x_k), \tag{8}$$

kde x_k je stav (např. teplotní stav RC modelu nebo stav NN prediktoru), u_k je řídicí zásah (např. výkon topení / setpoint) a d_k jsou poruchy (počasí, obsazenost, solární zisky). MPC v čase k typicky řeší úlohu

$$
\begin{aligned}
\min_{\{u_{k+i}\}_{i=0}^{N-1}} \quad & \sum_{i=0}^{N-1} \left(\|y_{k+i|k} - r_{k+i}\|_Q^2 + \|u_{k+i|k}\|_R^2 + \|\Delta u_{k+i|k}\|_S^2 \right) \\
\text{s.t.} \quad & x_{k+i+1|k} = f(x_{k+i|k}, u_{k+i|k}, d_{k+i|k}), \\
& y_{k+i|k} \in \mathcal{Y} \quad \text{(komfortní omezení)}, \\
& u_{k+i|k} \in \mathcal{U} \quad \text{(limity aktuátorů)}, \\
& \Delta u_{k+i|k} \in \Delta\mathcal{U} \quad \text{(omezení rychlosti změny)}, \\
& x_{k|k} = \hat{x}_k.
\end{aligned} \tag{9}
$$

Tento tvar explicitně ukazuje tři typické penalizace: odchylku od reference (komfort), energii / velikost zásahu a změny zásahu (omezení cyklování, opotřebení). Jde o standardní konstrukci MPC, v níž se praktický charakter řízení nastavuje volbou vah Q, R, S a volbou množin omezení $\mathcal{Y}, \mathcal{U}$ (Drgoňa et al., 2020; Rawlings et al., 2018).

4.2.6 Měkká omezení a robustní komfort

V praxi se komfortní omezení často implementuje jako **měkké** (soft) omezení se slack proměnnou $\epsilon \geq 0$, aby optimalizace zůstala proveditelná i při neočekávaných poruchách (např. rychlý pokles venkovní teploty nebo výpadek výkonu). Typicky:

$$
T_{\min} - \epsilon_{k+i} \leq T_{k+i|k} \leq T_{\max} + \epsilon_{k+i}, \qquad \epsilon_{k+i} \geq 0, \tag{10}
$$

a do cíle se přidá penalizace $\rho\|\epsilon\|_1$ nebo $\rho\|\epsilon\|_2^2$. Tím se explicitně řídí kompromis „raději krátce porušit komfort, než zkolabovat optimalizaci“ (Rawlings et al., 2018).

4.2.7 Komfortní kritéria: teplotní pásmo vs. PMV/PPD

Nejjednodušší komfortní metrika je řízení teploty do pásma (deadband). Pro přesnější popis komfortu se používají indexy jako PMV/PPD, které jsou standardizované v ergonomických a HVAC normách. ASHRAE Standard 55 definuje podmínky tepelné pohody (včetně metodiky PMV/PPD a adaptivního komfortu) (ASHRAE, 2023). ISO 7730 standardizuje analytické určení a interpretaci tepelné pohody pomocí PMV/PPD a lokálních kritérií (International Organization for Standardization, 2025). V praxi se u MPC často volí pragmatická varianta: teplotní pásmo jako hlavní constraint a případně doplňkové metriky pro vyhodnocení (comfort KPI), protože

PMV/PPD vyžaduje další vstupy (metabolismus, oděv, rychlost proudění vzduchu) a zvyšuje složitost online řízení (Drgoňa et al., 2020).

4.2.8 Odhad stavu a poruch: proč je důležitý pozorovatel

MPC potřebuje stav x_k. V budovách ale typicky měříme jen část stavů (např. pouze T_{in}). Proto se používají pozorovatele (Kalmanův filtr pro lineární modely, rozšířený KF pro nelineární modely) nebo metody typu *moving horizon estimation* (MHE). Odhad stavu je klíčový zejména u grey-box RC modelů, kde teplota „obálky“ nebo interní zisky nejsou přímo měřené, ale zásadně ovlivňují predikci (Drgoňa et al., 2020; Rawlings et al., 2018).

4.2.9 Robustní a stochastické MPC v HVAC

Model budovy je vždy zatížen nejistotou: neznámé interní zisky, nepřesná předpověď počasí, proměnná infiltrace. Robustní MPC pracuje s množinami nejistot a garantuje splnění omezení i při nepříznivých realizacích, často za cenu konzervativity (Bemporad & Morari, 1999). Stochastické MPC (SMPC) naopak modeluje nejistoty pravděpodobnostně a používá např. *chance constraints*, což může být méně konzervativní a přirozeně se kombinuje s pravděpodobnostními prediktory (např. bayesovský LSTM) (Hannula et al., 2025; Mesbah, 2016).

4.3 MPC ve vytápění a HVAC

4.3.1 Typické aplikace a úspory

Přístup *Model Predictive Control* (MPC) prokázal v oblasti řízení budov a systémů HVAC v mnoha nezávislých studiích významné provozní úspory. Například u chladicích vodních systémů lze nasazením tohoto algoritmu dosáhnout snížení spotřeby o 10 až 15 % v porovnání s konvenčními metodami řízení (Afram & Janabi-Sharifi, 2014). Ještě výraznějších výsledků, konkrétně až 35% úspory elektrické energie, bylo dosaženo při cílené optimalizaci *setpointu* vnitřní teploty (Kumar et al., 2021). Ekonomický potenciál se pak naplno projevuje při integraci do širších energetických trhů, kde účast v *demand response bidding* programech prokazatelně přináší až 22% snížení celkových provozních nákladů (Paré et al., 2024).

Klíčovým mechanismem, který dosažení těchto energetických i finančních úspor umožňuje, je především inherentní schopnost MPC algoritmů aktivně a s předstihem využívat přirozenou tepelnou setrvačnost samotné budovy (Oldewurtel et al., 2013).

4.3.2 Multi-zónové a distribuované MPC

Pro velké budovy s desítkami zón je centralizovaný MPC výpočetně nezvládnutelný. Proto se využívá distribuované MPC.

Typická motivace DMPC v budovách vychází z toho, že jednotlivé zóny mají vlastní lokální dynamiku a lokální akční zásahy (např. ventily, průtoky, lokální jednotky), ale zároveň jsou mezi zónami přítomny vazby (tepelné přestupy přes konstrukce, sdílené zdroje tepla/chladu, společné omezení výkonu). Distribuované přístupy proto často formulují lokální optimalizační úlohy pro každou zónu a zavádějí koordinační mechanismus (např. výměna hranových teplot, sdílených výkonových limitů nebo duálních proměnných), aby bylo dosaženo globálně konzistentního řešení (Christofides et al., 2013).

Praktickou bariérou multi-zónového řízení je vedle výpočtu také **identifikace a údržba modelu** včetně vazeb mezi zónami: zatímco jednoduchý model jedné místnosti lze kalibrovat z omezeného množství měření, u desítek zón rychle roste počet parametrů a roste citlivost na nekonzistentní data (např. chybějící senzory, změny konfigurace BMS, zásahy údržby).

4.3.3 Bariéry adopce v praxi

I přes vysoký teoretický potenciál je nasazení *MPC* v reálném provozu stále spíše výjimečné. Mezi hlavní překážky jeho širší adopce patří podle dostupné literatury především nutnost vytvoření a následné dlouhodobé údržby prediktivního modelu. V praxi je mimořádně náročné takový model nejen jednorázově identifikovat, ale také jej průběžně aktualizovat v závislosti na změnách v užívání budovy, probíhajících renovacích, fyzických zásazích do systémů HVAC nebo úpravách v nastavení BMS. Bez pravidelné rekalibrace totiž dochází k nevyhnutelné degradaci modelu, což ve výsledku vede k narušení tepelného komfortu nebo k podstatně nižším úsporám.

Další významnou bariéru představuje samotná integrace do existujících systémů měření a regulace (BMS) a do zavedených provozních procesů. Nasazení MPC obvykle vyžaduje komplexní napojení na tyto systémy, ošetření bezpečnostních režimů (*fail-safe*), nastavení provozních priorit a respektování pravidel údržby. Provozní týmy navíc z pochopitelných důvodů preferují jednoduché a plně transparentní regulátory, přičemž prediktivní řízení často vnímají jako netransparentní „black-box“, jehož provoz vyžaduje zcela odlišný přístup k monitoringu a diagnostice. Tuto situaci navíc v praxi komplikuje samotná kvalita a dostupnost provozních dat. Běžně chybí měření klíčových veličin, jako je spolehlivý odhad výkonu, průtoků či reálné obsazenosti. Dostupná data navíc bývají zatížena šumem, častými výpadky nebo

nekonzistencí napříč různými systémy, což zásadně ztěžuje jak úvodní identifikaci modelu, tak i následnou validaci reálných přínosů řízení.

V neposlední řadě omezuje praktické využití tohoto přístupu jeho výpočetní náročnost a požadavky na spolehlivost. V každém kroku řízení musí MPC online řešit složitou optimalizační úlohu, což může být u komplexnějších modelů nebo multi-zónových systémů silně limitující. Tento proces proto vyžaduje vysoce robustní implementaci se stabilním solverem, striktním dodržováním časových limitů a ošetřením případné neřešitelnosti (infeasibility) pro zajištění spolehlivosti HVAC v reálném čase. Právě z těchto důvodů se v posledních letech výrazně zvyšuje zájem o hybridní a datově řízené přístupy, jako je například *learning-based MPC*. Tyto moderní metody se primárně snaží snížit vysoké nároky na ruční modelování a údržbu, a přitom si plně zachovat klíčovou schopnost efektivně pracovat s fyzikálními i provozními omezeními (Drgoňa et al., 2020).

4.4 Data-driven MPC s neuronovými sítěmi

Tradiční MPC vyžaduje fyzikální model (grey-box RC síť nebo white-box EnergyPlus), jehož identifikace je náročná. Neuronové sítě nabízejí alternativu: naučit se model přímo z dat.

4.4.1 Architektonické přístupy k NN-MPC

V literatuře se v posledních letech objevuje několik architektonických směrů, jak kombinovat neuronové sítě s *Model Predictive Control*. Nejjednodušší přístup představují tzv. black-box modely, kde neuronová síť slouží čistě jako prediktor dynamiky nebo spotřeby a je přímo vložena do prediktivního řízení (např. LSTM pro predikci teploty a výkonu). Výhodou je relativně snadné nasazení při dostupnosti dat, nevýhodou pak horší interpretovatelnost a riziko slabší generalizace mimo tréninkový rozsah, což se může projevit zejména při změnách provozu nebo extrémních podmínkách (Kumar et al., 2021).

Druhou skupinu tvoří hybridní a physics-informed architektury, které se snaží zachovat fyzikální konzistenci a současně využít flexibilitu datově řízených modelů. Typicky jde o modulární přístup, kde je část modelu (např. RC síť) dána fyzikálně a neuronová síť doplňuje pouze nelineární nebo obtížně modelovatelné složky (neznámé zisky, nelinearity HVAC, vlivy obsazenosti), případně adaptivně koriguje parametry modelu. Tento směr může snížit nároky na množství dat a zlepšit přenositelnost mezi budovami, protože fyzikální struktura omezuje chování modelu (Jiang & Dong,

2024).

Z hlediska implementace do MPC jsou významné také konvexní neuronové architektury, jejichž cílem je zachovat řešitelnost optimalizační úlohy v reálném čase. Například konvexní (input-convex) sítě umožňují formulovat řídicí problém tak, aby zůstával konvexní a bylo možné použít spolehlivé a rychlé solvery i pro komplexnější budovy. Tím se snižuje jedno z hlavních praktických omezení NN-MPC, kterým je výpočetní náročnost a riziko nespolehlivého řešení při nelineárních modelech (Paré et al., 2024).

4.4.2 Kvantifikace nejistoty

Klasické neuronové sítě typicky poskytují bodový odhad bez informace o důvěře (tj. bez explicitní prediktivní distribuce a intervalů spolehlivosti), což komplikuje rozhodování v řízení při neznámých poruchách a změnách režimu. Bayesovský LSTM (Hannula et al., 2025) tento problém řeší aproximací Bayesovské inference nad parametry (vahami) sítě a poskytuje prediktivní rozdělení (např. ve formě 95% věrohodnostních/konfidenčních intervalů), nikoli pouze jedinou křivku predikce (Hannula et al., 2025). To je kritické pro robustní/stochastické varianty MPC: pokud je model nejistý, lze v optimalizaci vynutit konzervativnější akci (např. přes *chance constraints* nebo explicitní práci s nejistotami poruch) (Mesbah, 2016).

4.4.3 Praktické implementace a důsledky pro návrh

Praktické nasazení NN-MPC typicky vyžaduje sladit tři vrstvy: (i) model predikce (přesnost, generalizace, kvantifikace nejistoty), (ii) optimalizaci (konvexita, garantované omezení, robustnost) a (iii) integrační vrstvu (BMS, komunikace, diagnostika). V praxi je proto klíčové volit takovou složitost modelu, aby byla udržitelná z hlediska výpočetních nároků i provozní spolehlivosti (Drgoňa et al., 2020).

4.4.4 Implementační aspekty a hardware

Současný výzkum jasně potvrzuje, že pokročilé řídicí algoritmy lze spolehlivě provozovat i na běžně dostupných výpočetních platformách. Úspěšná reálná implementace prediktivního řízení využívajícího lehký data-driven model, složený ze čtyř malých ANN či MLP modelů pro predikci stavů, byla demonstrována přímo na průmyslovém objektu. Autoři této případové studie reportují prokazatelnou a velmi významnou redukci celkové spotřeby elektrické energie, a to až o 31,7 % (Kim & Park, 2023). Pro nasazení těchto výpočetních úloh přímo v terénu v režimu edge computingu lze s výhodou využít hardwarovou akceleraci pomocí obvodů *FPGA*. Tento přístup je mimořádně vhodný zejména pro sekvenční modely typu LSTM, u kterých cílí na

dosažení velmi nízké latence a vysoké energetické efektivity samotného výpočetního uzlu (Liang et al., 2023).

Z hlediska softwarové implementace a praktické škálovatelnosti představuje další klíčový nástroj transfer learning. Ten umožňuje model primárně natrénovaný na budově s relativně jednoduchou a konstantní obsazeností efektivně přenést na složitější scénář s proměnnou obsazeností. Tento postup prokazatelně vede ke zlepšení přesnosti krátkodobých predikcí, a především radikálně snižuje časové i finanční náklady na zdlouhavý sběr trénovacích dat v nově připojovaných objektech (Tanahashi et al., 2024).

4.4.5 Klíčové poznatky

Z provedené analýzy jasně vyplývají základní pilíře pro návrh moderního řídicího systému. Zásadní roli zde hraje především hybridní přístup, jenž organicky spojuje *physics-informed* neuronové sítě a *grey-box* modely. Tato synergie nejen prokazatelně zvyšuje celkovou robustnost a interpretovatelnost celého systému, ale zároveň umožňuje maximálně těžit z reálných provozních dat (IEA EBC Annex 81, 2023). Na tento přístup úzce navazuje nutnost využití specifických konvexních architektur. Cílené nasazení architektur, jako je například *ICRNN*, totiž úspěšně překonává dřívější výpočetní bariéry, čímž otevírá cestu k plnohodnotné *real-time* optimalizaci i v případě složitějších nelineárních modelů (Paré et al., 2024). V neposlední řadě se jako nepostradatelná ukazuje integrace bayesovských metod. Pravděpodobnostní odhad začleněný přímo do modelu poskytuje exaktní kvantifikaci nejistoty, jež je naprosto kritická pro bezpečné a spolehlivé rozhodování v celém procesu prediktivního řízení (Hannula et al., 2025; Mesbah, 2016).

Ve světle těchto poznatků lze konstatovat, že moderní NN-MPC již nepředstavuje kompromis či nutnost volby mezi striktními fyzikálními zákony a čistě datově řízenými přístupy. Jedná se naopak o vysoce efektivní symbiózu obou těchto světů, jejímž hlavním cílem je dosažení skutečně inteligentního a dlouhodobě udržitelného řízení budov.

5 Východiska a omezení pro návrh řešení

Sektor budov představuje jednu z klíčových oblastí pro snižování energetické spotřeby a emisí skleníkových plynů. V evropském kontextu se opakovaně uvádí, že budovy jsou spojovány přibližně se 40% spotřeby energie a zhruba 36% emisí skleníkových plynů, což je jedním z důvodů, proč se energetická účinnost budov promítá přímo do evropské regulace (EPBD) (European Commission, 2020a). Z hlediska koncové spotřeby v domácnostech je dominantní zejména dodávka tepla: vytápění prostoru a ohřev vody dlouhodobě tvoří většinu spotřeby energie domácností v EU (European Commission, 2023; Eurostat, 2025). To potvrzuje, že opatření cílená na vytápění (renovace, volba zdroje tepla i kvalita řízení) mají v praxi největší potenciál dopadu.

V teoretické části byly shrnuty základní technologie vytápění (plynové kotle, elektrické vytápění, biomasa, tepelná čerpadla, CZT) a jejich role v dekarbonizačních scénářích (Dodoo, 2019; Georges et al., 2012; Knobloch et al., 2017). Ze systémového hlediska se jako důležité ukazuje také využití nízkoteplotních soustav (např. podlahové vytápění), které díky nižším požadavkům na teplotu topné vody zvyšují účinnost tepelných čerpadel a současně zavádějí vyšší tepelnou setrvačnost do dynamiky řízené soustavy (Göbel et al., 2021).

Pro návrh pokročilého řízení je klíčová schopnost predikovat teplotní chování místnosti/budovy. V modelování tepelné dynamiky budov se běžně rozlišují tři přístupy: *white-box* (detailní fyzikální simulace), *grey-box* (zjednodušené fyzikální modely s identifikací z dat) a *black-box* (čistě datové modely) (Doddi et al., 2018; Frahm et al., 2022). Zatímco *white-box* přístupy jsou vhodné pro analýzu a návrh, pro účely řízení v reálném čase bývají často příliš náročné z hlediska parametrizace i výpočtu. Naopak *grey-box* modely typu RC (např. 2R2C) představují praktický kompromis: zachovávají fyzikální interpretaci odporů a kapacit, ale jsou dostatečně jednoduché pro implementaci v prediktivním řízení (Doddi et al., 2018; Pathak et al., 2019). V této práci byl jako vhodný základ uveden model TiTe, u kterého lze parametry odhadovat i bayesovským přístupem a využít informaci o nejistotě parametrů (Pathak et al., 2019).

V části věnované řídicím metodám bylo ukázáno, že v praxi stále dominují jednoduché regulátory (On/Off, hystereze, PID), zejména díky jednoduchosti a robustnosti (Åström & Hägglund, 1995; Åström & Murray, 2008; Drgoňa et al., 2020). Jejich zásadním limitem je ale reaktivní charakter – regulátor typicky nereaguje na budoucí vývoj počasí, obsazenosti nebo cen energie, a proto nedokáže systematicky

využít tepelnou setrvačnost budovy (Killian & Kozek, 2016). Oproti tomu modelově prediktivní řízení (MPC) pracuje s predikčním modelem a v každém kroku optimalizuje budoucí sekvenci akcí při respektování omezení na komfort a provozní limity (Drgoňa et al., 2020; Rawlings et al., 2018). Literatura uvádí opakovaně dosažitelné úspory a zároveň zdůrazňuje bariéry adopce v praxi (náročnost modelu, integrační složitost, výpočetní nároky) (Afram & Janabi-Sharifi, 2014; Drgoňa et al., 2020).

Významným současným směrem je kombinace MPC s metodami strojového učení. Neuronové sítě se používají buď jako prediktory dynamiky (black-box), nebo jako hybridní doplnění fyzikálního modelu (physics-informed/hybridní přístupy), případně pro predikci poruch (obsazenost, vnitřní zisky) (Eini & Abdelwahed, 2019; Jiang & Dong, 2024). Praktické limity (konvexita, rychlost řešení) řeší práce využívající speciální architektury, které vedou k lépe řešitelným optimalizačním úlohám v rámci MPC (Paré et al., 2024). Z pohledu robustnosti je důležitá také kvantifikace nejistoty predikce – bayesovské varianty rekurentních sítí umožňují získat prediktivní rozdělení (nejen bodový odhad), což je relevantní pro robustní či stochastické varianty MPC (Hannula et al., 2025; Mesbah, 2016).

Celkově lze shrnout, že literatura se shoduje na vysokém potenciálu úspor v oblasti vytápění, ale úspěšná implementace v praxi vyžaduje (i) zvolený model odpovídající dostupným datům a výpočetnímu rozpočtu, (ii) jasně formulovaný kompromis mezi komfortem a spotřebou, a (iii) realizovatelnou integrační vrstvu pro reálný provoz (BMS/IoT, měření, spolehlivost) (Drgoňa et al., 2020; IEA EBC Annex 81, 2023).

6 Metodika a návrh simulačního experimentu

6.1 Cíle praktické části a specifikace požadavků

Cílem praktické části je porovnat čtyři strategie řízení teploty v budovách v simulovaném prostředí: bezpaměťové řízení s pásmem necitlivosti (dále jen referenční strategie `onoff`), PID regulátor (`pid`), konvenční modelově prediktivní řízení (`pure_mpc`) a hybridní MPC s reziduální korekcí pomocí LSTM sítě (`hybrid_mpc`). Srovnání probíhá na třech typologicky odlišných místnostech za šesti klimatických scénářů.

Aby bylo srovnání metodicky korektní, bylo nutné splnit několik podmínek. Každý běh musí být deterministicky reprodukovatelný, při stejných vstupních parametrech tedy produkuje identické výsledky. Trénovací data, zejména cílové hodnoty reziduí použité při trénování sítě LSTM, nesmí být dostupná v evaluační fázi. Všechny regulátory musí dostávat stejná vstupní data a být hodnoceny stejnou sadou klíčových ukazatelů výkonnosti (KPI). V praxi se ukázalo, že právě zajištění reprodukovatelnosti je inženýrsky náročnější, než se na první pohled zdá. Inicializační hodnotu generátoru (tzv. *seed*) je nutné koordinovat napříč generátorem scénářů, simulátorem, tvorbou excitačních dat i tréninkem modelu LSTM.

Výkon regulátorů je hodnocen primárně dvěma ukazateli: dobou porušení komfortního pásma (*comfort_violation_hours*) a celkovým teplotním diskomfortem (*degree_minutes_outside_band*). Jako doplňkové metriky slouží RMSE, MAE a energetický zástupný ukazatel (tzv. *proxy*), který reprezentuje celkový akční zásah v ekvivalentních hodinách plného výkonu topení. Komfortní pásmo pro vyhodnocení KPI je definováno jako $[\mathrm{sp} - 0{,}5\,^{\circ}\mathrm{C},\ \mathrm{sp} + 0{,}5\,^{\circ}\mathrm{C}]$ okolo aktuální žádané hodnoty.

6.1.1 Definice KPI

V této práci nejsou ukazatele KPI definovány pouze na úrovni obecné matematické symboliky, ale především na úrovni konkrétní implementace. Tento přístup byl zvolen z toho důvodu, že právě implementační detail rozhoduje o tom, co srovnávací test (tzv. *benchmark*) ve skutečnosti měří. Všechny reportované ukazatele vznikají z časové řady uzavřené regulační smyčky, ve které je pro každý krok zaznamenána skutečná teplota místnosti `y`, aktuální žádaná hodnota `setpoint` a akční zásah `u`. Výpočet je centralizován do jediné funkce `compute_kpi()`, takže všechny regulátory jsou vyhodnocovány identickou logikou a nevzniká prostor pro to, aby různé referenční strategie používaly odlišnou definici komfortu nebo chyby.

Jádro implementace vypadá následovně:

Výpis 1: Oříznutí inicializační fáze a definice komfortního pásma

```
if skip_steps > 0:
    df = df.iloc[skip_steps:].copy()

y = df["y"].to_numpy(dtype=float)
sp = df["setpoint"].to_numpy(dtype=float)
u = df["u"].to_numpy(dtype=float)

lower = sp - 0.5
upper = sp + 0.5
violations = ((y < lower) | (y > upper)).astype(float)
```

Z tohoto fragmentu je patrné několik metodicky podstatných skutečností. Nejprve je odříznuta počáteční část simulace pomocí parametru `skip_steps`. V provedeném srovnávacím testu je tímto mechanismem odstraněna inicializační fáze (tzv. *warm-up*). Teprve poté jsou zbylá data převáděna do číselných polí a pro každý krok je vytvořena dolní a horní mez komfortního pásma. To znamená, že komfortní pásmo není vztaženo k jedné fixní teplotě pro celý běh, ale vždy k aktuálnímu setpointu v daném čase. Pokud se tedy během dne žádaná hodnota změní, posouvá se s ní automaticky i vyhodnocovací pásmo.

Ukazatel *comfort_violation_hours* představuje záměrně binární časovou metriku. Každý krok simulace se nachází buď uvnitř komfortního pásma, nebo mimo něj. Velikost odchylky v tomto konkrétním ukazateli nehraje roli. Pokud je teplota mimo komfort byť jen nepatrně, celý krok je započten jako porušení. Taková definice je vhodná pro provozní interpretaci, protože odpovídá na otázku, jak dlouho byl uživatel vystaven nekomfortnímu stavu. Současně je ale třeba si uvědomit její limit: odchylka o desetinu stupně a odchylka o dva stupně se zde projeví stejně dlouhým časovým příspěvkem. Právě proto není v práci využívána pouze tato metrika, ale je doplněna i o ukazatel celkové intenzity diskomfortu.

Ten je v implementaci odvozen následovně:

Výpis 2: Rozklad diskomfortu na podchlazení a přetopení

```
under = np.maximum(0.0, lower - y)
over = np.maximum(0.0, y - upper)
outside = under + over

underheating_degree_minutes = np.sum(under) * sampling_minutes
overheating_degree_minutes = np.sum(over) * sampling_minutes
degree_minutes_outside_band = np.sum(outside) * sampling_minutes
```

Metrika *degree_ minutes_ outside_ band* tedy nepočítá pouze délku pobytu mimo komfort, ale i velikost odchylky od nejbližší hranice komfortního pásma. Prakticky to znamená, že krátké a mírné vybočení je penalizováno méně než dlouhé nebo hluboké podchlazení či přetopení. Pokud je například teplota při desetiminutovém vzorkování o 0,5 °C pod dolní hranicí pásma, do této metriky se přičte 5 °C·min za každý takový krok. Tato veličina proto lépe zachycuje skutečnou závažnost nepohodlí než samotné hodiny porušení komfortu.

Za užitečný implementační detail lze považovat i skutečnost, že kód odděleně počítá `underheating_degree_minutes` a `overheating_degree_minutes`. Tyto pomocné hodnoty sice nejsou v hlavních tabulkách této práce reportovány jako samostatná KPI, ale mají diagnostickou hodnotu. Umožňují rozlišit, zda daný regulátor selhává spíše nedotápěním, nebo naopak přetápěním. To je důležité zejména v situaci, kdy dvě strategie vykazují podobný celkový diskomfort, ale jedna z nich k němu dochází převážně kvůli podteplotě a druhá kvůli přestřelování nad setpoint.

Vedle primárních komfortních ukazatelů jsou počítány také metriky RMSE a MAE. Tyto ukazatele již nepracují s komfortním pásmem, ale přímo s odchylkou od žádané hodnoty. I když je teplota stále uvnitř tolerovaného pásma ±0,5 °C, může mít regulátor nenulové hodnoty RMSE a MAE, pokud kolem setpointu systematicky osciluje. To je hlavní důvod, proč jsou v této práci chápány jako doplňkové, nikoli jako hlavní KPI. Z pohledu uživatelského komfortu je důležitější, zda je prostor mimo akceptovatelné meze, zatímco RMSE a MAE slouží spíše k jemnějšímu posouzení kvality sledování reference a hladkosti regulace.

Energetický proxy ukazatel je interpretován opatrně. V kódu vzniká jako časový součet normalizovaného akčního zásahu topení, tedy jako ekvivalent doby, po kterou by topný systém běžel na plný výkon:

Výpis 3: Finální sestavení návratové struktury KPI

```
err = y - sp

return KPIResult(
    comfort_violation_hours=float(violations.sum() * sampling_minutes / 60.0),
    rmse=float(np.sqrt(np.mean(err**2))),
    mae=float(np.mean(np.abs(err))),
    energy_proxy=float(np.sum(u) * sampling_minutes / 60.0),
    degree_minutes_outside_band=float(degree_minutes_outside_band),
    underheating_degree_minutes=float(underheating_degree_minutes),
    overheating_degree_minutes=float(overheating_degree_minutes),
)
```

Protože proměnná `u` představuje bezrozměrnou normalizovanou veličinu v intervalu od nuly do jedné, nejde o fyzikálně přesnou spotřebu energie v kWh. V ukazateli nejsou zohledněny účinnosti zdroje tepla, nelinearity výkonu ani případné rozdíly v technologii vytápění. Jeho smyslem je spíše relativní porovnání regulačních strategií za stejných podmínek než energetický audit v absolutních jednotkách. Jinými slovy, metrika dobře odpovídá na otázku, který regulátor vyžadoval větší kumulovaný zásah, ale sama o sobě neumožňuje tvrdit, kolik elektrické nebo tepelné energie by se v reálné budově skutečně spotřebovalo.

Místo ve zpracovatelském řetězci (tzv. *pipeline*), kde jsou KPI skutečně vyhodnocovány, se nachází v koordinačním skriptu až po dokončení simulace daného scénáře a po odečtení inicializační fáze:

Výpis 4: Vyhodnocení KPI až po ukončení inicializační fáze

```
kpi = compute_kpi(
    log_df,
    sampling_minutes=cfg.sampling_minutes,
    skip_steps=settings.warmup_steps,
)
```

Tento detail má přímý dopad na interpretaci výsledků. Prvních 120 minut běhu není využíváno pro finální hodnocení, protože v této fázi se systém ustaluje po inicializaci a u hybridního regulátoru současně dobíhá naplnění krátké historie vstupů pro LSTM prediktor. Metriky tak odpovídají pouze ustálenější části experimentu a nejsou deformovány startovními přechodovými jevy. Současně z toho plyne, že efektivní délka vyhodnocovacího okna není ve všech místnostech stejná, liší se podle

vzorkovací periody a je nutné ji zohlednit při mezimístnostním srovnání.

Právě z tohoto důvodu je v interpretaci vedle oficiálně ukládaných KPI využíván také odvozený ukazatel podílu času mimo komfort, který je označen jako *violation_fraction*. Ten se v artefaktech neukládá jako samostatný sloupec, ale jednoduše se dopočítá z hodnoty *comfort_violation_hours* vydělením efektivní délkou evaluačního okna po odečtení inicializační fáze. Jeho význam je čistě interpretační: umožňuje převést absolutní hodiny na relativní podíl vyhodnocovaného času a tím férověji porovnávat malou kancelář (`small_office`), velkou kancelář (`large_office`) a zasedací místnost (`meeting_room`), které mají po inicializaci různě dlouhé evaluační úseky.

6.2 Architektura aplikace a správa experimentů

Kód je organizován do čtyř funkčně oddělených vrstev: aplikační logika (`app/`), koordinační skripty (`scripts/`), konfigurace (`configs/`) a výstupní artefakty. Toto oddělení není pouhou konvencí, ale přímo podporuje metodickou čistotu experimentu. Konfigurace je oddělena od implementace a vedle výsledků je vždy uložen otisk použitých parametrů (tzv. *snapshot*), takže konkrétní běh lze reprodukovat i bez znalosti aktuálního stavu repozitáře.

Implementace je realizována v jazyce Python. Pro numerické výpočty a práci s tabulkami jsou použity zejména knihovny NumPy, SciPy a Pandas, pro formulaci a řešení optimalizační úlohy CVXPY a OSQP, pro reziduální model PyTorch a pro správu konfigurace YAML. Tato technologická vrstva je uvedena explicitně, protože je součástí praktické reprodukovatelnosti řešení a současně vymezuje jeho implementační rámec.

Výstupy každého běhu jsou ukládány do stromové adresářové struktury `artifacts/<tag>/<room_id>/runs/train_seed_{s}/eval_variant_{v}/`. Model LSTM je identifikován hashem konfigurace. Při opakované evaluaci se shodným nastavením proto není nutné model přetrénovat. Tato volba se ukázala jako praktická nejen z hlediska výpočetního výkonu, ale i z hlediska auditovatelnosti.

Schéma na obrázku 1 shrnuje, kde se v experimentu odděluje offline trénink reziduálního modelu od vlastní evaluace a kde vznikají auditovatelné artefakty pro KPI a statistické vyhodnocení. Trénovací větev sítě `ResidualLSTM` je oddělena od evaluační větve, ve které všechny regulátory dostávají shodná scénářová data a jsou vyhodnoceny jednotnou sadou KPI.

Obrázek 1: Celková experimentální pipeline

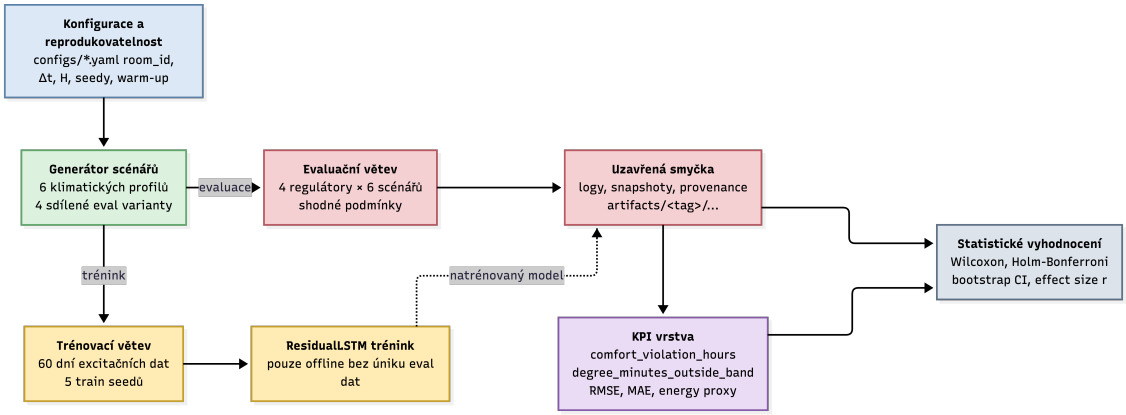

6.3 Konfigurace a simulační model prostředí

6.3.1 Typové místnosti

Experiment pracuje se třemi místnostmi lišícími se fyzikálními vlastnostmi, žádanými hodnotami i vzorkovací periodou. Malá kancelář (`small_office`) disponuje vzorkovací periodou $\Delta t = 10\,\text{min}$ a predikčním horizontem 18 kroků. Velká kancelář (`large_office`) modeluje otevřený prostor s $\Delta t = 15\,\text{min}$ a horizontem 12 kroků. Tato místnost má vyšší tepelný výkon a přísnější omezení rychlosti změny akčního zásahu, čímž simuluje setrvačnost velkoplošných otopných systémů. Zasedací místnost (`meeting_room`) reprezentuje starší zástavbu s $\Delta t = 20\,\text{min}$ a horizontem 10 kroků, vykazuje tedy vyšší koeficient tepelné ztráty a silnější vliv solárních zisků i obsazenosti.

Generátor scénářů používá standardně 192 kroků na scénář. Po odečtení inicializační fáze v délce 120 minut proto vyhodnocované okno nemá jednotnou délku: pro malou kancelář (`small_office`) činí 30 h, pro velkou kancelář (`large_office`) 46 h a pro zasedací místnost (`meeting_room`) 62 h. Tato skutečnost je pro interpretaci výsledků zásadní, protože absolutní hodiny porušení komfortu nejsou bez další normalizace přímo srovnatelné napříč místnostmi.

Přesné parametry typových místností shrnuje tabulka 1. Právě rozdílná kombinace Δt, horizontu a délky evaluačního okna vysvětluje, proč nelze absolutní hodiny mimo komfort interpretovat napříč místnostmi bez předchozí normalizace.

6.3.2 Model tepelné dynamiky

Simulovaný systém vychází z lineárního RC modelu místnosti diskretizovaného Eulerovou metodou a vyjádřeného rovnicí (11):

Tabulka 1: Typové místnosti a základní parametry

Místnost	Δt [min]	H [kroků]	Setpoint den/noc [°C]	$\Delta u_{\max}$	Evaluační okno [h]
`small_office`	10	18	22,0 / 20,5	1,2	30
`large_office`	15	12	22,5 / 21,0	0,3	46
`meeting_room`	20	10	21,0 / 18,0	0,8	62

$$T[k+1] = T[k] + \Delta t \cdot \big(\alpha(T_{\text{out}}[k] - T[k]) + \beta\, u[k] + \gamma\, I_{\text{sol}}[k] + \delta\, n_{\text{occ}}[k] + \varepsilon[k]\big), \quad (11)$$

kde $T[k]$ je teplota místnosti, $T_{\text{out}}[k]$ venkovní teplota, $u[k] \in [0, 1]$ normalizovaný akční zásah topení, $I_{\text{sol}}[k]$ sluneční radiace a $n_{\text{occ}}[k]$ počet osob. Parametry α, β, γ, δ charakterizují tepelné ztráty, výkon topení, solární zisky a tepelný příspěvek osob. Člen $\varepsilon[k]$ reprezentuje procesní šum simulující neměřené vlivy prostředí.

Žádané hodnoty nejsou ve všech místnostech stejné. Pro malou kancelář (`small_office`) se žádaná hodnota přepíná mezi 22,0 °C během dne a 20,5 °C v noci, pro velkou kancelář (`large_office`) mezi 22,5 °C a 21,0 °C a pro zasedací místnost (`meeting_room`) mezi 21,0 °C a 18,0 °C. Všechny tyto hodnoty jsou explicitně uloženy v konfiguračních souborech a text je proto uvádí po místnostech, nikoli jednou univerzální dvojicí.

Koeficienty fyzikálního modelu nejsou v této práci identifikovány z reálných dat ani převzaty z normy. Jsou explicitně zadány v YAML konfiguracích jako syntetické reprezentativní hodnoty pro tři typové prostory. To je vhodné pro srovnávací experiment a reprodukovatelnost, nikoli však pro tvrzení o přímé přenositelnosti na konkrétní budovu.

6.4 Strukturální odchylka modelu a skrytá obsazenost

6.4.1 Záměrná chyba nominálního modelu

Regulátory MPC pracují s nominálním predikčním modelem, jehož parametry se úmyslně liší od skutečného simulovaného systému. U malé kanceláře (`small_office`) je nominální koeficient tepelné ztráty nastaven na 0,08 oproti skutečným 0,15, solární koeficient na 0,0012 oproti 0,003 a příspěvek obsazenosti na 0,03 oproti 0,07. U velké kanceláře (`large_office`) je strukturální odchylka (tzv. *model mismatch*) mírnější, například 5,0 oproti 5,8 u topného zisku a 0,15 oproti 0,20 u tepelné ztráty. V zasedací místnosti (`meeting_room`) je záměrná nepřesnost opět výrazná, zejména

v parametrech úniku tepla a solárních zisků. Z hlediska interpretace výsledků je důležité, že srovnávací test (*benchmark*) tímto způsobem simuluje situaci nepřesně kalibrovaného modelu, nikoli ideálně identifikovaný MPC.

Konkrétní hodnoty parametrů skutečného a nominálního modelu uvádí tabulka 2. Zápis „skutečný → MPC“ zdůrazňuje, že regulátor optimalizuje nad vědomě zkreslenou dynamikou místnosti.

Tabulka 2: Strukturální odchylka modelu

Místnost	Topení β	Ztráty α	Solár γ	Obsazenost δ
`small_office`	3,5 → 3,5	0,15 → 0,08	0,0030 → 0,0012	0,07 → 0,03
`large_office`	5,8 → 5,0	0,20 → 0,15	0,0050 → 0,0030	0,09 → 0,05
`meeting_room`	4,2 → 4,2	0,28 → 0,18	0,0100 → 0,0060	0,15 → 0,10

V důsledku toho predikovaná teplota čistého MPC systematicky diverguje od skutečného průběhu.

$$r[k] = T[k+1] - \hat{y}_{\text{nom}}[k+1 \mid k] \tag{12}$$

Reziduální chyba definovaná vztahem (12) je přitom měřitelná po každém kroku a nese informaci o skrytých vlivech, které nominální model nezachycuje. Právě tato chyba je cílovým signálem pro reziduální LSTM síť.

6.4.2 Skrytá obsazenost

Regulátor dostává jako vstup pouze predikovanou obsazenost. Skutečná obsazenost může navíc zahrnovat neplánované skupinové návštěvy a přesčasové pobyty, o nichž regulátor neví. V generátoru scénářů jsou tyto události modelovány jako dodatečné pulsy o velikosti 2 až 7 osob na 1 až 4 kroky. V proměnlivých a podzimních scénářích (`mixed_day` a `autumn_day`) se navíc objevují i sporadické pozdní návštěvy mimo hlavní pracovní dobu. Tento rozdíl tvoří složku reziduální chyby, kterou by LSTM síť měla detekovat ze sekundárních signálů, zejména z odchylky teploty od predikované trajektorie.

6.5 Návrh a implementace řídicích strategií

6.5.1 Sjednocené rozhraní

Všechny čtyři regulátory implementují identické rozhraní: vstupem je struktura `Observation` s aktuální teplotou, žádanou hodnotou a prognózami budoucích po-

ruch a setpointů v horizontu. Výstupem je skalární akční zásah $u \in [0, 1]$. Identické rozhraní je nezbytnou podmínkou metodické validity srovnání.

6.5.2 Řízení s pásmem necitlivosti (`onoff`)

Nejjednodušší strategie bez predikce. Topení se zapne, pokud teplota klesne více než 0,4 °C pod žádanou hodnotu, a vypne, pokud ji překročí o více než 0,4 °C. Uvnitř pásma se v implementaci nenese předchozí stav, ale explicitně se nastaví $u = 0{,}0$. Nejde tedy o hysterézní spínací regulátor s pamětí stavu, ale o jednodušší bezpaměťovou logiku pásma necitlivosti. Tato implementační volba je důležitá, protože mění interpretační rámec celé strategie, a v další interpretaci je proto důsledně označována jako referenční strategie `onoff`, nikoli jako klasický On/Off regulátor s hysterezí.

6.5.3 PID regulátor

Použit je diskrétní PID regulátor s proporcionální, integrační a derivační složkou. Výstup je saturován na [0, 1] a doplněn ochranou proti přesycení integrační složky (tzv. *anti-windup*), která zabraňuje nekontrolovanému nárůstu regulační odchylky při saturaci.

6.5.4 Konvenční MPC

Optimální prediktivní regulátor minimalizuje kvadratické kritérium přes predikční horizont H podle vztahu (13):

$$\min_{\mathbf{u}} \sum_{k=0}^{H-1} \Big[q_{\text{track}} \big(\hat{y}[k+1] - \text{sp}[k]\big)^2 + r_{\text{e}}\, u[k]^2 + r_{\Delta u}\, \Delta u[k]^2 \Big]. \tag{13}$$

Omezení zahrnují $u[k] \in [0, 1]$ a maximální rychlost změny akčního zásahu. V samotné optimalizaci je použita nepenalizovaná zóna s poloviční šířkou 0,3 °C, nikoli ±0,5 °C. Hodnota ±0,5 °C patří až do definice vyhodnocovacích KPI. Tyto dvě role je proto nutné důsledně odlišovat: toleranční pásmo (tzv. *deadband*) uvnitř MPC formuluje cíl optimalizace, zatímco komfortní pásmo v metrikách určuje post-hoc hodnocení kvality regulace.

Optimalizační úlohu řeší nástroj OSQP Stellato et al., 2020. Při neúspěchu jsou připraveny záložní sekvence optimalizačních nástrojů ECOS a SCS. Jak bude uvedeno dále, v reálném srovnání nebylo záložní řešení ani jednou potřeba.

6.6 Hybridní MPC s reziduální korekcí (LSTM)

6.6.1 Motivace

Protože nominální model systematicky chybuje, predikce MPC se od skutečného průběhu teploty liší. Hybridní přístup tento problém řeší přidáním opravného členu $\hat{r}[k+j]$ do predikčního modelu podle vztahu (14):

$$\hat{y}[k+j+1] = a\,\hat{y}[k+j] + b_u\,u[k+j] + b_{\text{out}}\,T_{\text{out}}[k+j] + b_{\text{sol}}\,I_{\text{sol}}[k+j] + b_{\text{occ}}\,n_{\text{occ}}[k+j] + \hat{r}[k+j], \tag{14}$$

kde $\hat{r}[k:k+H]$ je vektor reziduálních predikcí dodaný LSTM sítí před zahájením optimalizace.

6.6.2 Architektura reziduální sítě

Síť `ResidualLSTM` je rekurentní neuronová síť s jednou skrytou vrstvou o 24 neuronech. Tato volba byla zvolena heuristicky jako záměrně malá architektura, aby inference zůstala stabilní a výpočetně nenáročná vzhledem k cílovému použití v regulační smyčce. Vstupní vektor příznaků v každém kroku je definován vztahem (15):

$$\mathbf{x}[k] = \big[T[k],\ u[k-1],\ T_{\text{out}}[k],\ I_{\text{sol}}[k],\ n_{\text{occ}}[k],\ \text{sp}[k],\ r[k-1]\big]^{\top}. \tag{15}$$

Záměrně je použit zpožděný akční zásah $u[k-1]$ místo aktuálního $u[k]$, protože ten je právě optimalizovanou proměnnou a jeho přímé zahrnutí by vytvořilo cirkulární závislost. Historie má délku 12 kroků, ale výstupní horizont sítě není pevně šestikrokový. Výstupní horizont je svázán s horizontem dané místnosti. Síť se tedy trénuje na $H = 18$ kroků pro malou kancelář (`small_office`), $H = 12$ pro velkou kancelář (`large_office`) a $H = 10$ pro zasedací místnost (`meeting_room`).

6.6.3 Trénink

Trénink probíhá výhradně v trénovací fázi oddělené od evaluace. Za tímto účelem je syntetizován 60denní excitační scénář sestavený z šesti desetidenních segmentů, po jednom pro každý klimatický profil. Akční zásahy jsou v excitační fázi generovány náhodně v intervalu $[0, 1]$, aby data pokryla dostatečně širokou oblast dynamického chování. Rezidua jsou vypočtena jako rozdíl skutečné a nominálně predikované teploty.

Datová sada (*dataset*) je chronologicky rozdělena v poměru 80/20, tedy 80 % trénovací a 20 % validační část. Vzorky nejsou přehazovány, aby nedocházelo k úniku budoucí informace do trénování. Síť je trénována pomocí optimalizačního algoritmu

Adam po dobu 20 epoch se ztrátovou funkcí MSE. Normalizační statistiky jsou ukládány spolu s váhami modelu. Na reprezentativním doplňkovém běhu zasedací místnosti (`meeting_room`, seed 42, varianta 2) byl ověřen také krátký test závislosti výsledků na velikosti skryté vrstvy (tzv. *sweep*) pro hodnoty 16/24/32 jednotek. Hybridní regulátor zde dosáhl téměř shodných výsledků 30,56/30,61/30,56 h v metrice *comfort_violation_hours* a 3,91/3,92/3,91 v RMSE. Větší síť tedy v tomto rozsahu nepřinesla měřitelný přínos z hlediska komfortu, a volbu 24 neuronů lze proto považovat za rozumný kompromis mezi jednoduchostí modelu a dostatečnou kapacitou.

6.6.4 Inference

Prediktor využívá klouzavé okno tvořené posledními 12 vektory příznaků. Důležitý implementační detail spočívá v tom, že zpracovatelský řetězec (*pipeline*) při evaluaci nevolá metodu `bootstrap()`. Prediktor se po zavolání `reset()` vrací do prázdného stavu. V prvních krocích proto pomocná rutina interně doplňuje sekvenci opakováním aktuálního vektoru příznaků. Prakticky tedy nejde o inicializaci z předchozího stavu (tzv. *warm-start*) převzatou z excitačního scénáře, ale o start ze studeného stavu (tzv. *cold-start*), jehož dopad je tlumen tím, že KPI se vyhodnocují až po 120minutové inicializační fázi.

V každém kroku se provede dopředná inference a výsledná reziduální prognóza se předá MPC optimalizátoru. Po aplikaci akčního zásahu se sice v observační fázi spočítá aktuálně pozorované reziduum, implementace jím však historii neaktualizuje bezprostředně v témže kroku. Do interní sekvence se ukládá naposledy použitý vektor příznaků vytvořený v metodě `act()`, zatímco nově pozorované reziduum se do vstupu promítne až v následujícím kroku prostřednictvím složky `_last_residual_obs`. Tím je zachováno oddělení trénovací a evaluační fáze: během evaluace se model neučí, pouze používá dříve natrénované váhy.

Celý tok informací v jednom kroku hybridního regulátoru shrnuje obrázek 2. Je z něj patrné, že datová vrstva koriguje pouze predikci nominálního modelu a že regulátor dostává pouze predikovanou obsazenost. Skutečná neplánovaná obsazenost se projeví až v reziduu využitém v dalších krocích. Samotná optimalizační úloha zůstává stejná jako u čistého MPC.

Obrázek 2: Tok informací v hybridním MPC

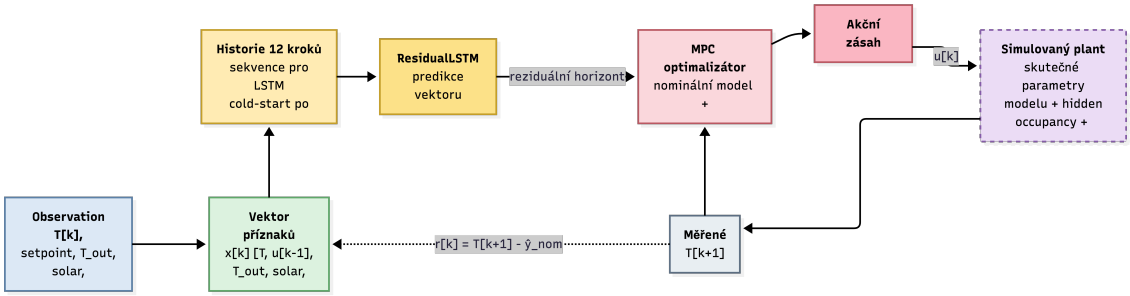

6.7 Metodika generování testovacích scénářů

6.7.1 Klimatické profily

Testovací sada obsahuje šest klimatických profilů pokrývajících různé operační podmínky. Zimní profil (`cold_day`) testuje regulaci při trvale nízkých venkovních teplotách, kdy topení pracuje téměř nepřetržitě. Slunečný profil (`sunny_day`) kombinuje chladnější vzduch s vysokými solárními zisky a vytváří podmínky pro přetápění. Jarní a podzimní profily (`spring_day` a `autumn_day`) reprezentují přechodná období s mírnější dynamikou. Proměnlivý profil (`mixed_day`) je záměrně nejchaotičtější a kombinuje vyšší variabilitu teploty, proměnlivou radiaci a zvýšenou pravděpodobnost skryté obsazenosti. Extrémní letní profil (`summer_heatwave`) testuje chování systému při extrémním tepelném zatížení, kdy bez aktivního chlazení nelze komfortní pásmo dlouhodobě udržet.

Výběr profilů nesleduje meteorologickou věrnost konkrétnímu roku, ale pokrytí různých provozních režimů. Každý profil proto odhaluje jiná slabá místa regulátorů: reaktivní přístupy selhávají zejména při teplotních špičkách a neplánované obsazenosti, prediktivní přístupy naopak narážejí na limity tehdy, když je systém fyzikálně saturován.

Základní parametrizaci profilů shrnuje tabulka 3. Nejde o meteorologický kalendář konkrétní lokality, ale o řízeně navržené provozní režimy s různou kombinací venkovní teploty, solárních zisků a skryté obsazenosti.

Tabulka 3: Klimatické profily scénářů

Profil	Základní T_{out} [°C]	Základní solár	Skrytá obsazenost	Hlavní účel
`cold_day`	-3	180	Standardní denní pulsy	Test saturace topení a dlouhodobého podchlazování.
`sunny_day`	4	450	Standardní denní pulsy	Riziko přetápění při vysokých solárních ziscích.
`spring_day`	12	350	Standardní denní pulsy	Přechodný profil s mírnější dynamikou.
`autumn_day`	8	200	Denní pulsy + občasné pozdní návštěvy	Mírné počasí se skrytou obsazeností mimo hlavní pracovní dobu.
`mixed_day`	5	250	Zesílené pulsy + pozdní návštěvy	Nejchaotičtější profil s frontami, proměnlivou radiací a vyšší stochastikou.
`summer_heatwave`	28	600	Standardní denní pulsy	Demonstrace fyzikálního limitu bez aktivního chlazení.

6.7.2 Reprodukovatelnost

Každý scénář je generován stochasticky, ale deterministicky. Výsledek tedy jednoznačně závisí na inicializační hodnotě generátoru (*seed*). Pro srovnávací test byly použity trénovací hodnoty $\{40, \ldots, 44\}$ a čtyři pevně uložené evaluační varianty scénářů. Tyto evaluační varianty nejsou pro každý seed znovu generovány, ale vznikají jednorázově ze samostatného seedu generátoru a následně se znovu používají napříč všemi pěti trénovacími seedy. Náhodnost zde tedy neslouží k vytváření nové čtveřice evaluačních scénářů pro každý seed, ale k oddělené variabilitě trénovací a evaluační části při zachování plné reprodukovatelnosti.

6.8 Experimentální infrastruktura a ověřovací pravidla

6.8.1 Základní běh

Skript `run_mvp.py` realizuje jeden úplný experimentální běh: načte konfiguraci, případně natrénuje LSTM model a spustí evaluaci pro všechny kombinace klimatického profilu a regulátoru. Inicializační fáze prvních 120 minut je z výpočtu KPI vyloučena. Výsledky jsou exportovány jako CSV soubory s KPI na úrovni scénářů i jejich průměry. Vedle nich je uložen konfigurační otisk (*snapshot*).

6.8.2 Komplexní benchmark

Koordinační skript `benchmark_report.py` systematicky prochází kombinatorický prostor tří místností, pěti trénovacích seedů a čtyř evaluačních variant. To znamená 20 evaluačních kontextů na místnost a 60 kontextů celkem. Metodicky podstatné

přitom je, že benchmark nepřipravuje pro každý seed novou čtveřici evaluačních scénářů, ale kombinuje pět seedů použitých v trénovací části se čtyřmi předem vytvořenými evaluačními variantami. V každém kontextu jsou spuštěny všechny čtyři regulátory nad shodnou sadou šesti scénářů. Na úrovni agregovaných dat tedy vzniká 240 řádků běhových KPI (3 místnosti $\times$ 5 seedů $\times$ 4 varianty $\times$ 4 regulátory) a 1440 řádků scénářových KPI.

6.8.3 Ochranné mechanismy a audit

Před každým spuštěním jsou automaticky ověřeny podmínky integrity dat: typová správnost, celistvá časová osa simulace a úplnost výsledků pro všechny kombinace regulátor $\times$ scénář. Při porušení jakéhokoliv ochranného mechanismu (tzv. *guardrail*) se experiment okamžitě ukončí s chybovým hlášením.

Nezávislý skript `audit_benchmark.py` tvoří samostatnou verifikační vrstvu. Ověřuje konzistenci výstupů pouze na základě artefaktů a konfiguračního souboru (manifestu), bez přístupu ke zdrojovému kódu. Tím vzniká užitečný druhý pohled na správnost experimentu.

6.9 Metodika statistického vyhodnocení

Výsledky jsou hodnoceny párovým Wilcoxonovým testem znaménkových pořadí Wilcoxon, 1945, který porovnává distribuci KPI hybridního regulátoru vůči každé ze tří referenčních strategií. Test je zvolen jako konzervativní neparametrická volba pro párová data s možnými vazbami, s malým počtem pozorování na úrovni jedné místnosti a s metrikami, jejichž rozdělení je omezené fyzikálními limity.

Test je aplikován na dvou úrovních agregace. Na úrovni běhů je párovacím klíčem trojice (místnost, seed, varianta), na úrovni scénářů čtveřice (místnost, seed, varianta, klimatický profil). Holmova-Bonferroniho korekce (Holm, 1979) přitom není aplikována pouze na tři souběžná srovnání mezi regulátory, ale vždy na celý soubor testů v daném rozsahu vyhodnocení. Při společném posouzení pěti KPI vůči třem referenčním strategiím tedy korekce v každém takovém scope zahrnuje 15 p-hodnot najednou.

Praktická relevance výsledků je vyjádřena efektovou velikostí, rank-biserální korelací $r \in [-1, 1]$, kde $r = 1$ znamená, že hybridní regulátor dosáhl lepšího výsledku v každém z párů. Intervalová nejistota středních hodnot je odhadnuta metodou *bootstrap* na 2000 iteracích.

Přehled obou úrovní statistického vyhodnocení uvádí tabulka 4. Ta je důležitá zejména proto, že stejná metrika je jednou interpretována na úrovni 60 běhových párů a podruhé na úrovni 360 scénářových párů.

Tabulka 4: Úrovně statistického vyhodnocení

Úroveň	Párovací klíč	n	Interpretace
Běhy	(místnost, seed, varianta)	60	Celková kvalita regulace v jednom evaluačním kontextu po agregaci přes všech šest scénářů.
Scénáře	(místnost, seed, varianta, scénář)	360	Jemnější pohled na citlivost regulátorů na konkrétní klimatický profil při zachování párového srovnání.

7 Experimentální vyhodnocení a výsledky

7.1 Souhrnné výsledky experimentu

Srovnávací experiment byl proveden na třech typových místnostech (`small_office`, `large_office`, `meeting_room`) s pěti trénovacími seedy a čtyřmi sdílenými evaluačními variantami. To odpovídá 20 evaluačním kontextům na místnost a 60 kontextům celkem. Je však třeba přesně rozlišovat, že nejde o čtyři nově generované varianty pro každý seed, ale o čtyři pevné evaluační varianty opakovaně zkřížené se všemi pěti trénovacími seedy. V tomto uspořádání dosáhl hybridní regulátor `hybrid_mpc` nejnižší doby porušení komfortního pásma ve všech 60 běhových párových porovnáních vůči každé základní strategii. Tento výsledek je ale třeba interpretovat v kontextu záměrné strukturální odchylky a skryté obsazenosti: nominální MPC model byl kalibrován s odchylkami od skutečných parametrů a simulace současně obsahuje poruchy, které regulátor přímo nepozoruje, čímž byl prostor pro hybridní korekci vědomě vytvořen.

7.1.1 Celkové pořadí regulátorů

Souhrnné výsledky primárních KPI shrnuje tabulka 5. Tabulka vychází z $n = 20$ běhů na místnost a regulátor. Regulátory jsou v každé sekci seřazeny vzestupně podle průměrné doby porušení komfortu. U primárních KPI je uveden průměr ± směrodatná odchylka. RMSE a MAE jsou pro úsporu místa ponechány ve formě průměru.

Tabulka 5: Průměrné KPI regulátorů dle místnosti

Místnost	Regulátor	Porušení komfortu [h]	Diskomfort [°C·min]	RMSE	MAE
`small_office`	**hybrid_mpc**	**7,54 ± 0,72**	**2831,7 ± 212,2**	**2,00**	**1,88**
	`pid`	12,30 ± 0,46	2927,8 ± 205,1	2,13	1,96
	`pure_mpc`	14,48 ± 0,63	2887,8 ± 203,4	2,15	2,04
	`onoff`	15,82 ± 0,83	2978,1 ± 196,2	2,21	2,05
`large_office`	**hybrid_mpc**	**8,84 ± 0,16**	4784,1 ± 591,2	**2,19**	**2,02**
	`pure_mpc`	9,40 ± 0,38	**4781,9 ± 595,3**	2,24	2,09
	`pid`	16,09 ± 0,59	4882,2 ± 605,5	2,30	2,09
	`onoff`	26,34 ± 0,40	5198,9 ± 610,5	2,50	2,27
`meeting_room`	**hybrid_mpc**	**30,97 ± 0,63**	**12231,8 ± 764,1**	**4,14**	**3,66**
	`onoff`	45,94 ± 0,77	12909,3 ± 737,9	4,35	3,90
	`pid`	46,01 ± 2,59	12907,1 ± 746,8	4,34	3,90
	`pure_mpc`	47,81 ± 1,19	12530,9 ± 761,3	4,25	3,83

Z tabulky je patrné, že míra zlepšení silně závisí na typu místnosti. V případě malé kanceláře (`small_office`) překonává hybridní regulátor (`hybrid_mpc`) strategii PID o 4,75 h a čistý MPC o 6,94 h. Čistý MPC zde navíc zaostává i za PID, což potvrzuje, že odchylka modelu je pro tuto místnost dostatečně silná na to, aby zhoršila chování samotného nominálního modelu. Ve velké kanceláři (`large_office`) je nejsilnějším protivníkem čistý MPC (`pure_mpc`). Rozdíl 0,56 h v komfortní metrice je malý a u metriky *degree_minutes_outside_band* je dokonce nepatrně lepší čistý MPC. Největší rozdíl se projevuje v zasedací místnosti (`meeting_room`): `hybrid_mpc` dosahuje 30,97 h oproti 45,94–47,81 h ostatních strategií. To již nepředstavuje pouze rozdíl v řádu jednotek hodin, ale téměř polovinu 62hodinového vyhodnocovaného okna, které je pro tuto místnost specifické.

Ukazatel RMSE v tabulce je vhodné číst jako agregát přes všech šest scénářů, nikoli jako chybu v běžném komfortním režimu. Tuto metriku výrazně navyšuje zejména scénář extrémních veder (`summer_heatwave`), v němž simulace ukazuje fyzikálně neudržitelný komfort bez chlazení a kde všechny strategie tráví mimo komfort 100 % vyhodnocovaného času. Po vyloučení tohoto jediného scénáře klesá průměrné RMSE u hybridního regulátoru z 2,00 na 0,39 v malé kanceláři, z 2,19 na 0,31 ve velké kanceláři a z 4,14 na 1,85 v zasedací místnosti. Agregované RMSE tedy v tomto experimentu vypovídá spíše o celkové robustnosti napříč všemi režimy včetně fyzikálně nesplnitelného letního scénáře než o přesnosti regulace v běžně realizovatelných provozních stavech.

Rozptyl výsledků na úrovni jednotlivých 20 evaluačních kontextů zachycuje graf 3. Krabicové grafy jsou zde vhodnější než samotné průměry, protože ukazují nejen střední hodnotu, ale i stabilitu regulátoru mezi počátečními hodnotami a variantami scénářů. Je z nich dobře patrné, že hybridní regulátor není lepší pouze v průměru, ale že si ve všech třech místnostech drží užší nebo srovnatelný rozptyl oproti konkurenčním regulátorům. Obzvláště v zasedací místnosti (`meeting_room`) je to dobře patrné: `hybrid_mpc` dosahuje nejen nižšího mediánu, ale jeho interkvartilové rozpětí se s ostatními metodami vůbec nepřekrývá.

7.1.2 Normalizace napříč místnostmi

Protože efektivní délka vyhodnocovaného okna není ve všech místnostech stejná, je vhodné porovnat výsledky i v relativním vyjádření. Tabulka 6 uvádí průměrný podíl času mimo komfortní pásmo. Hodnoty jsou odvozeny z *comfort_violation_hours* a používají délku evaluačního okna $T_{\text{eval}} = 30/46/62$ h pro `small_office`/`large_office`/`meeting_room`.

Obrázek 3: Rozdělení doby porušení komfortu

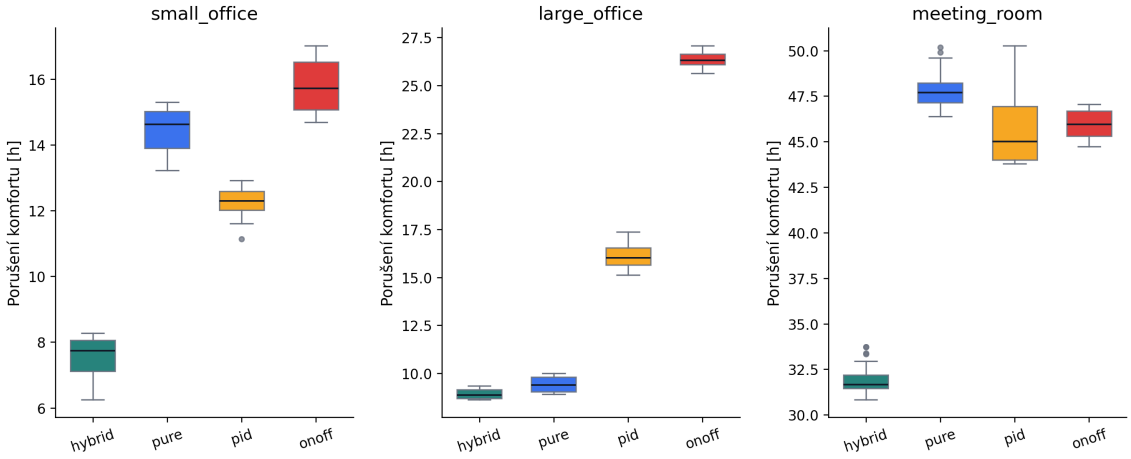

Tabulka 6: Podíl času mimo komfort podle místnosti

Místnost	`hybrid_mpc`	`pure_mpc`	`pid`	`onoff`
`small_office`	**25,15**	48,28	40,99	52,72
`large_office`	**19,23**	20,44	34,97	57,27
`meeting_room`	**49,95**	77,11	74,21	74,09

Po normalizaci je lépe vidět charakter jednotlivých místností. Velká kancelář (`large_office`) je z pohledu komfortu nejméně problematická, hybridní i čistý MPC se zde pohybují okolo 20 % času mimo pásmo. Malá kancelář (`small_office`) je naopak citlivější na odchylku modelu a hybridní regulátor zde snižuje podíl času mimo komfort z 48,28 % (u `pure_mpc`) na 25,15 %. Nejnáročnější je zasedací místnost (`meeting_room`). I nejlepší regulátor zde tráví mimo komfort téměř polovinu vyhodnocovaného času. To není známka selhání samotného hybridního přístupu, ale důsledek silné strukturální odchylky, skryté obsazenosti a absence chlazení.

Stejnou informaci v kompaktnější vizuální podobě ukazuje graf 4. Pro interpretaci napříč místnostmi je tento graf důležitější než absolutní hodiny, protože již respektuje rozdílnou délku evaluačních oken. Je zřejmé, že nejmenší relativní rozdíl mezi variantami `hybrid_mpc` a `pure_mpc` nastává ve velké kanceláři, zatímco v malé kanceláři a hlavně v zasedací místnosti je přínos hybridní korekce výrazně větší.

7.1.3 Spotřeba energie

Energetický proxy ukazatel se mezi regulátory liší jen minimálně. V malé kanceláři leží v rozmezí 14,28–14,87 h, ve velké kanceláři 18,98–19,48 h a v zasedací místnosti 33,62–34,54 h. Hybridní regulátor spotřebuje v průměru o 0,44 h více než čistý MPC, což odpovídá zhruba 2 % celkového akčního zásahu. Zlepšení komfortu tedy

Obrázek 4: Podíl času mimo komfort podle místnosti

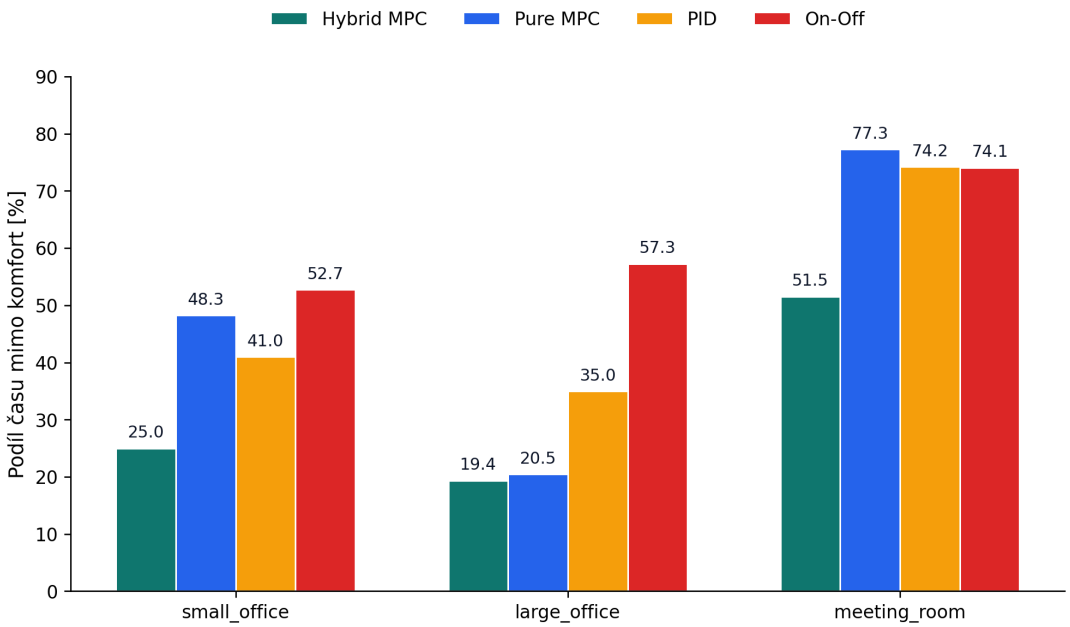

není vykoupeno výrazně vyšší spotřebou energie, byť ve srovnání s čistým MPC je rozdíl konzistentně mírně ve prospěch jednodušší varianty.

7.2 Analýza chování regulátorů v referenčních scénářích

7.2.1 Deskriptivní průměr v hodinách

Průměrné doby porušení komfortu pro jednotlivé klimatické profily zachycuje tabulka 7. Jde o deskriptivní průměr přes místnost, seed a variantu. V každé buňce je tedy $n = 60$. Tato tabulka je užitečná pro základní orientaci, ale sama o sobě nemá sloužit jako hlavní podklad pro srovnání napříč místnostmi, protože míchá 30hodinová, 46hodinová a 62hodinová evaluační okna.

Tabulka 7: Porušení komfortu dle klimatického profilu

Scénář	`hybrid_mpc`	`pure_mpc`	`pid`	`onoff`
`autumn_day`	**2,87**	15,88	13,81	21,05
`spring_day`	**5,81**	11,36	17,75	18,11
`sunny_day`	**7,90**	20,27	20,90	26,86
`mixed_day`	**8,42**	18,74	21,63	25,11
`cold_day`	**23,71**	31,15	28,69	39,07
`summer_heatwave`	46,00	46,00	46,00	46,00

Například hodnota 46,00 h u letního scénáře (`summer_heatwave`) neznamená, že každý běh měl po inicializaci právě 46 h. Jedná se o průměr přes místnosti s

délkami 30/46/62 h, v nichž se všechny regulátory nacházely mimo komfort po celou vyhodnocovanou dobu. V absolutních hodinách je tedy tato tabulka čitelná hlavně uvnitř jedné místnosti, nikoli mezi místnostmi navzájem.

7.2.2 Normalizované scénářové srovnání

Pro srovnání napříč místnostmi je vhodnější podíl času mimo komfort. Tabulka 8 uvádí průměrný podíl porušených kroků po normalizaci délkou evaluačního okna dané místnosti. I zde jde o průměr přes místnost, seed a variantu, tedy $n = 60$ na buňku.

Tabulka 8: Podíl času mimo komfort dle klimatického profilu

Scénář	`hybrid_mpc`	`pure_mpc`	`pid`	`onoff`
`autumn_day`	**5,36**	29,64	25,55	43,47
`spring_day`	**10,03**	20,05	33,22	35,40
`sunny_day`	**13,79**	39,33	41,48	55,42
`mixed_day`	**15,20**	36,06	43,79	51,29
`cold_day`	**44,26**	66,60	56,30	82,59
`summer_heatwave`	100,00	100,00	100,00	100,00

Normalizované výsledky potvrzují stejný kvalitativní obraz jako absolutní hodiny, ale bez metodického zkreslení. Hybridní regulátor je nejúspěšnější u podzimního, jarního, slunečného a proměnlivého profilu, tedy v situacích, kde systém není tvrdě limitován výkonem topidla a kde naopak významně roste role skrytých poruch. V zimním profilu (`cold_day`) zlepšení zůstává zřetelné, ale menší, protože systém je častěji saturován na plném topném výkonu. V letním profilu (`summer_heatwave`) tráví všechny strategie mimo komfort 100 % vyhodnocovaného času. Tento scénář proto testuje fyzikální limity systému, nikoli kvalitu samotného regulátoru.

Pro rychlou orientaci ve scénářové obtížnosti je užitečný také graf 5. Každá buňka v něm představuje průměr přes místnost, seed a variantu po předchozí normalizaci délkou evaluačního okna dané místnosti. Graf potvrzuje dva důležité závěry. Zaprvé, hybridní regulátor dosahuje nejlepších výsledků ve všech nesaturovaných profilech a jeho výhoda je obzvláště výrazná u podzimního a slunečného dne, kde reziduální korekce dobře zachycuje vliv poruch mimo nominální model. Zadruhé, extrémní letní den je kvalitativně odlišný scénář: všechny buňky mají hodnotu 100 %, takže tento profil neodlišuje kvalitu regulace, ale pouze potvrzuje absenci aktivního chlazení a fyzikální neudržitelnost komfortu při vysokém teplotním zatížení.

Obrázek 5: Heatmapa podílu času mimo komfort

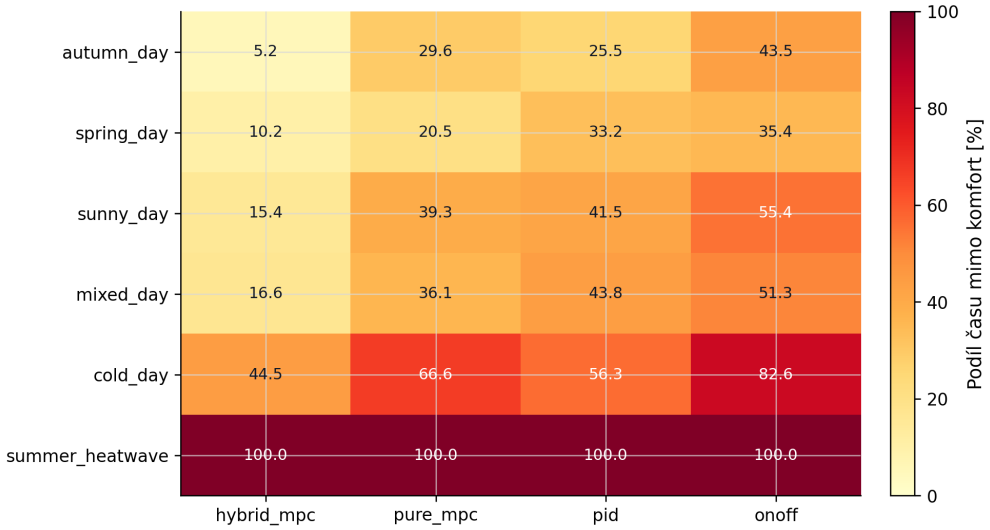

7.2.3 Interpretace scénářů na úrovni místností

V malé kanceláři (`small_office`) se přínos hybridní korekce projevuje téměř ve všech profilech. U podzimního profilu (`autumn_day`) klesá podíl času mimo komfort na 3,14 % oproti 22,33 % u čistého MPC a 14,50 % u PID. Výrazný je i proměnlivý profil (`mixed_day`), kde hybridní regulátor dosahuje 6,67 % oproti 31,08 % u strategie `pure_mpc`. Zvláště zajímavý je zimní profil (`cold_day`): čistý MPC zde tráví mimo pásmo 90,17 % času, tedy hůře než PID. To odpovídá skutečnosti, že v malé kanceláři je odchylka modelu natolik výrazná, že samotná optimalizace nad nepřesným modelem nepomáhá.

Ve velké kanceláři (`large_office`) je situace odlišná. U podzimního, jarního, slunečného a proměnlivého profilu jsou výsledky obou MPC strategií téměř nerozlišitelné: například u `autumn_day` dosahují 2,20 % a 2,17 %, u `spring_day` 2,23 % a 2,39 %. Smysluplnější rozdíl se objevuje až v zimním profilu, kde hybridní řešení snižuje podíl mimo komfort z 9,86 % na 3,26 %. Tato téměř shodná trajektorie vysvětluje, proč je ve velké kanceláři přínos hybridní korekce nad čistým MPC malý a proč se u metriky celkového diskomfortu může pořadí dokonce obracet.

V zasedací místnosti (`meeting_room`) je naopak hybridní přístup výrazně nejlepší téměř ve všech nesaturovaných scénářích. U podzimního profilu klesá podíl času mimo komfort na 10,75 % oproti 64,41 % u čistého MPC. U slunečného dne na 34,19 % oproti 78,23 % a u proměnlivého dne na 33,44 % oproti 71,34 %. Na tomto typu místnosti se tedy nejlépe ukazuje, že reziduální model dokáže kompenzovat podhodnocený příspěvek obsazenosti a ztrát. V zimním a letním profilu však i zde

naráží na fyzikální limity, protože systém se nachází mimo komfort téměř po celou dobu.

7.2.4 Reprezentativní časové trajektorie

Agregované tabulky ukazují velikost efektu, ale nikoliv mechanismus, kterým k němu dochází. Grafy 6, 7 a 8 proto doplňují tři reprezentativní evaluační běhy po odečtení inicializační fáze. Ve všech případech je zobrazena teplota místnosti T_{room}, aktuální žádaná hodnota a akční zásah u pro obě prediktivní strategie.

Obrázek 6: Reprezentativní trajektorie: malá kancelář

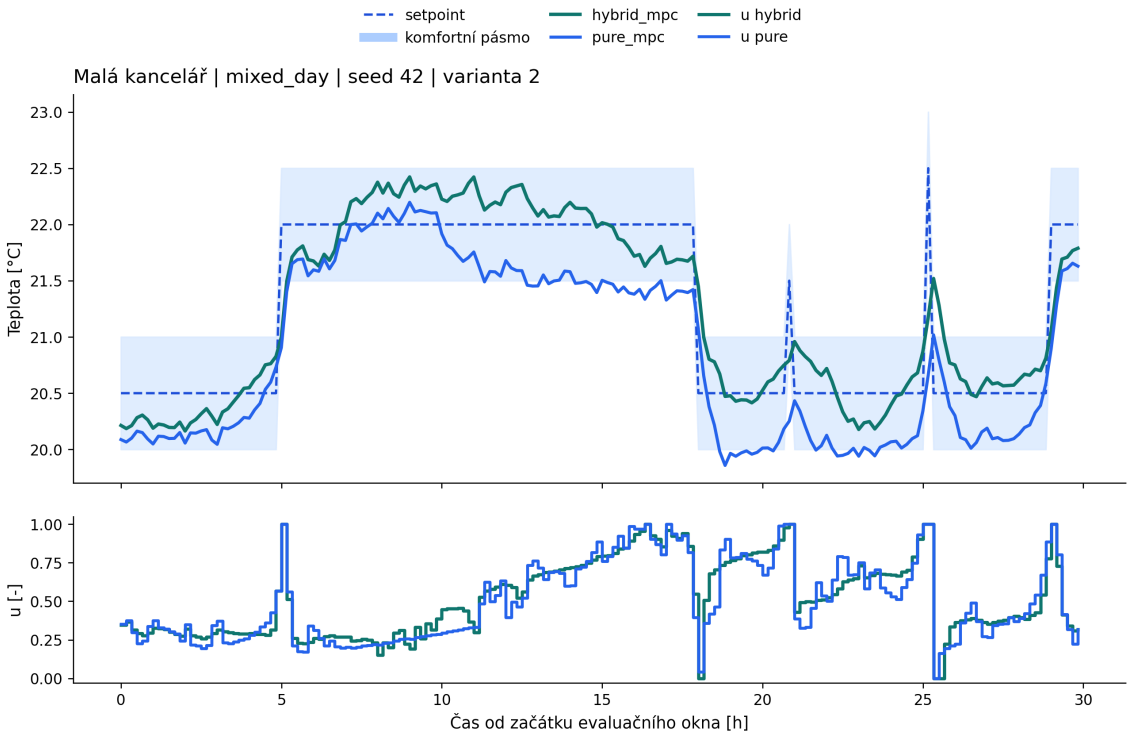

Graf 6 zachycuje reprezentativní běh malé kanceláře ve scénáři `mixed_day` pro seed 42 a variantu 2 po odečtení inicializační fáze. Je z něj patrné, že hybridní korekce pomáhá zejména v proměnlivém profilu `mixed_day`. Čistý MPC zde častěji klesá pod dolní mez komfortního pásma, zatímco hybridní varianta se vrací k žádané hodnotě dříve a s menším následným rozkmitáním akčního zásahu.

Obrázek 7: Reprezentativní trajektorie: velká kancelář

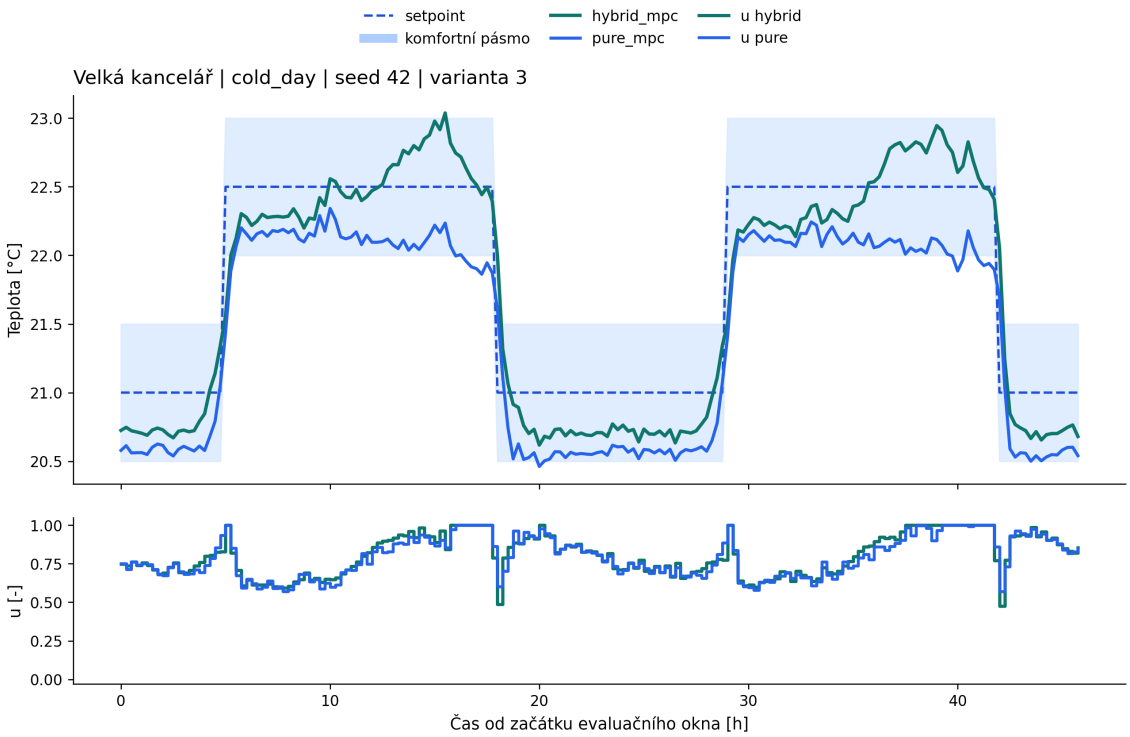

Graf 7 zachycuje reprezentativní zimní běh velké kanceláře ve scénáři `cold_day` pro seed 42 a variantu 3. Potvrzuje, že ve velké kanceláři jsou obě MPC varianty v celé řadě situací téměř překryté. Hybridní korekce zde zlepšuje některé kroky v zimním profilu, ale z tvaru obou trajektorií je dobře vidět, proč se v této místnosti pořadí u agregovaného diskomfortu může i obracet.

Obrázek 8: Reprezentativní trajektorie: zasedací místnost

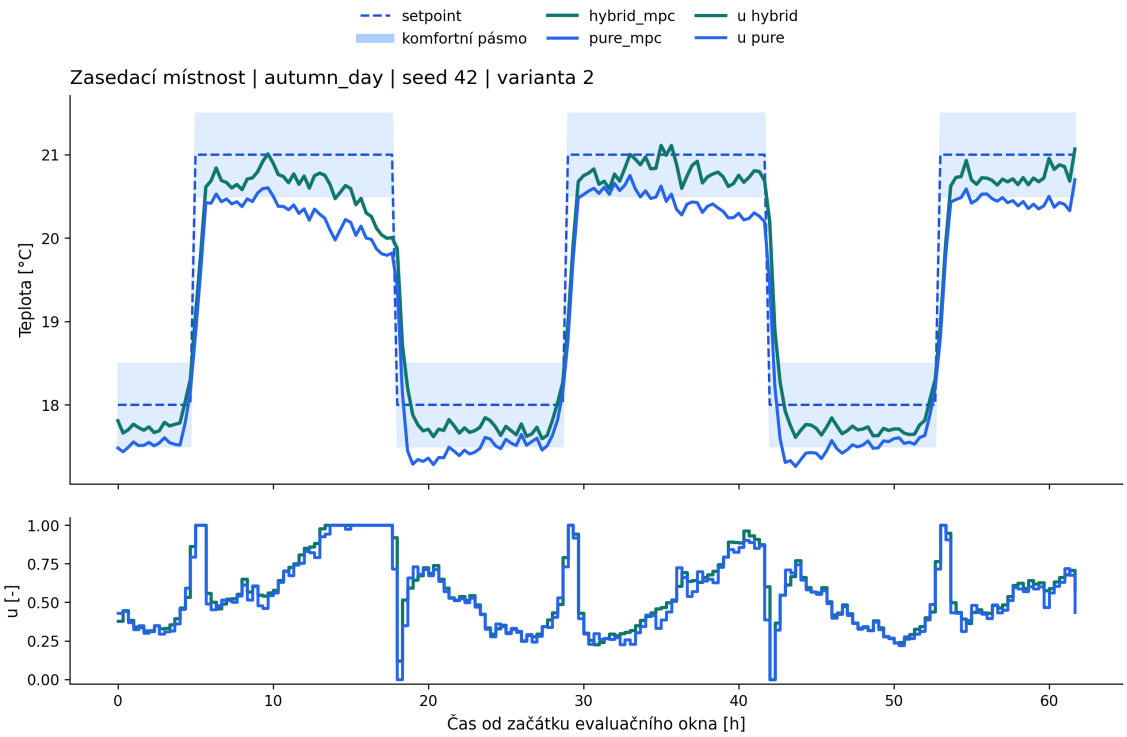

Nejsilnější ilustraci mechanismu nabízí graf 8, který zachycuje reprezentativní běh zasedací místnosti ve scénáři `autumn_day` pro seed 42 a variantu 2. V zasedací místnosti hybridní regulátor během denních přechodů systematicky udržuje vyšší teplotu v chladnějších úsecích a současně omezuje propady po změnách žádané hodnoty. Právě zde se nejlépe ukazuje praktický význam reziduální korekce v prostoru s výraznou skrytou obsazeností a silnější odchylkou modelu.

Obrázek 9: Predikované a pozorované reziduum

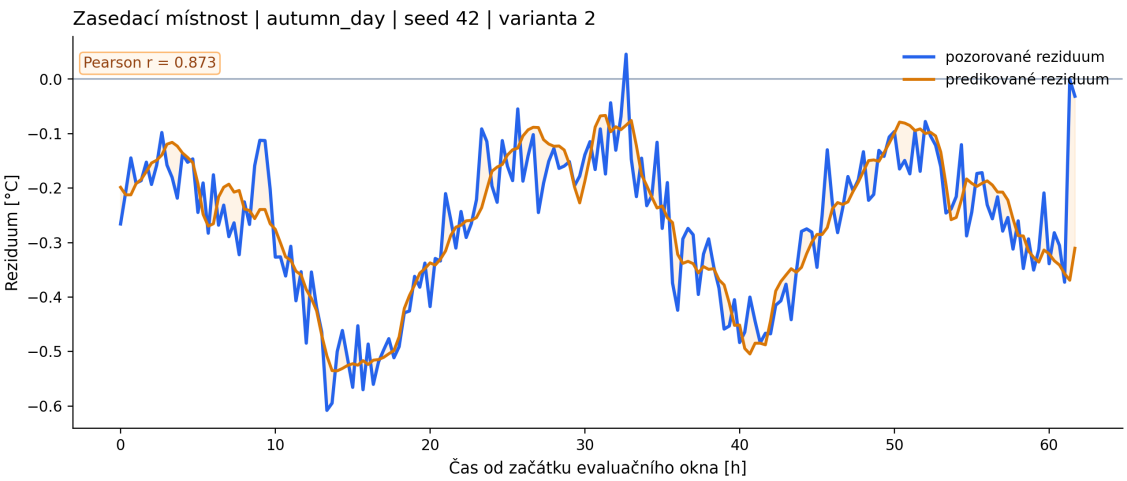

Graf 9 zachycuje tentýž reprezentativní běh zasedací místnosti ve scénáři `autumn_day` (seed 42, varianta 2). Pearsonova korelace mezi predikovaným a pozorovaným rezi-

duem zde dosahuje $r = 0{,}87$, takže rezidua nejsou pouhým šumem. LSTM prediktor nesleduje každý jednotlivý výkyv, ale poměrně věrně zachycuje pomalejší trend pozorovaného rezidua. Právě taková strukturovaná chyba je předpokladem pro to, aby datová korekce mohla čistému MPC smysluplně pomoci.

7.2.5 Doplňková ablace velikosti odchylky modelu

Největší metodickou otázkou je, nakolik je zlepšení hybridního přístupu podmíněno velikostí záměrně vložené odchylky modelu. Tabulka 9 proto doplňuje ilustrativní ablaci na jednom reprezentativním běhu zasedací místnosti (seed 42, varianta 2; průměr přes všech šest scénářů). Postupně byl zmenšen rozdíl mezi parametry nominálního modelu a reálného systému, aniž by byla měněna testovací infrastruktura.

Tabulka 9: Ablace velikosti odchylky modelu

Konfigurace MPC modelu	Hybridh>h	Pureh>h	Δh>h	Hybrid RMSE	Pure RMSE
Původní odchylka	30,61	47,28	16,67	3,92	4,01
Menší odchylka	30,28	35,28	5,00	3,90	3,96
Přesná shoda s modelem	29,83	30,50	0,67	3,89	3,89

Ačkoliv se nejedná o plnohodnotnou náhradu hlavního srovnávacího testu (tabulka pokrývá pouze jediný scénář), tento rozbor dobře ilustruje směr efektu: jakmile se nominální model přiblíží skutečnému systému, výhoda hybridního řízení nad čistým MPC se rychle zmenšuje. Tato zkouška tedy podporuje interpretaci, že přínos hybridní vrstvy není univerzální, ale úzce souvisí s velikostí modelové chyby, pro kterou byl *benchmark* záměrně konstruován.

7.3 Robustnost optimalizace a výpočetní náročnost

7.3.1 Stabilita solveru

Oba regulátory MPC dosáhly ve všech 60 evaluačních kontextech stavu `optimal` bez jediného použití záložního solveru. Na úrovni jednotlivých kroků to odpovídá 69 120 úspěšně vyřešeným optimalizačním úlohám pro `pure_mpc` a stejnému počtu pro `hybrid_mpc`. Přidání reziduálních predikcí LSTM jako externího opravného členu tedy nenarušilo konvexnost ani numerickou stabilitu kvadratické úlohy.

7.3.2 Výpočetní náročnost

Průměrné výpočetní časy na krok shrnuje tabulka 10.

Reaktivní regulátory zvládají krok prakticky okamžitě. Oba regulátory MPC se pohybují v rozmezí 1,8–2,9 ms. Hybridní verze přidává nad čistým MPC přibližně

Tabulka 10: Výpočetní čas regulátorů a trénink LSTM

Místnost	Regulátor	Čas/krok [ms]	Trénink LSTM [s]
small_office	onoff	< 0,001	–
	pid	< 0,001	–
	pure_mpc	2,61	–
	hybrid_mpc	2,91	4,43
large_office	onoff	< 0,001	–
	pid	< 0,001	–
	pure_mpc	1,83	–
	hybrid_mpc	2,18	2,88
meeting_room	onoff	< 0,001	–
	pid	< 0,001	–
	pure_mpc	1,87	–
	hybrid_mpc	2,18	2,16

0,3 ms, což odpovídá dopředné inferenci LSTM. Toto navýšení lze považovat za zanedbatelné vzhledem k typickým vzorkovacím periodám systémů HVAC. Jednorázový trénink modelu LSTM trvá 2–5 s a je vykonáván mimo vlastní regulační smyčku.

7.4 Výsledky statistického posouzení

7.4.1 Statistická významnost na úrovni běhů

Wilcoxonův párový test na datech z 60 běhových kontextů odmítl nulovou hypotézu pro všechna tři srovnání v primární metrice *comfort_violation_hours*. Výsledky shrnuje tabulka 11.

Tabulka 11: Wilcoxonův test pro *comfort_violation_hours*

Základní strategie	p_{raw}	p_{Holm}	r	$\Delta\bar{x}$ [h]
pure_mpc	$< 10^{-10}$	$< 10^{-9}$	1,000	8,11
pid	$< 10^{-10}$	$< 10^{-9}$	1,000	9,01
onoff	$< 10^{-10}$	$< 10^{-9}$	1,000	13,58

Efektová velikost $r = 1{,}000$ pro všechna tři srovnání znamená, že hybrid_mpc dosáhl nižší doby porušení než příslušná referenční strategie v každém z 60 běhových párů. U metriky celkového diskomfortu zůstávají výsledky rovněž silné při srovnání s PID a bezpaměťovým řízením, ale vůči čistému MPC klesá efektová velikost na $r = 0{,}828$. To odpovídá situaci ve velké kanceláři, kde je rozdíl mezi oběma MPC variantami malý a v části měření má čistý MPC dokonce o něco nižší diskomfort.

7.4.2 Výsledky na úrovni scénářů

Na datech z 360 scénářových párů jsou závěry konzistentní. Efektová velikost pro *comfort_violation_hours* dosahuje $r = 0{,}992$ vůči čistému MPC a $r = 1{,}000$ vůči oběma jednodušším strategiím. Mírný pokles v případě `pure_mpc` je způsoben především letním scénářem (`summer_heatwave`), kde jsou rozdíly nulové, protože všechny strategie selhávají stejně.

U energetického zástupného ukazatele je obraz méně jednoznačný. Na scénářové úrovni je vůči čistému MPC efektová velikost přibližně $r = -0{,}907$ a vůči řízení s pásmem necitlivosti $r = -0{,}878$, což znamená, že hybridní řešení zpravidla spotřebuje o něco více. Vůči PID je však efekt kladný ($r = 0{,}417$), tedy hybridní regulátor bývá mírně úspornější než PID. Statistickou významnost je zde proto nutné interpretovat společně s absolutní velikostí efektu, která zůstává malá.

7.4.3 Pohled na úrovni místností

Výsledky analýzy po jednotlivých místnostech potvrzují heterogenitu chování. V malé kanceláři a v zasedací místnosti jsou všechna srovnání u obou primárních KPI statisticky signifikantní s velmi vysokými efektovými velikostmi. Ve velké kanceláři je srovnání hybridní varianty vůči čistému MPC v metrice celkového diskomfortu nesignifikantní ($p = 0{,}053$, $r = -0{,}495$) a znaménko efektu je zde dokonce opačné. Jedná se o metodicky důležitý detail: pro tuto místnost nelze prohlásit, že hybridní varianta je dominantní ve všech metrikách.

8 Diskuze a zhodnocení limitů

8.1 Interpretace výsledků experimentu

Experiment v rámci srovnávacího testu se záměrně vloženou odchylkou modelu (*model mismatch*) a skrytou obsazeností potvrzuje, že hybridní MPC s reziduální korekcí pomocí sítě LSTM může významně zlepšit komfort tam, kde nominální model systematicky podhodnocuje vnitřní zisky nebo tepelné ztráty. Neprokázalo se však, že by tento přínos byl plošný. Hybridní architektura je naopak nejsilnější tam, kde jsou současně splněny dvě podmínky: strukturální odchylka je dostatečně velká a rezidua nesou strukturovanou informaci o budoucím vývoji (nikoli pouze náhodný šum).

V zasedací místnosti (`meeting_room`) jsou tyto podmínky naplněny téměř ideálně. Prostor je citlivý na neplánovanou obsazenost, nominální model podhodnocuje tepelné zisky osob i únik tepla a výsledné reziduum má výraznou informační hodnotu. Zlepšení proto není pouze statistické, ale i prakticky relevantní: podíl času mimo komfort zde klesá zhruba z 74–77 % na 50 %. Přesto ani v tomto případě hybridní přístup neodstraňuje všechny problémy, neboť bez aktivního chlazení nelze v letní vlně veder předepsané komfortní pásmo splnit.

Ve velké kanceláři (`large_office`) je situace opačná. Vyšší tepelná kapacita prostoru tlumí rychlé změny a nominální model je zde relativně přesný. Reziduální korekce proto přináší nad čistým MPC jen velmi malý užitek v komfortní metrice a v části měření není lepší vůbec. Právě tento výsledek je stěžejní pro formulaci praktického doporučení: hybridní vrstva není automaticky vhodná pro každou zónu. Pokud je nominální model dobře kalibrovaný a obsazenost nevytváří prudké skryté tepelné špičky, může být čistý MPC výhodnější, a to především pro svou implementační jednoduchost.

V malé kanceláři (`small_office`) leží chování mezi těmito dvěma extrémy. Odchylka modelu je zde dostatečně výrazná na to, aby čistý MPC zaostal i za regulátorem PID, ale tepelná dynamika není tak strmá jako v zasedací místnosti. Hybridní korekce zde proto funguje jako efektivní stabilizační člen, který prediktivnímu řízení vrací jeho výhodu nad reaktivními strategiemi.

Z hlediska celkové energetiky je výsledek příznivý. Hybridní regulátor sice bývá vůči čistému MPC nepatrně energeticky náročnější, ale absolutní rozdíl je malý a zůstává řádově nižší než dosažené zlepšení komfortu. Lze konstatovat, že skutečný praktický kompromis neleží mezi komfortem a výpočetním časem, nýbrž spíše mezi

komfortem a implementační složitostí, protože udržování trénovací infrastruktury, obnova dat, údržba modelu a celkový audit představují netriviální zátěž.

8.2 Praktická doporučení pro nasazení

Z provedeného experimentu plyne několik praktických závěrů. Nasazení hybridního MPC dává smysl zejména tehdy, když není realistické přesně identifikovat parametry nominálního modelu, když se v zóně objevují skryté interní zisky a když zaznamenané odchylky teploty představují skutečný provozní problém. Typickým příkladem mohou být zasedací místnosti, nepravidelně využívané kanceláře nebo starší prostory s nejistými vlastnostmi obálky.

Naopak v prostředích s relativně přesně známou dynamikou a s klidnějším provozem se přidaná složitost datově orientovaného řešení jeví jako nadbytečná. Výsledky velké kanceláře v tomto *benchmarku* ukazují, že čistý MPC může nabídnout srovnatelný komfort a místy i nepatrně nižší agregovaný diskomfort. Ekonomická smysluplnost hybridního přístupu proto nezávisí na době výpočtu (ta je zanedbatelná), ale na tom, zda vynaložené náklady na datovou infrastrukturu a údržbu modelu vyváží získaný přínos v tepelném komfortu uživatelů.

8.3 Reprodukovatelnost a robustnost řešení

Možnost exaktně zreprodukovat každý experimentální běh byla od začátku jedním z hlavních metodických požadavků. V praxi se ukázalo, že deterministické chování vyžaduje explicitní správu inicializačních hodnot (tzv. *seedů*) na více místech najednou: simulátor, generátor scénářů, proces tvorby excitačních dat i samotný trénink sítě LSTM mají každý vlastní zdroj pseudonáhodnosti. Teprve centralizované sjednocení této vrstvy dodává celkovým výsledkům plnohodnotnou auditovatelnost.

Ukládání konfiguračních otisků (tzv. *snapshotů*) vedle výsledků funguje jako účinná pojistka. Při zpětném dohledávání příčin neočekávaného chování bylo vždy možné zcela přesně zrekonstruovat podmínky konkrétního běhu, a to bez nutnosti spoléhat na historické revize repozitáře zdrojových kódů. Podobně užitečným prvkem se stal ověřovací skript pro audit, který validuje strukturu artefaktů čistě na základě uložených dat bez vazby na logiku softwaru.

8.4 Ohrožení validity a omezení

Prvním metodickým omezením jsou různé délky vyhodnocovacích oken podle místnosti. Absolutní počty hodin porušení komfortu jsou sice pro čtenáře intuitivní,

avšak bez předchozí normalizace mohou vést k zavádějícím úsudkům. V textu jsou hodnoty z artefaktů ponechány v původní podobě pro snazší porovnatelnost s výstupy, nicméně pro interpretaci napříč různými místnostmi se doporučuje opírat se o normalizovaný podíl času mimo komfort.

Druhým rizikem ohrožení validity (tzv. *threats to validity*) je syntetická povaha dat. Parametry modelu i jednotlivých scénářů byly navrženy tak, aby explicitně reprezentovaly tři odlišné typy místností a kontrolovanou modelovou odchylku, nešlo tedy o namodelování jedné reálně existující budovy. Uvedený postup posiluje interní konzistenci srovnávacího testu, zároveň však částečně omezuje externí validitu získaných zjištění vůči reálnému provozu.

Třetí omezení přímo plyne ze snížené složitosti použitých modelů. Experiment operuje nad jednou zónou, s lineární dynamikou a čistě topným systémem bez aktivního letního chlazení. Letní scénář veder je proto koncipován spíše jako demonstrace fyzikálního limitu než jako test regulační jemnosti. Ve vícezonální budově vybavené chladicími systémy by se mohlo relativní pořadí posuzovaných strategií znatelně proměnit.

Čtvrtým rizikem je způsob napojení datové vrstvy. Model LSTM je plně trénován offline na syntetických excitačních datech s generovanými náhodnými zásahy a jeho vnitřní váhy se během evaluace dále nijak neupravují. Stejně tak chybí implementace nativního převzetí historického kontextu (tzv. *warm-start*) z předchozího provozu, a počáteční zátěž neznalosti tak musí být potlačována inicializační fází vyhodnocování. Ačkoli je podobná zkratka přijatelná pro uzavřený vědecký experiment, reálné průmyslové nasazení by vyžadovalo mechanismus průběžného online učení.

Pátým omezením je výpočetní platforma, na které byla metodika ověřována. Zaznamenané výpočetní časy pocházejí z desktopového prostředí jazyka Python, nikoli z vestavěného (*embedded*) hardwaru, který představuje ve světě automatizace budov reálný standard. Ačkoli se časy v řádu jednotek milisekund jeví jako příznivé, pro úplnou průkaznost je třeba tyto závěry v budoucnosti ověřit na konkrétní nasazované platformě.

8.5 Možnosti budoucího rozšíření

Přirozeným rozšířením je detailní ablační analýza napříč celou šíří 60 evaluačních kontextů. V této práci byl představen pouze ilustrativní příklad zaměřený na variabi-

litu velikosti strukturální odchylky v jednom reprezentativním běhu. Plnohodnotná navazující studie by měla oddělit izolovaný vliv menší modelové odchylky, vliv deaktivované reziduální korekce a vliv scénářů bez skryté obsazenosti.

Dalšími relevantními směry jsou testování online adaptace reziduálního modelu za provozu a přenos parametrů sítě mezi podobnými zónami (tzv. *transfer learning*) v případě vícezonálních topologií. Přirozeným navazujícím krokem je rovněž ověření celého řešení v reálném provozu: pouze přímé napojení na skutečná měření v budově může s definitivní platností prokázat, zda synteticky nastavené odchylky odpovídají problémům vyskytujícím se v praxi.

9 Závěr

Tato práce se zabývala návrhem a experimentálním vyhodnocením hybridního přístupu k řízení teploty v budovách. Navržené řešení kombinuje modelově prediktivní řízení s vrstvou reziduální korekce zajišťovanou neuronovou sítí s architekturou LSTM. V rámci praktické části bylo sestaveno reprodukovatelné simulační prostředí zahrnující tři typologicky odlišné virtuální místnosti, čtyři řídicí strategie a testovací plán pokrývající šest klimatických scénářů, pět trénovacích seedů a čtyři sdílené evaluační varianty.

Tato kombinace umožnila sestavit 20 evaluačních kontextů pro jednu místnost a 60 celkově. Na základě srovnávacího testu se záměrnou modelovou chybou a skrytou obsazeností byl jako hlavní výsledek stanoven následující poznatek hodnotící klíčovou metriku komfortu (*comfort_violation_hours*): hybridní regulátor dosáhl statisticky významně nižší doby porušení komfortu oproti všem referenčním strategiím ve všech 60 měřených párech. Po převodu na normalizované veličiny je zřejmé, že hybridní regulátor tráví mimo toleranci průměrně 25,15 % času v malé kanceláři, 19,23 % ve velké kanceláři a 49,95 % v zasedací místnosti.

Klíčovým zjištěním je potvrzení, že praktický přínos reziduální korekce úzce souvisí se závažností modelové odchylky a s charakterem exogenních poruch systému. V zasedací místnosti (`meeting_room`), pro kterou je typická proměnlivá obsazenost doprovázená výraznými chybami nominálního modelu, je nasazení hybridního řízení přínosné. U tepelně setrvačnější velké kanceláře (`large_office`) se naopak přínos hybridní korekce oproti čistému MPC vytrácí a část sledovaných metrik nevykazuje statisticky významný rozdíl. Z těchto zjištění plyne praktické doporučení: hybridní přístup je opodstatněný především v provozech s vysokou vnitřní nejistotou modelu a s obtížně identifikovatelnými kalibračními parametry. U zón s dobře známou tepelnou dynamikou a stabilním provozem je vhodnější čistý MPC pro svou nižší implementační náročnost.

Energetické náklady spojené se zlepšením komfortu zůstávají ve všech sledovaných případech podobné. Výpočetní nároky hybridního regulátoru jsou hluboko pod typickými vzorkovacími periodami systémů HVAC. Případné bariéry širšího nasazení datově řízeného řízení tedy pravděpodobně nesouvisejí s výpočetním výkonem, ale s organizační připraveností budovat a udržovat potřebnou datovou infrastrukturu.

Přes uvedená omezení, mezi která patří zejména využití syntetických dat, jednozónová topologie, absence aktivního chlazení a absence online učení, práce dokládá, že kombinace fyzikálně podloženého MPC s datově řízenou reziduální korekcí dokáže efektivně kompenzovat nepřesnosti nominálního modelu, aniž by byla narušena transparentnost optimalizačního procesu.

Seznam zkratek

- **ANN** – Artificial Neural Network (Umělá neuronová síť)
- **BACS** – Building Automation and Control Systems (Systémy automatizace a řízení budov)
- **BAS** – Building Automation System (Systém automatizace budov)
- **BEMS** – Building Energy Management System (Systém energetického řízení budov)
- **BMS** – Building Management System (Systém řízení budov)
- **CAPEX** – Capital Expenditures (Kapitálové výdaje)
- **CFD** – Computational Fluid Dynamics (Výpočetní dynamika tekutin)
- **CO_2** – Oxid uhličitý
- **CZT** – Centrální zásobování teplem
- **DDC** – Direct Digital Control (Přímé číslicové řízení)
- **DMPC** – Distributed Model Predictive Control (Distribuované modelově prediktivní řízení)
- **DR** – Demand Response (Flexibilita strany poptávky)
- **EMPC** – Economic Model Predictive Control (Ekonomické modelově prediktivní řízení)
- **EPBD** – Energy Performance of Buildings Directive (Směrnice o energetické náročnosti budov)
- **EU** – Evropská unie
- **FPGA** – Field Programmable Gate Array (Programovatelné hradlové pole)
- **GRU** – Gated Recurrent Unit
- **HDP** – Hrubý domácí produkt
- **HVAC** – Heating, Ventilation, and Air Conditioning (Vytápění, větrání a klimatizace)
- **ICNN** – Input Convex Neural Network (Vstupně konvexní neuronová síť)
- **ICRNN** – Input Convex Recurrent Neural Network

- **IoT** – Internet of Things (Internet věcí)
- **ISE** – Integral Square Error (Integrál kvadrátu regulační odchylky)
- **ITAE** – Integral Time Absolute Error
- **KF** – Kalman Filter (Kalmanův filtr)
- **KPI** – Key Performance Indicator (Klíčový ukazatel výkonnosti)
- **LMPC** – Linear Model Predictive Control (Lineární modelově prediktivní řízení)
- **LSTM** – Long Short-Term Memory
- **LTI** – Linear Time-Invariant (Lineární časově invariantní systém)
- **MHE** – Moving Horizon Estimation (Odhad na posuvném horizontu)
- **ML** – Machine Learning (Strojové učení)
- **MLP** – Multilayer Perceptron (Vícevrstvý perceptron)
- **MPC** – Model Predictive Control (Modelově prediktivní řízení)
- **Mtoe** – Million tonnes of oil equivalent (Milion tun ropného ekvivalentu)
- **NARX** – Nonlinear Autoregressive Network with Exogenous Inputs (Nelineární autoregresní síť s vnějšími vstupy)
- **NMPC** – Nonlinear Model Predictive Control (Nelineární modelově prediktivní řízení)
- **NN** – Neural Network (Neuronová síť)
- **nZEB** – nearly Zero Energy Building (Budova s téměř nulovou spotřebou energie)
- **OPEX** – Operational Expenditures (Provozní výdaje)
- **PDCBO** – Process-Driven Contextual Bayesian Optimization
- **PDE** – Partial Differential Equation (Parciální diferenciální rovnice)
- **PI** – Proportional-Integral (Proporcionálně-integrační regulátor)
- **PID** – Proportional-Integral-Derivative (Proporcionálně-integračně-derivační regulátor)

- **PLC** – Programmable Logic Controller (Programovatelný logický automat)
- **PMV** – Predicted Mean Vote (Předpovídané střední hodnocení komfortu)
- **PPD** – Predicted Percentage of Dissatisfied (Předpovídané procento nespokojených s komfortem)
- **QP** – Quadratic Programming (Kvadratické programování)
- **RC** – Resistor-Capacitor (Odpory a kapacity – náhradní tepelný obvod)
- **RLS** – Recursive Least Squares (Rekurzivní metoda nejmenších čtverců)
- **RNN** – Recurrent Neural Network (Rekurentní neuronová síť)
- **SEOS** – Smart Energy Operating System
- **SMPC** – Stochastic Model Predictive Control (Stochastické modelově prediktivní řízení)
- **TCN** – Temporal Convolutional Network
- **TUV** – Teplá užitková voda
- **UK** – United Kingdom (Spojené království)

Summary

This master's thesis addresses the optimization of building heating control systems by integrating machine learning techniques. While modern buildings require energy-efficient operations without compromising thermal comfort, traditional reactive controllers (such as On/Off or PID) fail to exploit the building's thermal inertia effectively. Model Predictive Control (MPC) overcomes this by optimizing future control actions based on a dynamic model and external forecasts; however, its practical adoption is heavily hindered by the difficulty of identifying and maintaining highly accurate physical models over time.

To address these limitations, this thesis proposes and evaluates a hybrid control architecture. The solution combines a physics-based nominal model predictive controller with a data-driven residual correction layer powered by a Long Short-Term Memory (LSTM) recurrent neural network. The LSTM network predicts the structural mismatch and unmeasured disturbances, correcting the nominal model's predictions before the optimization step.

The methodology involved developing a reproducible simulation environment to benchmark four control strategies: On/Off, PID, pure MPC, and the proposed hybrid MPC. The evaluation was conducted across three distinct virtual room types (a small office, a large office, and a meeting room) and subjected to six diverse climate scenarios. To rigorously test the hybrid controller's robustness, intentional parameter mismatches and hidden occupancy pulses were introduced into the nominal model to simulate real-world inaccuracies.

The experimental results demonstrate the following:

- **Improved Thermal Comfort:** The hybrid MPC achieved a statistically significant reduction in thermal comfort violation time across all 60 evaluated pairs compared to the reference strategies.
- **Performance by Zone Type:** The most substantial benefits were observed in spaces with highly variable occupancy and significant nominal model inaccuracies, such as the meeting room, where the time outside the comfort zone decreased by tens of percent. In contrast, in thermally stable environments with a well-calibrated model (like the large office), the hybrid approach provided only marginal improvements over pure MPC.
- **Operational Efficiency:** The enhanced comfort was achieved while maintaining comparable energy consumption to pure MPC.

- **Computational Stability:** The integration of the LSTM predictions did not compromise the convexity or numerical stability of the quadratic programming solver, ensuring real-time feasibility.

In conclusion, the thesis proves that combining physics-based MPC with data-driven residual correction is an effective and robust solution for building climate control. This hybrid approach is particularly recommended for zones where acquiring an accurate physical model is impractical or where significant unmeasured disturbances frequently occur.

Seznam použitých zdrojů

Afram, A., & Janabi-Sharifi, F. (2014). Theory and applications of HVAC control systems – A review of model predictive control (MPC). *Building and Environment*, *72*, 343–355. https://doi.org/10.1016/j.buildenv.2013.11.016

Al Dakheel, J., et al. (2020). Smart buildings features and key performance indicators: A review. *Sustainable Cities and Society*, *61*, 102328. https://doi.org/10.1016/j.scs.2020.102328

Amos, B., & Kolter, J. Z. (2017). Input Convex Neural Networks. *Proceedings of the 34th International Conference on Machine Learning (ICML)*. https://proceedings.mlr.press/v70/amos17b.html

ASHRAE. (2020). *ANSI/ASHRAE Standard 135-2020: BACnet – A data communication protocol for building automation and control networks*. Retrieved February 14, 2026, from https://www.ashrae.org/technical-resources/bookstore/bacnet-ansi-ashrae-standard-135-2020

ASHRAE. (2023). *ANSI/ASHRAE Standard 55-2023: Thermal Environmental Conditions for Human Occupancy*. Retrieved February 14, 2026, from https://webstore.ansi.org/standards/ashrae/ansiashrae552023

ASHRAE. (2024). *ANSI/ASHRAE Standard 135-2024: BACnet — A Data Communication Protocol for Building Automation and Control Networks*. Retrieved February 14, 2026, from https://webstore.ansi.org/standards/ashrae/ansiashrae1352024

Åström, K. J., & Hägglund, T. (1995). *PID Controllers: Theory, Design, and Tuning* (2nd ed.). ISA – The Instrumentation, Systems, Automation Society. https://www.ucg.ac.me/skladiste/blog_2146/objava_92847/fajlovi/Astrom.pdf

Åström, K. J., & Murray, R. M. (2008). *Feedback Systems: An Introduction for Scientists and Engineers*. Princeton University Press. https://www.cds.caltech.edu/~murray/books/AM08/pdf/am08-complete.pdf

Bagheri, A., Feldheim, V., & Ioakimidis, C. S. (2018). A Review on Thermal Network Models for Building and District Heating System Modelling. *Energies*, *11*(4), 890. https://doi.org/10.3390/en11040890

Bai, S., Kolter, J. Z., & Koltun, V. (2018). An Empirical Evaluation of Generic Convolutional and Recurrent Networks for Sequence Modeling. *arXiv preprint*, *arXiv:1803.01271*. Retrieved February 14, 2026, from https://arxiv.org/abs/1803.01271

Balaji, B., Bhattacharya, A. A., Fierro, G., Gao, J., Gluck, J., Hong, D., Johansen, A., Koh, J., Ploennigs, J., Agarwal, Y., Berges, M., Culler, D., & Gupta, R. K. (2018). Brick: Metadata schema for portable smart building applications. *Applied Energy*, *226*, 1273–1292. https://doi.org/10.1016/j.apenergy.2018.02.091

Bemporad, A., & Morari, M. (1999). Robust Model Predictive Control: A Survey. *Robustness in Identification and Control*, 207–226. https://cse.lab.imtlucca.it/~bemporad/publications/papers/survey-robust-mpc.pdf

Bresa, A., Dragusha, B., Berisha, X., Selimaj, R., & Sahiti, N. (2023). Identifying the optimal measures to reduce the heating energy consumption and environmental impact of existing apartment blocks in the Republic of Kosovo. *Journal of Sustainable Development of Energy, Water and Environment Systems*, *11*(3), 1110455. https://doi.org/10.13044/j.sdewes.d11.0455

Brooks, D. J., Garcia, M., Lefkovitz, N., Lightman, S., Nadeau, E., & Somorovsky, J. (2018). *Building Automation & Control Systems: An Investigation into Vulnerabilities and Attack Surfaces* (tech. rep.). Security Industry Association. Retrieved February 14, 2026, from https://www.securityindustry.org/wp-content/uploads/2019/09/Building-Automation-Control-Systems.pdf

CAP2i. (2024, July 16). *The impact of heat pumps on reducing carbon emissions.* Retrieved December 22, 2025, from https://cap2i.eu/news/the-impact-of-heat-pumps-on-reducing-carbon-emissions-6.php

Cohen, G. H., & Coon, G. A. (1953). Theoretical consideration of retarded control. *Transactions of the ASME*, *75*, 827–834. https://archive.org/details/sim_transactions-of-the-asm--e_1953_75/page/n851/mode/2up

Czech Statistical Office. (2021). *A sample survey on energy consumption in households (ENERGO 2021)* (tech. rep.). Czech Statistical Office. Retrieved December 22, 2025, from https://csu.gov.cz/vykazy/a-sample-survey-on-energy-consumption-in-households-energo-2021

Dassault Systèmes. (n.d.). *Decarbonize Building Operations With an Optimized HVAC System*. Retrieved December 22, 2025, from https://www.3ds.com/sustainability/decarbonization/decarbonizing-industry-operations/decarbonize-building-operations-hvac-systems

Doddi, H., Talukdar, S., Deka, D., & Salapaka, M. (2018). Data-driven identification of a thermal network in multi-zone building. *arXiv preprint arXiv:1810.07400*. https://arxiv.org/pdf/1810.07400.pdf

Dodoo, A. (2019). Techno-economic and environmental performances of heating systems for single-family code-compliant and passive houses. *E3S Web of Conferences*, *111*, 03039. https://doi.org/10.1051/e3sconf/201911103039

Drgoňa, J., Arroyo, J., Cupeiro Figueroa, I., Blum, D., Arendt, K., Kim, D., Perarnau Ollé, E., Oravec, J., Wetter, M., Vrabie, D. L., & Helsen, L. (2020). All you need to know about model predictive control for buildings. *Annual Reviews in Control*, *50*, 190–232. https://doi.org/10.1016/j.arcontrol.2020.09.001

Eini, R., & Abdelwahed, S. (2019). Learning-based Model Predictive Control for Smart Building Thermal Management. *arXiv preprint arXiv:1909.05331*. https://arxiv.org/pdf/1909.05331.pdf

Ellis, M., Durand, H., & Christofides, P. D. (2014). A tutorial review of economic model predictive control methods. *Journal of Process Control*, *24*(8), 1156–1178. https://doi.org/10.1016/j.jprocont.2014.03.010

Enerdata. (2012). *Energy Efficiency Trends in Buildings in the EU* (tech. rep.). Enerdata. Retrieved December 22, 2025, from https://energiatalgud.ee/sites/default/files/images_sala/6/68/Enerdata._Energy_Efficiency_Trends_in_Buildings_in_the_EU._2012.pdf

Energy Transitions Commission. (2020). *Building Heating: Decarbonising Heat in Buildings* (tech. rep.). Energy Transitions Commission. Retrieved December 22, 2025, from https://www.energy-transitions.org/wp-content/uploads/2020/08/200729-ETC-Paper-Building-Heating-FINAL.pdf

Enhanced EnHub: dynamic simulation of housing stock energy systems. (2020). *Building Research & Information*. https://doi.org/10.1080/19401493.2020.1788641

EURAC Research. (2021). *European Building Stock Analysis (EBSa)* (tech. rep.). EURAC Research. Retrieved December 22, 2025, from https://webassets.eurac.edu/31538/1643788710-ebsa_web_2.pdf

European Commission. (2020a, February 17). *Focus on energy efficiency in buildings (2020-02-17)*. Retrieved December 22, 2025, from https://commission.europa.eu/news-and-media/news/focus-energy-efficiency-buildings-2020-02-17_en

European Commission. (2020b, October 14). *Energy performance of buildings directive*. Retrieved December 22, 2025, from https://energy.ec.europa.eu/topics/energy-efficiency/energy-performance-buildings/energy-performance-buildings-directive_en

European Commission. (2023). *Heating and cooling*. Retrieved December 22, 2025, from https://energy.ec.europa.eu/topics/energy-efficiency/heating-and-cooling_en

Eurostat. (2025). *Energy consumption in households: Statistics Explained*. Retrieved December 22, 2025, from https://ec.europa.eu/eurostat/statistics-explained/index.php/Energy_consumption_in_households

Fierro, G., & Pauwels, P. (2022a). *Survey of Metadata Schemas and Ontologies for Building Applications* (tech. rep.) (Technical report, June 2022). IEA EBC Annex 81. Retrieved February 14, 2026, from https://annex81.iea-ebc.org/Data/publications/annex81_survey_of_metadata_schemas.pdf

Fierro, G., & Pauwels, P. (2022b, May). *Survey of metadata schemas for data-driven smart buildings* (tech. rep.). CSIRO (Operating Agent for IEA EBC Annex 81). Retrieved February 14, 2026, from https://annex81.iea-ebc.org/Data/publications/Survey%20of%20meta-data%20schemas%20%28final%291.pdf

Frahm, M., Klumpp, E., Meisenbacher, S., Matthes, J., Mikut, R., & Hagenmeyer, V. (2022). Development and Validation of Grey-Box Multi-Zone Thermal Building Models. *Proceedings of BauSim Conference 2022: 9th Conference of IBPSA-Germany and Austria*. https://doi.org/10.26868/29761662.2022.22

FutureBridge. (n.d.). *Renewable-based heating and cooling in Europe by 2030*. Retrieved December 22, 2025, from https://www.futurebridge.com/industry/perspectives-energy/renewable-based-heating-and-cooling-in-europe-by-2030/

Georges, L., Van Moeseke, G., Massart, C., & De Herde, A. (2012). Environmental and economic performance of heating systems for energy-efficient dwellings: Case of passive and low-energy single-family houses. *Energy Policy*, *40*, 452–464. https://doi.org/10.1016/j.enpol.2011.10.037

Göbel, S., Schmitt, E., Mehrfeld, P., & Müller, D. (2021). Underfloor heating system model for building performance simulations. *Proceedings of the 14th International Modelica Conference*. https://ecp.ep.liu.se/index.php/modelica/article/download/212/172/115

Goyal, S., & Barooah, P. (2010). Modeling thermal dynamics in multi-zone buildings. *Proceedings of the 1st ACM Workshop on Embedded Sensing Systems for Energy-Efficiency in Buildings*, 61–66. https://doi.org/10.1145/1878431.1878445

Hannula, E., Häkkinen, A., Solonen, A., Uribe, F., de Wiljes, J., & Roininen, L. (2025). Bayesian LSTM for indoor temperature modeling. *arXiv preprint arXiv:2504.03350*. https://arxiv.org/html/2504.03350v1

Holm, S. (1979). A Simple Sequentially Rejective Multiple Test Procedure. *Scandinavian Journal of Statistics*, *6*(2), 65–70. http://www.jstor.org/stable/4615733

Christofides, P. D., Scattolini, R., Muñoz de la Peña, D., & Liu, J. (2013). Distributed model predictive control: A tutorial review and future research directions. *Computers & Chemical Engineering*, *51*, 21–41. https://doi.org/10.1016/j.compchemeng.2012.05.010

IEA EBC Annex 81. (2023). *Data-Driven Smart Buildings: State-of-the-Art Review* (tech. rep.). Energy in Buildings and Communities (EBC) TCP, International Energy Agency. https://annex81.iea-ebc.org/Data/publications/Annex%2081%20State-of-the-Art%20Report%20(final).pdf

International Organization for Standardization. (2022). *ISO 16484-5:2022 — Building automation and control systems (BACS) — Part 5: Data communication protocol*. Retrieved February 14, 2026, from https://www.iso.org/standard/71935.html

International Organization for Standardization. (2024a). *Building automation and control systems (BACS) – Part 1: Project specification and implementation*. Retrieved February 14, 2026, from https://www.iso.org/standard/82331.html

International Organization for Standardization. (2024b). *ISO 16484-1:2024 — Building automation and control systems (BACS) — Part 1: Project specification and implementation*. Retrieved February 14, 2026, from https://www.iso.org/standard/84890.html

International Organization for Standardization. (2025). *ISO 7730:2025 — Ergonomics of the thermal environment — Analytical determination and interpretation of thermal comfort using calculation of the PMV and PPD index and local thermal comfort criteria*. Retrieved February 14, 2026, from https://www.iso.org/standard/78767.html

Jiang, Z., & Dong, B. (2024). Modularized neural network incorporating physical priors for future building energy modeling. *Patterns*, *5*(8), 101029. https://doi.org/10.1016/j.patter.2024.101029

Joseph, S. B., Dada, E. G., Abidemi, A., Oyewola, D. O., & Khammas, B. M. (2022). Metaheuristic algorithms for PID controller parameters tuning: review, approaches and open problems. *Heliyon*, *8*(5), e09399. https://doi.org/10.1016/j.heliyon.2022.e09399

Ju, Y., Lindholm, J., Verbeck, M., Jokisalo, J., Kosonen, R., Janssen, P., Li, Y., Schäfers, H., & Nord, N. (2022). Cost savings and CO2 emissions reduction potential in the German district heating system with demand response. *Science and Technology for the Built Environment*, *28*(2), 255–274. https://doi.org/10.1080/23744731.2021.2018875

Killian, M., & Kozek, M. (2016). Ten questions concerning model predictive control for energy efficient buildings. *Building and Environment*, *105*, 403–412. https://doi.org/10.1016/j.buildenv.2016.05.034

Kim, Y. S., & Park, C. S. (2023). Real-time predictive control of HVAC systems for factory building using lightweight data-driven model. *Journal of Building Performance Simulation*, *16*(5), 507–525. https://doi.org/10.1080/19401493.2023.2182363

Knobloch, F., Pollitt, H., Chewpreecha, U., Daioglou, V., & Mercure, J.-F. (2017). Simulating the deep decarbonisation of residential heating for limiting global warming to 1.5C. *arXiv preprint*. https://arxiv.org/pdf/1710.11019.pdf

Kumar, S., Pal, S. K., & Singh, R. P. (2021). LSTM-Based Model Predictive Control for Optimal Temperature Set-Point Planning. *Sustainability*, *13*(2), 894. https://doi.org/10.3390/su13020894

Liang, B., Wang, S., Huang, Y., Liu, Y., & Ma, L. (2023). F-LSTM: FPGA-Based Heterogeneous Computing Framework for Deploying LSTM-Based Algorithms. *Electronics*, *12*(5), 1139. https://doi.org/10.3390/electronics12051139

Mesbah, A. (2016). Stochastic Model Predictive Control: An Overview and Perspectives for Future Research. *IEEE Control Systems Magazine*, *36*(6), 30–44. https://doi.org/10.1109/MCS.2016.2602087

ODYSSEE-MURE. (2021). *Buildings: energy efficiency trends (Policy brief)*. Retrieved December 22, 2025, from https://www.odyssee-mure.eu/publications/policy-brief/buildings-energy-efficiency-trends.html

ODYSSEE-MURE. (2025). *Czechia — Efficiency trends and policies profiles*. Retrieved December 22, 2025, from https://www.odyssee-mure.eu/publications/efficiency-trends-policies-profiles/czechia.html

Oldewurtel, F., Sturzenegger, D., & Morari, M. (2013). Importance of occupancy information for building climate control. *Energy and Buildings*, *64*, 132–143. https://doi.org/10.1016/j.enbuild.2013.04.014

Paré, M.-C., Dermardiros, V., & Lesage-Landry, A. (2024). Efficient Data-Driven Model Predictive Control for Demand Response of Commercial Buildings. *IEEE Transactions on Control Systems Technology*. http://arxiv.org/pdf/2401.15742.pdf

Pathak, N., Foulds, J., Roy, N., Banerjee, N., & Robucci, R. (2019). Estimating Buildings' Parameters over Time Including Prior Knowledge. *arXiv preprint arXiv:1901.07469*. https://arxiv.org/pdf/1901.07469.pdf

Project Haystack. (2021a). *Guide Specification for Data Modeling of Building Systems and Equipment (v2021-12-30)*. Retrieved February 14, 2026, from https://marketing.project-haystack.org/images/documents/Project-Haystack-Guide-Specification-for-Data-Modeling-Standard-2021-12-30-English.pdf

Project Haystack. (2021b). *Project Haystack 4: User Guide*. Retrieved February 14, 2026, from https://project-haystack.org/download/guide

Qi, Z., Zhou, N., Feng, X., et al. (2025). Optimizing space heating efficiency in sustainable building design: a multi criteria decision making approach with model predictive control. *Scientific Reports*, *15*, 27743. https://www.nature.com/articles/s41598-025-13325-4

Ramaraj, S., et al. (2025). *Evaluating Thermostats' Deadbands Using HVAC Hardware-in-the-Loop* (tech. rep.). National Renewable Energy Laboratory (NREL). https://docs.nrel.gov/docs/fy25osti/91372.pdf

Rawlings, J. B., Mayne, D. Q., & Diehl, M. (2018). *Model Predictive Control: Theory, Computation, and Design* (2nd ed.). Nob Hill Publishing. https://sites.engineering.ucsb.edu/~jbraw/mpc/MPC-book-2nd-edition-4th-printing.pdf

Sha, X., et al. (2025). Online learning-enhanced data-driven model predictive control of residential building heating, ventilation, and air conditioning system for demand response. *Applied Energy*, *383*, 125341. https://doi.org/10.1016/j.apenergy.2025.125341

Shahriari, B., Swersky, K., Wang, Z., Adams, R. P., & de Freitas, N. (2016). Taking the Human Out of the Loop: A Review of Bayesian Optimization. *Proceedings of the IEEE*, *104*(1), 148–175. https://doi.org/10.1109/JPROC.2015.2494218

Stellato, B., Banjac, G., Goulart, P., Bemporad, A., & Boyd, S. (2020). OSQP: an operator splitting solver for quadratic programs. *Mathematical Programming Computation*, *12*(4), 637–672. https://doi.org/10.1007/s12532-020-00179-2

Taboada-Orozco, A., Yetongnon, K., & Nicolle, C. (2024). Smart Buildings: A Comprehensive Systematic Literature Review on Data-Driven Building Management Systems. *Sensors*, *24*(13), 4405. https://doi.org/10.3390/s24134405

Tanahashi, H., Kawaguchi, N., & Sasaki, Y. (2024). Evaluation of Transfer Learning Using RNN and LSTM for Room Temperature Prediction Considering Occupancy Variation. *IEEE Access*. https://doi.org/10.1109/ACCESS.2024.XXXXXX

Vala, J. (2004). *Heat transfer and air flow in buildings* (tech. rep.). Department of Mathematics and Descriptive Geometry, Brno University of Technology. Brno, Czech Republic. https://math.fce.vutbr.cz/konference/workshop_2004/pdf/R43.pdf

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention Is All You Need. *Advances in Neural Information Processing Systems*, 6000–6010. Retrieved February 14, 2026, from https://arxiv.org/abs/1706.03762

Wang, Y., Hirvonen, J., Qu, K., Jokisalo, J., & Kosonen, R. (2022). The Impact of Energy Renovation on Continuously and Intermittently Heated Residential Buildings in Southern Europe. *Buildings*, *12*(9), 1316. https://doi.org/10.3390/buildings12091316

Wilcoxon, F. (1945). Individual Comparisons by Ranking Methods. *Biometrics Bulletin*, *1*(6), 80–83. https://doi.org/10.2307/3001968

Xu, W., Svetozarevic, B., Di Natale, L., Heer, P., & Jones, C. N. (2024). Data-driven adaptive building thermal controller tuning with constraints: A primal-dual contextual Bayesian optimization approach. *Applied Energy*. https://www.sciencedirect.com/science/article/pii/S0306261923018573

Zhang, Y., et al. (2023). Optimizing the operation strategy of a combined cooling, heating and power system based on energy storage and ground-source heat pump considering energy management. *Scientific Reports*. https://www.nature.com/articles/s41598-023-29938-6

Ziegler, J. G., & Nichols, N. B. (1942). Optimum settings for automatic controllers. *Transactions of the ASME*, *64*, 759–768. https://www.math.nyu.edu/~eitan/kurse/control/ZieglerNichols.pdf

Seznam obrázků

Obrázek 1: Celková experimentální pipeline 41
Obrázek 2: Tok informací v hybridním MPC 47
Obrázek 3: Rozdělení doby porušení komfortu 53
Obrázek 4: Podíl času mimo komfort podle místnosti 54
Obrázek 5: Heatmapa podílu času mimo komfort 56
Obrázek 6: Reprezentativní trajektorie: malá kancelář 57
Obrázek 7: Reprezentativní trajektorie: velká kancelář 58
Obrázek 8: Reprezentativní trajektorie: zasedací místnost 59
Obrázek 9: Predikované a pozorované reziduum 59

Seznam tabulek

Tabulka 1: Typové místnosti a základní parametry 42
Tabulka 2: Strukturální odchylka modelu 43
Tabulka 3: Klimatické profily scénářů 48
Tabulka 4: Úrovně statistického vyhodnocení 50
Tabulka 5: Průměrné KPI regulátorů dle místnosti 51
Tabulka 6: Podíl času mimo komfort podle místnosti 53
Tabulka 7: Porušení komfortu dle klimatického profilu 54
Tabulka 8: Podíl času mimo komfort dle klimatického profilu 55
Tabulka 9: Ablace velikosti odchylky modelu 60
Tabulka 10: Výpočetní čas regulátorů a trénink LSTM 61
Tabulka 11: Wilcoxonův test pro *comfort_violation_hours* 61

Příloha A – Obsah přiloženého datového nosiče

Součástí práce je datový nosič (CD/DVD nebo ZIP archiv odevzdaný prostřednictvím IS STAG), který obsahuje následující adresářovou strukturu:

```
/
├── app/ ..... zdrojové kódy aplikační logiky
├── scripts/ ..... koordinační skripty
├── configs/ ..... konfigurační YAML soubory
├── data/ ..... vygenerované klimatické scénáře ve formátu CSV
├── artifacts/ ..... výstupní adresář pro logy, otisky konfigurací a výsledky
├── tests/ ..... sada automatizovaných testů
├── docs/ ..... rozšířená technická dokumentace
├── requirements.txt ..... seznam požadovaných softwarových závislostí
├── README.md ..... detailní návod k instalaci a spuštění simulačního programu
└── thesis.pdf ..... text této diplomové práce v elektronické podobě
```

Postup pro spuštění simulačního prostředí je popsán v souboru `README.md`. Technické požadavky na software a knihovny jsou uvedeny v souboru `requirements.txt`.